


存档日期: _____

存档编号: _____



江苏师范大学科文学院

JIANGSU NORMAL UNIVERSITY KEWEN COLLEGE

本科生毕业设计

题 目: 基于多智能体协同与大语言模型的
多专科医疗健康咨询及辅助分诊系统

姓 名: 窦成皓

专 业: 软件工程

年 级: 2023 级

学 号: 7230264110

指 导 教 师: 王伟、陈祥

江苏师范大学科文学院印制

设计原创性声明

本人郑重声明：所呈交的毕业设计，是在导师的指导下，独立进行研究所取得的成果，所有数据、图片资料真实可靠。除文中已经注明引用的内容外，本设计的研究成果不包含他人享有著作权的内容。对本设计所涉及的研究工作做出贡献的个人和集体，均已在设计中以明确的方式标明。本设计的知识产权归属培养单位。

本人签名： 梁成皓

2026 年 5 月 12

日



设计版权使用授权书

本设计“基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统”是本人在校期间所完成学业的组成部分，是在江苏师范大学科文学院教师的指导下完成的，因此，本人特授权江苏师范大学科文学院可将本毕业设计的全部或部分内容编入有关书籍、数据库保存，可采用复制、印刷、网页制作等方式将设计文本和经过编辑、批注等处理的设计文本提供给读者查阅、参考，可向有关学术部门和国家有关部门或机构呈送复印件和电子文档。本毕业设计无论做何种处理，必须尊重本人的著作权，署明本人姓名。

作者签名： 袁成皓
陈祥

指导教师签名： 王伟

2026 年 5 月 12 日

2026 年 5 月 12 日

基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统

摘 要

随着互联网医疗、医学知识库和大语言模型技术的发展，自然语言交互已成为健康信息服务的重要入口。然而，医疗健康咨询具有症状表述不完整、专业知识密集和错误风险不对称等特点。若直接依赖大语言模型生成回答，容易出现危险信号识别不稳定、证据来源难以追溯以及咨询与诊断边界不清等问题。针对上述问题，本文设计并实现了基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统 MedPilot。

系统采用 Vue 3、Spring Boot 和 FastAPI 构建前后端分离架构，AI 服务基于 LangGraph 组织安全筛查、症状抽取、信息充分性判断、主动追问、医学知识检索、辅助分诊和回答编排等固定职责节点。系统在调用大语言模型和向量检索前执行危险信号筛查，并根据信息完整程度选择主动追问或进入分诊流程；普通场景使用 bge-m3 生成查询向量，结合 FAISS 与词法重合度检索医学证据，再根据证据所属科室进行加权分析。系统还实现了 NDJSON 流式事件、问诊记录、授权健康档案、医生复核、知识审核与索引版本治理、Trace 监控、审计日志及基于医疗关系、组织范围和多因素认证的权限控制。

本文使用固定种子构建并执行了 1000 条人工构造工程测试。危险信号召回率为 80.00%，四个受支持科室的 Macro-F1 为 0.9585；加入 200 条知识库外症状后，五分类 Macro-F1 降至 0.5861。检索 Recall@3 为 71.88%，主动追问触发率为 100.00%，低证据回退率为 0.00%。结果表明，当前系统在封闭科室分诊和结构化追问方面表现较稳定，但对未登录危险表达和知识库外输入的识别与回退仍需改进。

关键词：多智能体协同；大语言模型；检索增强生成；医疗健康咨询；辅助分诊

Design and Implementation of a Multi-Specialty Healthcare Consultation and Auxiliary Triage System Based on Multi-Agent Collaboration and Large Language Models

Abstract

Natural-language interaction has become an important entry point for digital health services as Internet healthcare, medical knowledge bases, and large language models continue to develop. However, healthcare consultation involves incomplete symptom descriptions, specialized knowledge, and asymmetric consequences of errors. Directly generating responses with a large language model may therefore lead to unstable danger-signal detection, untraceable evidence, and an unclear boundary between consultation and diagnosis. To address these problems, this study designs and implements MedPilot, a multi-specialty healthcare consultation and auxiliary triage system based on multi-agent collaboration and large language models.

MedPilot uses Vue 3, Spring Boot, and FastAPI in a separated front-end and back-end architecture. Its AI service uses LangGraph to coordinate fixed-responsibility nodes for safety screening, symptom extraction, information-sufficiency assessment, active follow-up questioning, medical knowledge retrieval, auxiliary triage, and answer composition. Danger signals are screened before large-language-model inference or vector retrieval. When information is insufficient, the system asks a targeted follow-up question; otherwise, bge-m3 generates query embeddings, and FAISS retrieval is combined with lexical overlap to obtain evidence for department-level weighted analysis. The system also provides NDJSON streaming events, consultation records, authorized health-profile context, physician review, knowledge and index-version governance, trace monitoring, audit logs, and access control based on care relationships, organizational scope, and multi-factor authentication.

A fixed-seed engineering test set containing 1,000 manually constructed cases



was executed. Danger-signal recall was 80.00%, and Macro-F1 across the four supported departments was 0.9585; after 200 out-of-knowledge-base cases were added, five-class Macro-F1 decreased to 0.5861. Retrieval Recall@3 was 71.88%, the follow-up trigger rate was 100.00%, and the low-evidence fallback rate was 0.00%. These results indicate stable behavior in closed-set department triage and structured follow-up, while exposing limitations in unseen danger expressions and out-of-distribution fallback.

Key Words: Multi-Agent Collaboration; Large Language Models; Retrieval-Augmented Generation; Healthcare Consultation; Auxiliary Triage

目 录

设计原创性声明.....	I
设计版权使用授权书.....	I
摘 要.....	I
Abstract.....	II
目 录.....	IV
图清单.....	VIII
表清单.....	IX
1 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	2
1.2.1 在线医疗健康咨询与智能分诊研究.....	2
1.2.2 大语言模型在医疗领域的应用研究.....	3
1.2.3 多智能体协同与检索增强生成研究.....	4
1.3 研究目的与意义.....	4
1.3.1 研究目的.....	4
1.3.2 研究意义.....	5
1.4 研究内容.....	5
1.5 本章小结.....	6
2 系统分析与相关技术.....	7
2.1 系统总体需求.....	7
2.2 系统角色与业务流程.....	7
2.2.1 系统角色.....	7
2.2.2 业务流程.....	8
2.3 可行性分析.....	9
2.3.1 技术可行性.....	9



2.3.2	经济可行性	9
2.3.3	操作可行性	9
2.3.4	医疗安全与隐私可行性	10
2.4	功能需求分析	10
2.4.1	用户认证与权限管理	10
2.4.2	智能问诊与主动追问	10
2.4.3	辅助分诊与风险提示	10
2.4.4	问诊记录与健康档案	11
2.4.5	医学知识库管理	11
2.4.6	医生复核、监控与治理	11
2.5	非功能需求分析	12
2.5.1	安全性	12
2.5.2	可靠性	12
2.5.3	可维护性	12
2.5.4	可解释性与可追溯性	12
2.5.5	可用性与兼容性	12
2.6	系统关键技术	13
2.6.1	LangGraph 条件工作流	13
2.6.2	FastAPI 与 Pydantic 结构化契约	13
2.6.3	Ollama 本地大语言模型与嵌入模型	13
2.6.4	FAISS 向量检索与词法融合	13
2.6.5	NDJSON 事件流与 Trace	14
2.6.6	MySQL、Flyway 与安全组件	14
2.7	本章小结	14
3	系统总体设计	15
3.1	系统总体架构设计	15
3.1.1	设计目标与边界	15
3.1.2	分层架构	15
3.1.3	运行时交互	16
3.2	系统功能模块设计	16
3.2.1	用户侧功能模块	16
3.2.2	管理侧功能模块	17
3.2.3	模块间依赖	17
3.3	多智能体协同分诊流程设计	17
3.3.1	状态模型	17
3.3.2	安全筛查与高风险快速通道	18
3.3.3	症状抽取与信息充分性判断	18
3.3.4	RAG 检索与证据分诊	19
3.3.5	回答编排与事件终态	19
3.4	系统数据库设计	19
3.4.1	数据库设计原则	19
3.4.2	用户、会话与问诊记录	21
3.4.3	Trace 与审计数据	21
3.4.4	健康档案、复诊与医疗关系	21



3.4.5	知识文档与治理数据.....	22
3.5	系统权限与安全设计.....	22
3.5.1	认证与会话安全.....	23
3.5.2	角色授权矩阵.....	23
3.5.3	数据加密与敏感访问.....	23
3.5.4	知识与模型治理闸门.....	23
3.6	Trace 监控、知识治理与复核流程设计.....	23
3.6.1	Trace 事件模型.....	23
3.6.2	知识生命周期.....	24
3.6.3	医生复核闸门.....	24
3.6.4	监控与审计闭环.....	24
3.7	本章小结.....	25
4	系统详细设计与实现.....	26
4.1	用户认证与角色权限模块.....	26
4.1.1	登录认证实现.....	26
4.1.2	CSRF 与内部服务令牌.....	26
4.1.3	角色授权实现.....	26
4.1.4	医疗数据加密实现.....	28
4.2	智能问诊核心模块.....	28
4.2.1	危险信号筛查实现.....	28
4.2.2	症状抽取实现.....	30
4.2.3	信息充分性与主动追问.....	30
4.2.4	检索增强与科室判断.....	32
4.2.5	确定性回答编排.....	34
4.2.6	NDJSON 流式返回.....	34
4.3	问诊记录与健康档案模块.....	36
4.3.1	会话历史与消息持久化.....	36
4.3.2	记录与 Trace 幂等持久化.....	36
4.3.3	健康档案与复诊任务.....	37
4.3.4	记录详情页面.....	37
4.4	医学知识库与 RAG 模块.....	38
4.4.1	文档入库.....	38
4.4.2	审核与版本构建.....	39
4.4.3	前端知识库页面.....	40
4.5	医生复核与治理模块.....	40
4.5.1	复核队列.....	40
4.5.2	复核决定.....	40
4.5.3	模型与知识治理.....	40
4.6	监控、审计与异常处理模块.....	41
4.6.1	Trace 监控页面.....	41
4.6.2	审计日志.....	42
4.6.3	错误与取消处理.....	43
4.7	前端主要页面实现.....	43
4.7.1	智能问诊页面.....	43



4.7.2 知识库、复核和监控页面.....	44
4.7.3 响应式与状态反馈.....	44
4.8 本章小结.....	44
5 系统测试与分析.....	45
5.1 测试环境与测试策略.....	45
5.1.1 测试环境.....	45
5.1.2 测试策略.....	45
5.1.3 指标定义.....	46
5.2 测试集设计与功能测试.....	46
5.2.1 测试集分布.....	46
5.2.2 功能测试项目.....	47
5.3 多智能体流程测试.....	48
5.3.1 安全筛查节点.....	48
5.3.2 信息充分性与主动追问.....	48
5.3.3 检索、分诊与回答编排.....	49
5.4 危险信号与风险分级结果.....	49
5.4.1 危险信号统计.....	50
5.4.2 风险等级与处理耗时统计.....	50
5.5 知识检索与引用追踪测试.....	50
5.5.1 检索功能测试.....	51
5.5.2 引用可追溯性测试.....	51
5.6 权限、安全与异常处理测试.....	51
5.6.1 权限测试.....	51
5.6.2 数据保护测试.....	52
5.6.3 异常与恢复测试.....	52
5.7 测试结果分析.....	52
5.7.1 科室分诊结果.....	52
5.7.2 风险分级结果.....	52
5.7.3 测试结果的工程含义.....	52
5.8 本章小结.....	53
6 总结与展望.....	54
6.1 研究工作总结.....	54
6.2 后续展望.....	54
参考文献.....	56
致谢.....	59

图清单

图序号	图名称	页码
图 3-1	系统总体架构图	16
图 3-2	多智能体协同分诊流程图	19
图 3-3	数据库 E-R 图	21
图 4-1	用户权限管理页面	28
图 4-2	高风险快速通道结果	30
图 4-3	主动追问交互页面	33
图 4-4	检索证据支持的辅助分诊结果	35
图 4-5	多智能体协同分析过程	37
图 4-6	问诊记录的风险与证据链可视化	39
图 4-7	医学知识库与索引版本管理页面	41
图 4-8	智能体运行监控页面	43
图 4-9	问诊调用链路详情	43
图 4-10	审计日志查询页面	44
图 5-1	不同扰动强度下的任务性能	49
图 5-2	科室与回退类别混淆矩阵	50
图 5-3	不同测试路径的离线组件耗时分布	52

表清单

表序号	表名称	页码
表 2-1	系统角色及职责	8
表 2-2	功能需求	12
表 2-3	非功能需求	13
表 2-4	关键技术及用途	14
表 3-1	多智能体节点职责与输入输出	19
表 3-2	核心接口设计	18
表 3-3	用户表(users)	17
表 3-4	问诊记录表(consultation_records)	22
表 3-5	Trace 表(consultation_traces)	22
表 3-6	健康档案表(health_profiles)	23
表 3-7	知识文档表(knowledge_documents)	23
表 3-8	临床复核表(clinical_reviews)	25
表 3-9	审计日志表(audit_logs)	26
表 3-10	角色权限矩阵	26
表 5-1	主要测试环境配置	46
表 5-2	扩展工程测试集分布	47
表 5-3	核心功能测试用例	48

1 绪论

1.1 研究背景

医疗健康咨询的第一步通常不是给出疾病名称，而是把用户对身体状况的自然语言描述整理成可供判断的信息。用户可能只说“胸口不舒服”“这几天一直喘”或“皮肤突然很痒”，其中的症状部位、发生时间、严重程度、伴随表现和既往情况并不完整。咨询系统如果直接围绕原句生成一段建议，容易把缺失信息当作不存在，也难以判断哪些表现需要优先处理。因此，医疗咨询系统的核心问题并非单纯提高回答的流畅度，而是如何在有限交互中完成信息采集、风险识别和就医路径提示。

在线问诊和互联网医院研究已经显示，用户端服务正在从单一的信息展示转向咨询、导诊和流程协同。医疗咨询中的自然语言输入往往不完整，系统需要先整理症状和就医需求，再进入后续流程。本文因此把信息采集、风险判断和路径提示作为连续任务处理。

大语言模型为自然语言交互提供了新的实现路径。医学大语言模型应用综述总结了其在医疗文本处理、问答和辅助决策中的使用方式[6]。面向患者健康咨询的研究同时指出，模型生成能力仍伴随可靠性和安全性挑战[9]。因此，大语言模型适合承担信息理解和语言编排工作，但不能自动替代医疗流程中的安全控制。

医疗场景对错误的容忍度低。角色协同、临床工作流、模型局限和评价维度不能由一条自由生成链路同时承担。本文把安全筛查、信息补全、证据检索和结果复核拆开设计，并把流程终态作为可测试对象。

知识来源是另一个需要解决的问题。检索增强生成的基本做法是先检索外部文档，再将证据交给生成模块使用[15]。融合反思机制的研究尝试通过结果校验改善回答质量[18]。公共卫生问答研究也验证了检索增强方法在具体健康任务中的应用价值[20]。因此，知识库审核、索引版本、证据快照和结果追踪需要与检索流程一起设计。

多智能体协同提供了另一种组织思路。与让一个模型连续完成所有任务相比，固定职责节点可以分别负责危险信号筛查、症状抽取、信息充分性判断、知识检索、分诊和回答编排。不同节点之间通过结构化状态传递结果，流程中的条件分支也能够被记录和测试。本文关注的重点不是增加节点数量，而是明



确任务边界、输入输出和异常路径。

基于上述背景，本文选择“基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统”作为毕业设计课题，系统名称为 MedPilot。本文不把系统定位为疾病诊断工具，而是将其作为一个面向医疗健康咨询和辅助分诊的工程 Demo，关注自然语言输入如何经过安全筛查、信息补全、医学知识检索和分诊编排，最终形成可解释、可追踪的就医建议。

1.2 国内外研究现状

1.2.1 在线医疗健康咨询与智能分诊研究

在线医疗咨询研究可以按文本理解、分诊决策和服务流程三条路线梳理。第一条路线关注从医患交流中识别医疗主题、抽取症状或判断用户意图。第二条路线关注根据患者表现安排急诊优先级、专科方向或进一步检查。第三条路线关注把咨询、预约、导诊和就医反馈连接起来。三条路线的技术对象不同，但都需要处理用户表达不完整和业务流程存在条件分支的问题。

在文本理解方面，张建同的研究以医患交流文本为对象，探讨基于大语言模型的医疗主题识别，说明自然语言可以作为医疗服务入口[1]。但主题识别并不等同于分诊结论，后续仍需把主题与症状、风险和服务路径连接起来。基于这一启发，本文系统首先抽取结构化症状，再判断是否需要追问或进入知识检索；信息不足时，不把第一轮回复直接视为最终结论。

在急诊与分诊场景，杨霞的研究考察人工智能门诊分导诊对分诊准确率和患者满意度的影响[3]。徐伟的研究围绕急性主动脉夹层讨论急诊分诊筛查和预测工具[4]。这些研究分别从服务效果和风险筛查角度说明，分诊系统需要同时关注分类结果和高风险情况的优先处理。对于软件系统而言，这意味着“推荐科室”和“是否立即就医”不能被压缩成同一个字段；至少应保留风险等级、就医时效和触发依据等信息。

互联网医院流程研究进一步说明，用户体验不仅取决于页面是否易于操作，还取决于入口、信息提交、路径选择和服务衔接是否连贯[5]。如果系统为用户首次输入不足时直接输出结论，用户可能得到一段看似完整、实际缺少关键条件的回答。相比之下，主动追问可以把信息不足显式呈现出来，也为后续检索和分诊提供更稳定的输入。

现有研究仍存在三个与本文相关的工程缺口。其一，文本识别、急诊筛查和互联网医院流程往往分别讨论，较少在一个可运行的 Demo 中把它们串成连续状态。其二，系统通常重视最终推荐，却没有充分展示危险信号筛查和证据来源如何影响推荐。其三，分诊流程中的节点耗时、异常状态和结果保存不一



定被统一记录。本文将这些问题转化为系统设计要求，在流程层面保留安全快速通道、主动追问和证据分诊三个分支，并用 Trace 记录节点执行过程。

1.2.2 大语言模型在医疗领域的应用研究

医疗大语言模型的研究重点已经从“模型能否回答医学问题”扩展到“模型能否在具体医疗任务中被评价和约束”。医疗大语言模型评价研究强调，模型表现需要结合任务目标、评价方法和应用边界判断[25]。医疗领域大语言模型综述系统梳理了问答、知识服务和临床辅助等应用方向[26]。医疗领域智能化语言服务研究总结了医疗文本交互的特点与发展趋势[33]。医疗卫生智库研究讨论了大语言模型赋能智库转型的路径[34]。基于专利数据的研究呈现了国内医疗大语言模型应用的技术分布[35]。医疗聊天机器人研究回顾了从传统方法到大语言模型的演进路径[38]。CiteSpace 研究归纳了国内外医疗大语言模型的研究热点变化[39]。这些研究共同表明，模型能力需要放在明确的任务边界和证据环境中理解。

在应用层面，大语言模型可以用于文本摘要、主题识别、问答、知识抽取和助手式交互。医疗不良事件分类研究将模型输出与人工分类结果进行对比[27]。在线医疗社区虚假评论研究考察了合成数据与大语言模型在识别任务中的结合方式[37]。两阶段专业级微调研究讨论了临床数据对模型适配的作用[40]。医疗数据脱敏、中文医疗文献主题建模和专业知识抽取等问题，将在后文结合系统的数据保护和症状抽取流程进一步讨论。因此，医疗系统中的模型评价不能只依据生成文本是否自然，还需要结合数据安全和具体任务标准。

报告规范和评价框架研究也在快速完善。TRIPOD-LLM 应用范围调查强调，使用大语言模型开展医疗研究时，需要说明数据、任务、评价过程和报告边界[29]。TRIPOD-LLM 指南解读进一步给出了医疗大语言模型研究的报告要求[30]。这些工作说明，系统设计应保留足够的中间信息，使评审者能够知道结果经过哪些节点、使用了哪些证据，而不是只能看到最终回答。

国外研究进一步揭示了模型进入临床工作流时的限制。临终关怀伦理研究讨论了人工智能介入临终照护时的价值冲突[41]。健康治理研究提出了数字治理背景下的健康服务路径[42]。关于模型限制、知识来源安全、算法偏见和人工智能伦理治理的具体工程处理，分别在第2章、第3章和第4章展开。本文把安全要求转化为可实现、可检查的软件边界，不据此宣称系统已经解决医疗安全问题。

1.2.3 多智能体协同与检索增强生成研究

多智能体协同研究的核心不是增加调用次数，而是把复杂任务拆成具有清

晰边界的子任务。Chen 的研究展示了多智能体对话模型在诊断能力增强中的应用，并体现了角色分工与协同对复杂医疗推理任务的支持作用[10]。这些研究为本文的流程拆分提供了参考，但本文只实现软件工程范围内的固定职责节点，不把节点称作可以独立做出诊断的自治医生。

在 MedPilot 中，多智能体流程沿着一条条件图展开。安全筛查首先检查危险信号；未命中时，症状抽取节点从用户描述中形成结构化信息；如果信息不足，系统进入主动追问；信息达到当前分诊要求后，才进入知识检索、辅助分诊和回答编排。这样的顺序把“先判断是否危险”从提示词中的一句要求变成了代码中的流程约束，也把信息不足从异常输入转化为明确的业务状态。

RAG 研究解决的是外部知识如何进入生成流程的问题。GraphRAG 与混合专家模型的研究探索了在线医疗问答中的知识关联和模型协同[21]。融合反思机制的研究也尝试提高知识组织和回答质量[18]。本文将在第 3 章和第 4 章说明检索、重排、审核和引用快照如何落到实现。

RAG 并不是一个自动纠错模块。检索结果质量取决于文档内容、切片方式、查询表达和阈值设置；证据有了，也不意味着分诊结论一定正确。本文将 RAG 限定为证据接入机制：系统使用 bge-m3 生成查询向量，结合 FAISS 和词法重合度获取候选证据，并保留来源、文档、分片、版本等信息。证据随后参与科室加权判断，并以引用快照进入回答。知识审核和索引版本则由业务模块管理，从而让知识更新能够被追踪。

综合来看，多智能体协同解决的是“谁负责哪一步、下一步何时执行”，RAG 解决的是“外部知识如何进入这一步”。两者组合后仍然需要规则筛查、权限控制、复核和 Trace 等工程机制，才能形成可观察的系统。本文的研究重点不在于证明某一种模型或某一种 RAG 算法优于其他方法，而在于把这些技术放入一个有安全顺序、有条件路由、有证据记录的医疗健康咨询 Demo 中。

1.3 研究目的与意义

1.3.1 研究目的

本文的直接目标是设计并实现一套多专科医疗健康咨询及辅助分诊系统，使用户能够以自然语言描述健康问题，系统能够完成症状采集、信息补全、知识检索、风险判断和科室建议。系统需要处理三类不同情况：命中危险信号时进入快速通道；信息不足时通过主动追问补充条件；信息相对完整时根据检索证据生成辅助分诊结果。

围绕这一目标，本文将任务拆分为四个层次。第一，建立模型调用前的安全筛查机制，识别胸痛、呼吸困难、咯血、意识不清等危险信号，并依据规则



给出更高的就医紧急度。第二，建立症状抽取和主动追问机制，使系统能够区分“没有足够信息”和“没有发现危险信号”这两种不同状态。第三，建立带引用快照的医学知识检索和科室加权分诊机制，让分诊依据能够被查看和追踪。第四，把问诊记录、健康档案、医生复核、Trace 监控、知识治理和审计日志纳入同一业务闭环，使系统不止停留在一次性聊天页面。

1.3.2 研究意义

本文的意义首先体现在医疗健康咨询系统的工程组织方式上。传统的单体式问答流程容易把输入理解、风险判断、知识查询和回答生成混在一起，出现问题时难以定位。MedPilot 把这些步骤拆为固定职责节点，并用结构化状态连接节点，有助于将自然语言应用转换为可测试的软件流程。

其次，本文把安全顺序作为系统设计的一部分。危险信号筛查先于大语言模型和向量检索执行，信息不足时系统先追问而不是直接给出确定性建议。

最后，本文将医学知识库与分诊结果的可追溯性放在同一条链路中。系统不仅返回科室和风险等级，还保留检索证据、来源信息和索引版本；知识文档需要经过审核，模型和知识变化也有相应治理入口。对于毕业设计而言，这种设计使系统功能、数据结构和运行过程能够相互对应，便于后续测试和答辩说明。

1.4 研究内容

本文围绕 MedPilot 的设计与实现开展以下工作。

(1) 分析多专科医疗健康咨询及辅助分诊的业务需求。论文首先明确患者用户、医生、知识编辑、审核人员、管理员和审计人员等角色，梳理从登录、症状描述、主动追问、辅助分诊到问诊记录保存的业务流程，并分析系统在安全、隐私、权限、可追溯性和异常处理方面的非功能需求。

(2) 设计多智能体协同分诊架构。系统以 LangGraph 组织固定职责节点，建立安全筛查、症状抽取、信息充分性判断、主动追问、医学知识检索、辅助分诊和回答编排之间的条件路由。设计中重点说明危险信号快速通道、信息不足分支和正常检索分支的触发条件，以及节点之间传递的结构化数据。

(3) 设计医学知识库与检索增强生成流程。系统使用本地嵌入模型生成查询向量，在 FAISS 索引上进行向量检索，并融合词法重合度筛选候选证据。论文将分析知识文档的元数据、审核状态、分片信息、索引版本和引用快照，说明这些数据如何参与分诊解释和回答编排。

(4) 实现问诊业务及安全治理模块。系统实现用户认证、角色权限、问诊会话、问诊记录、健康档案、复诊任务、医生复核、知识审核、模型与索引治



理、Trace 监控和审计日志等功能。隐私数据采用受控访问和加密存储，医疗关系、组织范围和紧急授权等规则用于限制敏感数据访问。

(5) 完成前端交互和系统联调。前端提供登录、智能问诊、问诊记录、记录详情、健康档案、知识库、医生复核、运行监控和审计等页面。问诊页面接收 NDJSON 流式事件，展示安全筛查、症状采集、知识检索、辅助分诊和回答编排的执行状态。

(6) 开展系统测试与结果分析。测试内容包括功能流程、危险信号筛查、主动追问、知识检索、分诊结果、权限控制、异常处理和 Trace 事件完整性。论文使用扩展测试集统计危险信号召回率、各科室 F1 以及各风险等级 F1，并将测试结果定位为工程验证，不将其外推为临床效果。

1.5 本章小结

本章从在线医疗健康咨询、大语言模型、多智能体协同和 RAG 四个方面说明了课题背景。现有研究已经提供了自然语言医疗服务、模型应用、检索增强和分诊流程的技术基础，但医疗场景仍要求系统处理危险信号、信息缺失、证据来源和执行追踪等问题。MedPilot 据此采用安全筛查前置、固定职责节点协同、检索证据支撑和 Trace 贯穿业务的设计主线，目标是完成一套可运行、可观察的医疗健康咨询及辅助分诊 Demo。



2 系统分析与相关技术

2.1 系统总体需求

MedPilot 面向需要进行健康信息咨询和初步就医路径判断的用户，同时服务于负责知识维护、结果复核和运行管理的工作人员。系统的总体需求可以概括为三个层次：面向用户的咨询与记录，面向业务人员的审核与复核，面向系统管理员的运行和安全治理。三个层次彼此关联，但权限和数据范围不能混用。

用户侧的核心需求是用自然语言描述健康问题，并获得结构化、可理解的辅助分诊结果。系统需要支持单轮和多轮咨询：用户首次输入后，系统应先判断是否出现危险信号；如果信息不足，应指出需要补充的内容并提出具体问题；如果信息达到分诊条件，系统应返回推荐科室、风险等级、就医时效、分诊依据和相关知识证据。用户还需要能够查看历史问诊记录、记录详情、健康档案和复诊任务，但只能访问属于自己的数据。

业务人员的需求围绕“审核和复核”展开。知识编辑人员负责提交、整理和维护医学知识文档，审核人员或医生负责对知识来源、模型评测记录和临床复核任务进行审查。医生复核模块需要支持领取待处理任务、查看问诊上下文和提交复核决定。系统不能把模型生成的结果直接视为医生意见，因此复核结果必须作为独立记录保存，并与原始问诊轨迹区分。

管理员和审计人员的需求主要是运行可见性与安全边界。管理员需要管理用户、模型发布、知识版本、治理变更和安全事件；审计人员需要查看运行指标和审计日志，但不应获得与其职责无关的写入权限。系统还需要保存节点执行状态、耗时、错误终态和引用快照，以便在出现异常时定位具体阶段。

从业务闭环看，系统不能只完成“输入—回答”两个动作。一次完整咨询至少应包含用户认证、会话建立、风险筛查、信息采集、条件路由、证据检索、辅助分诊、回答编排、事件流式传输和记录持久化。任何一步失败，都应留下可识别的错误状态，不能让前端把中断误显示为成功完成。

2.2 系统角色与业务流程

2.2.1 系统角色

MedPilot 在后端定义了六类角色：USER、DOCTOR、KNOWLEDGE_EDITOR、REVIEWER、ADMIN 和 AUDITOR。USER 是患者侧普通用户，负责提交咨询、查看个人问诊记录和维护授权健康档案。DOCTOR 可以处理临床复核任务，并在规定权限内查看相关患者上下文。

KNOWLEDGE_EDITOR 负责知识文档入库、元数据维护和索引构建。REVIEWER 负责对知识、模型评测结果和复核任务进行独立审查。ADMIN 负责用户、系统配置和治理操作。AUDITOR 负责查看监控、统计和审计证据，相关内容如表 2-1 所示。

表 2-1 系统角色及职责

角色	主要职责	可访问资源
USER	提交健康咨询，查看个人记录	个人会话、记录、档案、复诊和健康档案
DOCTOR	处理临床复核和紧急授权	复核队列、授权患者上下文
KNOWLEDGE_EDITOR	提交知识文档和构建索引	知识入库、版本构建
REVIEWER	审核知识、模型评测和复核任务	审核资源、临床复核
ADMIN	用户、模型、治理和系统管理	管理端写入与高风险操作
AUDITOR	查看监控和审计证据	监控、Trace、审计只读资源

角色不是页面菜单的别名，而是后端接口的访问边界。前端路由会根据角色控制管理端页面的可见性，但真正的授权由 Spring Security 过滤链和控制器规则完成。例如，临床复核接口只允许 DOCTOR 和 REVIEWER 访问；紧急授权接口只允许 DOCTOR 执行；知识文档的上传和版本构建由 ADMIN 或 KNOWLEDGE_EDITOR 负责；模型冻结、治理变更执行和回滚等高风险操作则进一步收紧到 ADMIN。这样的双层控制可以避免仅依赖前端隐藏按钮造成权限绕过。

2.2.2 业务流程

用户进入问诊页面后，前端向业务后端发起咨询请求，后端建立或恢复会话，并把历史消息和经过授权的健康档案上下文传递给 AI 服务。AI 服务首先运行安全筛查。当前实现使用否定感知的危险信号匹配器，检查胸痛、呼吸困难、气促、咯血、便血、晕厥、意识不清和大出血等表现。如果命中危险信号，流程直接进入高风险快速通道，不再等待普通的模型抽取和向量检索。

未命中危险信号时，LangGraph 工作流进入症状抽取节点。该节点利用本地大语言模型将自然语言整理为症状、持续时间、严重程度、既往史和原始描述等字段，同时再次保留由规则匹配得到的危险信号结果。随后，信息充分性判断节点根据症状数量、持续时间和严重程度判断是否能够进入分诊。如果信息不足，系统生成一条主动追问并结束本轮，等待用户补充；如果信息足够，则使用用户原始描述和结构化症状拼接检索查询。

检索节点调用嵌入模型生成查询向量，在 FAISS 索引中获取候选分片，同时计算词法重合度并融合分数。分诊节点从受支持科室的证据中进行加权投票，

输出推荐科室、风险等级、置信度、支持分和结构化分诊因素。回答编排节点再根据分诊结果、症状和证据生成自然语言说明，并把引用快照一并返回。前端接收 NDJSON 事件，按节点状态更新页面；业务后端在终态事件完整且没有错误时保存问诊记录和 Trace。

业务流程中存在三种需要区分的终态。第一种是高风险升级，表示安全筛查命中规则，系统给出立即或尽快就医提示。第二种是等待追问，表示当前信息不足，系统暂不做科室判断。第三种是正常完成，表示系统已经完成检索、辅助分诊和回答编排。错误状态则由独立事件表示，不能复用正常完成状态。

2.3 可行性分析

2.3.1 技术可行性

系统采用的技术均有成熟的本地运行环境和项目依赖。FastAPI 负责 AI 服务接口，LangGraph 负责条件工作流，Ollama 提供本地聊天模型和嵌入模型，FAISS 负责向量索引，MySQL 保存业务数据，Redis 可用于共享会话和推理容量控制。医疗健康领域应用研究提示，大语言模型的部署需要结合具体场景和应用边界[7]。项目已经配置 qwen2.5:7b 和 bge-m3 模型，AI 服务能够完成安全筛查、症状抽取、知识检索、辅助分诊和回答编排的连续调用。后端依赖 Java 17、Spring Boot、JPA、Flyway 和 Spring Security，前端提供问诊、记录、知识和监控等页面。因此，系统不需要依赖未验证的外部商业模型即可完成 Demo 运行。

技术可行性还体现在模块之间的接口契约。AI 服务使用 Pydantic 模型约束症状、证据、分诊结果、追问和回答结构；后端通过 NDJSON 解析节点事件，并在持久化前检查事件顺序和终态；前端根据事件类型更新不同的展示状态。结构化契约减少了自由文本在节点之间传递造成的字段漂移，使每个模块能够独立测试。

2.3.2 经济可行性

本系统以本地开发和毕业设计 Demo 为目标，使用开源框架、本地模型和本地向量索引，不需要购买在线推理服务或专用硬件。开发阶段可以在已有计算机环境中运行前端、后端、AI 服务和数据库，部署成本主要是运行环境配置和数据维护。系统如果进入真实机构场景，仍需要重新评估计算资源、数据合规、身份系统和运维投入；这些不属于本毕业设计的成本结论。

2.3.3 操作可行性



系统将复杂的多节点执行过程转化为连续的页面状态。用户只需填写自然语言描述，系统负责抽取症状、必要时提出追问，并以卡片化结果展示风险、科室、依据和引用。管理端按角色提供知识维护、临床复核、监控、审计和用户管理页面。对于不熟悉模型内部机制的使用者，节点标签和状态提示可以帮助其理解当前流程处于采集、追问、检索、分诊还是编排阶段。

操作可行性也要求系统对异常情况给出明确反馈。AI 服务不可用、模型缺失、知识索引不可用、会话正在被其他请求占用或推理容量超限时，健康接口和咨询接口都应返回可识别状态。前端不能把服务降级误显示为正常分诊结果，工作人员也能通过 Trace 和审计日志查看异常来源。

2.3.4 医疗安全与隐私可行性

本系统的安全边界采用“前置规则、权限控制、数据保护、人工复核”四层设计。医疗大语言模型研究指出，模型进入临床工作流时需要关注信息收集、指南遵循和结果解释等限制[12]。数据投毒研究进一步说明，知识来源和输入环境本身也可能成为攻击面[31]。医疗数据脱敏研究关注模型处理敏感信息时的风险[28]。人工智能伦理安全治理研究强调，系统需要明确应用边界并保留治理责任[44]。前置规则在模型调用前检查危险信号；权限控制使用 JWT 认证、角色授权和 CSRF 防护；敏感数据通过 AES-256-GCM 加密转换器保存，并限制健康档案、临床记录和紧急授权的访问范围；医生复核为高风险或需要人工判断的业务提供独立处理入口。

该设计能够在 Demo 层面验证安全流程是否存在、权限是否按角色生效、数据是否经过加密和事件是否可追踪，但不能据此证明系统已经满足医院上线或临床使用要求。医疗安全的最终评价还需要真实流程调研、专业人员参与和机构级审核，本文不把工程实现结果扩大为临床结论。

2.4 功能需求分析

2.4.1 用户认证与权限管理

系统需要支持用户登录、当前身份查询、退出登录和 CSRF 令牌获取。登录成功后，后端通过 HttpOnly Cookie 保存 JWT，前端不直接管理服务令牌。每个请求由认证过滤器解析身份，再由接口规则判断是否具有相应角色。用户只能访问自己的问诊会话、记录、健康档案和复诊任务；管理端接口则按 ADMIN、DOCTOR、REVIEWER、KNOWLEDGE_EDITOR 和 AUDITOR 分别限制。

2.4.2 智能问诊与主动追问

智能问诊是系统的核心功能。输入接口需要限制文本长度、拒绝空白内容，并允许用户提交有限的历史消息和授权健康背景。系统首先执行危险信号筛查，命中后走高风险快速通道。未命中时，症状抽取节点生成结构化症状；信息充分性判断节点在症状不足时返回追问问题。追问不是普通的聊天回复，而是带有缺失信息类别的结构化结果，前端可以据此展示本轮需要补充的内容。

2.4.3 辅助分诊与风险提示

分诊结果至少包含推荐科室、低/中/高风险等级、置信度、就医时效、命中规则或证据因素以及是否暂缓判断。高风险结果来自确定性危险信号规则；普通结果来自知识证据的科室加权；没有足够证据时，系统输出全科或建议线下分诊台，并把 `abstained` 标记为真。风险提示需要和分诊依据同时展示，避免用户只看到一个缺少条件说明的科室名称。

2.4.4 问诊记录与健康档案

系统需要持久化问诊会话、消息、症状、分诊结果、回答、引用和 `Trace` 标识。用户可以查看历史记录和单条记录详情。健康档案保存过敏史、既往情况、用药信息和备注等背景字段，只有在用户授权后才作为当前问诊的背景上下文传入 AI 服务。复诊任务与问诊记录关联，支持查看待办和更新状态。健康档案不是本轮症状的替代物，抽取节点需要区分背景信息与当前描述。

2.4.5 医学知识库管理

知识库功能包括文档入库、文件上传、文档列表、统计信息、版本构建、版本激活、版本差异查看、审核和删除。文档需要保存标题、科室、来源机构、URL、发布日期、校验摘要、解析状态、向量状态和审核状态。只有经过审核且进入有效索引的知识才能参与普通分诊。索引激活需要记录版本，检索结果保存该版本号，便于解释某次回答使用的知识环境。

2.4.6 医生复核、监控与治理

医生复核模块需要支持查询复核记录、领取任务和提交决定；复核过程应保留处理人、状态、意见和时间。监控模块提供健康状态、实时 `Trace`、节点事件、历史 `Trace` 和统计信息；审计模块记录操作者、角色、请求方法、动作、状态、成功标志、请求标识和耗时。治理模块进一步管理模型发布、评测记录、知识来源、变更审批、红队测试、回滚演练、监控快照和安全事件，相关内容如表 2-2 所示。

表 2-2 功能需求

编号	功能模块	功能说明
F1	用户认证	登录、当前身份、退出和 CSRF 令牌
F2	智能问诊	自然语言输入、流式状态、追问和辅助分诊
F3	问诊记录	保存并查询症状、分诊、回答、引用和 Trace
F4	知识库	文档入库、审核、版本构建、激活和差异
F5	医生复核	领取任务并提交确认、修改、退回或升级
F6	监控审计	查看健康状态、Trace、运行统计和审计日志

2.5 非功能需求分析

2.5.1 安全性

系统必须区分认证、授权和数据保护三个问题。认证使用 JWT 和可选的 OIDC 资源服务器；授权由后端接口规则执行；数据保护覆盖健康档案、问诊记录、附件和审计信息。CSRF 令牌使用 Cookie 仓库保存，生产环境通过环境变量提供 JWT 密钥、AI 服务令牌和数据加密密钥。AI 服务令牌只在后端与 AI 服务之间传递，前端不得配置或发送。

2.5.2 可靠性

咨询接口使用流式事件传输，事件需要包含协议版本、Trace 标识、序号、节点、阶段、状态和耗时。后端在保存结果前检查事件序列、终态和错误状态，避免把断流、超时或节点失败写成成功记录。推理容量控制和会话租约用于减少同一会话并发提交造成的状态覆盖。健康检查同时检查 Ollama、聊天模型、嵌入模型、知识索引、模型治理和共享状态。

2.5.3 可维护性

系统采用前端、业务后端和 AI 服务分层组织，各层通过 HTTP 或 NDJSON 契约交互。AI 服务的 Pydantic 模型设置为不可变结构，规则筛查、症状抽取、追问、检索、分诊和编排分别位于独立模块。数据库通过 Flyway 管理迁移，后端使用实体、仓库、服务和控制器分层。这样的结构便于替换模型、扩展科室知识或增加治理接口，而不必重写整个问诊流程。

2.5.4 可解释性与可追溯性

系统需要让使用者看到结果从何而来。分诊结果保留规则因素或证据因素，RAG 结果保留文档、分片、来源、URL 和索引版本，Trace 保留节点执行顺序和耗时，审计日志保留操作者和动作。可追溯性只能说明系统保存了依据和过程，不能等同于医学结论正确。

2.5.5 可用性与兼容性

前端需要在桌面和移动尺寸下展示问诊输入、流式状态、追问、分诊结果和引用信息。状态组件应区分加载、正常完成、等待追问、风险升级和错误。管理端页面根据角色显示相应模块，未经授权的路径由路由守卫拦截，后端再次校验。系统的可用性目标是让 Demo 流程清楚、反馈及时、错误可理解，不在本章对真实用户满意度作量化结论，相关内容如表 2-3 所示。

表 2-3 非功能需求

类别	要求	验证方向
安全性	认证、授权、CSRF、加密和服务令牌隔离	权限测试、密文篡改测试
可靠性	流式事件有序、终态明确、失败可追踪	断流、超时、取消测试
可维护性	分层模块和结构化契约	模块测试、接口契约检查
可追溯性	记录证据、索引版本、Trace 和审计	记录详情与监控查询
可用性	区分加载、追问、完成、升级和错误状态	页面流程测试

2.6 系统关键技术

2.6.1 LangGraph 条件 workflow

LangGraph 用于把症状抽取、追问、检索、分诊和回答编排组织成有向图。图中的条件边根据症状充分性选择检索或追问；安全筛查在图执行前运行，命中危险信号时进入快速通道。多智能体研究强调，医疗智能体应明确工具使用、工作流衔接和安全约束[24]；因此，条件图能够显式表示流程状态，并为每个节点注入测试替身。

2.6.2 FastAPI 与 Pydantic 结构化契约

FastAPI 负责 AI 服务的健康检查、咨询流和知识、监控相关接口。Pydantic 模型定义 StructuredSymptoms、RankedEvidence、TriageResult、ComposedAnswer 和 FollowUpQuestion 等结构，限制字段类型、枚举值、长度和数值范围。结构化契约使模型输出需要先经过解析和校验，才能进入下一个

节点或写入事件。

2.6.3 Ollama 本地大语言模型与嵌入模型

Ollama 作为本地模型服务边界，当前聊天模型为 qwen2.5:7b，嵌入模型为 bge-m3。聊天模型用于症状抽取，嵌入模型用于把检索查询转换为向量；最终分诊回答由经过校验的结构化字段确定性渲染，不直接采用自由生成文本。模型服务通过独立令牌受后端保护，健康接口会检查模型是否实际可用。将模型运行在本地便于毕业设计环境下控制数据流和复现实验条件，但不代表它已经满足生产级算力和运维要求。

2.6.4 FAISS 向量检索与词法融合

FAISS 负责在知识索引中执行归一化内积检索，结果可视为向量相似度。系统取较宽的候选集合，再计算查询与分片文本的字符二元组重合度，将向量分数和词法分数按固定比例融合，最后按综合分排序并截取 Top-K。该实现同时保留语义相似和关键词命中的互补性，并把分数、来源和索引版本写入 RankedEvidence。

2.6.5 NDJSON 事件流与 Trace

NDJSON 把一次咨询拆成多条独立事件，前端可以在节点完成时更新状态，不必等待整段回答生成后再刷新页面。事件包含协议版本、Trace ID、序列号、节点、阶段、状态、数据和耗时。后端对事件序列进行校验并持久化 Trace，监控端据此展示实时节点、历史轨迹和统计信息。

2.6.6 MySQL、Flyway 与安全组件

MySQL 保存用户、会话、消息、问诊记录、Trace、健康档案、知识文档、复核、治理和审计数据。Flyway 迁移脚本保证数据库结构按版本演进。Spring Security 负责 JWT、CSRF 和角色授权，AES-256-GCM 用于敏感字段加密转换，Redis 可用于共享会话、推理容量和运行时协调，相关内容如表 2-4 所示。

表 2-4 关键技术及用途

技术	用途	所在层
LangGraph	组织条件工作流和节点路由	AI 服务
FastAPI/Pydantic	提供接口并校验结构化契约	AI 服务
Ollama/qwen2.5:7b	症状抽取	模型服务
bge-m3/FAISS	查询嵌入与证据检索	RAG
NDJSON/Trace	流式传输和过程追踪	服务协同
MySQL/Flyway	业务数据和版本迁移	数据层



2.7 本章小结

本章从需求、角色、流程、可行性和非功能要求对 MedPilot 进行了系统分析。系统需要同时满足用户咨询、信息追问、辅助分诊、证据展示、记录保存、医生复核和运行审计等要求，不能把医疗健康咨询简化为一次模型调用。技术上，LangGraph 负责条件工作流，FastAPI 和 Pydantic 负责 AI 服务契约，Ollama 提供本地模型，FAISS 和 RAG 负责证据检索，NDJSON 和 Trace 负责过程传输与追踪，MySQL、Flyway 及安全组件负责业务数据和访问边界。第 3 章将在此基础上进行总体架构、功能模块、数据库和权限设计。

3 系统总体设计

3.1 系统总体架构设计

3.1.1 设计目标与边界

MedPilot 的总体设计围绕四个目标展开：把危险信号筛查放在生成流程之前，把复杂问诊拆成职责清晰的节点，把医学知识检索结果转化为可追溯证据，把一次咨询的执行过程保存为可检查的 Trace。系统的输出是辅助分诊信息和健康咨询回答，不承担疾病确诊、处方生成或治疗决策，如图 3-1 所示。




图 3-1 系统总体架构图

系统边界由用户端、业务后端、AI 服务、数据存储和治理管理五部分组成。用户端负责输入、状态展示和结果查看；业务后端负责认证、会话、记录、权限、持久化和接口编排；AI 服务负责安全筛查、智能体 workflow、模型调用和知识检索；MySQL 保存结构化业务数据和治理数据；FAISS 索引保存向量检索所需的知识分片；管理端负责知识、复核、监控和审计。Ollama 和 Redis 属于运行时基础设施，前者提供本地模型，后者在启用共享状态时负责会话协调和推理容量控制。

3.1.2 分层架构

系统采用前端、业务后端和 AI 服务分层。前端以路由和角色工作区组织患者端与管理端页面，通过 HTTP 请求和 NDJSON 流接收后端数据。业务后端使用控制器、服务、仓库和实体组织业务逻辑，负责把用户身份、患者关系、问诊记录和 AI 事件连接起来。AI 服务内部以 LangGraph 工作流为核心，外围由 FastAPI 路由、会话协调、知识库路由和监控路由组成。

分层设计把“语言理解”和“业务事实”分开。AI 服务可以返回结构化症状、证据和分诊结果，但不能自行决定谁可以读取患者记录；访问控制、患者关系和组织范围由业务后端执行。反过来，业务后端也不直接解析模型自由文本，而是依赖 Pydantic 契约和事件协议验证 AI 结果。这种边界避免了模型输出绕过业务授权，也避免业务层把不完整文本当作结构化医疗记录。

3.1.3 运行时交互

一次咨询的运行时交互可以分为五步。第一步，用户通过登录后的会话向后端提交咨询文本，后端解析历史消息和授权健康档案。第二步，后端调用 AI 服务并建立 Trace 上下文。第三步，AI 服务返回安全筛查和后续节点的 NDJSON 事件。第四步，后端在转发事件的同时累计回答、引用、终态和失败信息。第五步，只有在事件序列完整且终态为成功或明确的追问等待状态时，后端才持久化问诊记录和 Trace。

系统健康检查也遵循分层原则。AI 服务检查 Ollama 是否在线、聊天模型和嵌入模型是否可用、知识索引是否健康以及模型治理状态；后端再检查数据库、共享状态和 AI 服务连接。任何关键组件不可用时，健康接口返回降级状态，前端据此显示服务不可用或部分功能受限，而不是继续提交一条无法完成的咨询。

3.2 系统功能模块设计

3.2.1 用户侧功能模块

用户侧由认证、智能问诊、问诊记录、健康档案、复诊任务和设置等模块组成。认证模块负责登录、当前身份查询、退出和 CSRF 令牌获取。智能问诊模块负责新建会话、提交文本、接收流式事件、展示追问和显示辅助分诊结果。记录模块提供历史记录列表、筛选和记录详情，详情中包含症状、分诊结果、回答、引用和执行轨迹摘要。健康档案模块维护授权背景信息，复诊模块展示与问诊记录相关的待办任务，相关内容如表 3-1 所示。

表 3-1 用户表(users)

字段	类型	长度	约束	备注
id	BIGINT	—	主键、自增	用户编号
username	VARCHAR	64	非空、唯一	用户名
password_hash	VARCHAR	255	可空	密码摘要
role	VARCHAR	16	非空	角色
active	BOOLEAN	—	非空	启用状态
token_version	BIGINT	—	非空	令牌版本
organization_code	VARCHAR	64	可空	组织范围

字段	类型	长度	约束	备注
mfa_assurance_lev	INT	—	非空	MFA 级别

后端角色枚举固定为 USER、DOCTOR、KNOWLEDGE_EDITOR、REVIEWER、ADMIN 和 AUDITOR。USER 对应患者侧普通用户，其他角色只能通过管理端访问其职责范围内的资源。

3.2.2 管理侧功能模块

管理侧按照职责分为用户管理、知识库、临床复核、运行监控、审计和治理模块。用户管理只由管理员使用，用于维护用户状态和角色。知识库模块供知识编辑人员维护文档和索引，审核人员、医生和管理员按权限查看或审核。临床复核模块供医生和审核人员领取任务、查看上下文和提交决定。监控模块供管理员和审计人员查看健康状态、Trace 事件和运行统计。审计模块提供日志查询和导出。治理模块则记录模型、数据集、知识来源和变更审批等证据。

3.2.3 模块间依赖

认证模块是所有非公开业务的入口。智能问诊依赖会话、健康档案和 AI 服务；问诊记录依赖咨询流的成功终态；临床复核依赖问诊记录和患者访问上下文；知识库为 RAG 检索提供有效索引；监控和审计横向记录问诊、知识和治理模块的活动。依赖关系不是简单的页面跳转，而是以用户、会话、记录、Trace 和审核对象为核心实体进行关联，系统主要接口、调用方法、用途及权限约束汇总见表 3-2。

表 3-2 核心接口设计

接口	方法	用途	主要权限
/api/auth/login	POST	登录并签发 JWT	公开
/api/consult	POST	提交咨询并返回 NDJSON	已认证用户
/api/records/{id}	GET	查看问诊记录详情	记录所有者
/api/knowledge/ingest	POST	提交知识文档	ADMIN/知识编辑
/api/clinical-reviews/{id}/decision	POST	提交复核决定	医生/审核员
/api/monitor/trace/{id}	GET	查看 Trace 详情	ADMIN/审计员

3.3 多智能体协同分诊流程设计

3.3.1 状态模型

AI 服务以统一的工作流状态承载本轮输入及各节点产出的中间结果。与医疗业务含义直接相关的对象均采用不可变 Pydantic 模型，节点只能提交新的状



态更新，不能在后续节点中改写已形成的结果。这样可以保留节点边界，避免一个节点通过副作用改变另一个节点的输入，多智能体协同分诊流程如图 3-2 所示。




图 3-2 多智能体协同分诊流程图

为控制上下文规模并保持会话连续性， workflow 还记录本轮会话的标识、轮次及历史处理方式。历史处理方式在完整对话和摘要上下文之间切换，避免过长的历史消息持续传入模型。健康档案仅在用户授权后作为背景资料参与抽取，并明确与本轮症状和指令分离。各智能体节点的输入、输出及路由条件汇总见表 3-3。

表 3-3 多智能体节点职责与输入输出

节点	输入	输出	路由条件
safety_screen	用户原始文本	危险信号、规则分诊	命中则进入高风险快速通道
extract	文本、历史、授权档案	结构化症状	未命中安全规则时执行
ask_followup	症状结构	追问问题、缺失字段	信息不足
retrieve	文本和症状	Top-K 证据	信息充分
classify	症状和证据	科室、风险、因素	检索完成
compose	分诊结果和证据	确定性回答、引用	分诊完成

3.3.2 安全筛查与高风险快速通道

安全筛查是咨询流的前置节点。危险信号匹配器维护规范词和同义表达，并按照句子边界和否定词判断某个表现是“出现”还是“被否认”。当前规则覆盖胸痛、呼吸困难、气促、咯血、便血、晕厥、意识不清和大出血。例如，“没有胸痛，也没有呼吸困难”不能触发高风险规则；“没有胸痛，但后来出

现呼吸困难”则需要按分句重新判断。命中后，系统创建包含危险信号、规则名称、风险等级和就医时效的分诊结果，直接进入回答编排，不执行普通检索路径。

高风险快速通道的设计重点是顺序和终态。它先输出安全筛查开始与完成事件，再输出分诊节点和回答节点事件，最后以 `escalated` 阶段结束。该路径不依赖向量索引和模型抽取，因此即使知识索引或聊天模型暂时不可用，确定性危险信号仍能触发快速提示。快速通道的规则覆盖范围需要在系统文档中明确，不能被表述为对所有急症的完整识别。

3.3.3 症状抽取与信息充分性判断

未命中危险信号时，抽取节点调用聊天模型，要求其只返回症状、持续时间、严重程度和既往史等 `JSON` 字段。系统对模型返回内容做边界解析和字段归一化，并重新使用规则匹配器生成 `red_flags` 字段，以避免模型遗漏安全信号时完全依赖生成结果。

信息充分性判断由独立规则完成。没有症状时需要询问主要不适；只有一个症状且缺少持续时间或严重程度时，需要补充这些信息；症状数量达到要求，或一个症状同时具有持续时间或严重程度时，才进入检索。追问节点返回问题和 `missing` 字段，`missing` 可以是 `symptoms`、`duration`、`severity` 或 `more_symptoms`。追问等待状态不是错误，也不是低风险结论，而是本轮信息收集尚未完成。

3.3.4 RAG 检索与证据分诊

检索查询由原始输入和结构化症状拼接形成。检索器先通过同义词扩展查询，再调用嵌入模型生成向量，在 `FAISS` 索引中获取较宽的候选集合。面向医学问答的研究提出了结合领域知识与检索证据的实现路径[17]；本系统据此对每个候选分片计算向量分数和字符二元组词法重合度，并按固定权重得到综合分。低于阈值的候选被过滤，剩余结果按综合分排序后保留 `Top-K`。

每条证据以 `RankedEvidence` 模型返回，并携带能够定位来源、分片、科室、分数、索引版本和审核状态的元数据。分诊结果的科室枚举包括呼吸内科、消化内科、心血管内科、皮肤科、神经内科、急诊科和全科/建议线下分诊台，其中普通证据投票当前只使用呼吸内科、消化内科、心血管内科和皮肤科。证据按所属科室累计分数，最高科室获得推荐；若没有有效证据，则返回全科/建议线下分诊台并将 `abstained` 设为真。

3.3.5 回答编排与事件终态

回答编排节点采用失败关闭的确定性渲染方式，只读取经过 Pydantic 校验的科室、风险等级和就医时效字段，生成用户可读的辅助分诊说明。自由生成文本不会作为最终回答进入业务记录。证据还需通过审核状态、HTTPS 来源、发布日期、版本、许可信息和受限内容检查，符合条件后才进入引用快照。事件发送器将回答拆分为 `answer_delta` 事件，使前端能够逐步显示内容；完整回答仍在 `compose` 完成事件和 `done` 终态中保存。

正常流程的终态为 `completed`，追问流程的终态为 `completed` 但带有 `followup` 数据，危险信号流程的终态阶段为 `escalated`。节点异常、超时、取消或容量不足时输出 `error` 事件，后端不保存为成功回答。事件序列、Trace ID 和 session ID 共同构成一次执行的外部可观察标识。

3.4 系统数据库设计

3.4.1 数据库设计原则

数据库设计遵循身份与业务分离、原始结果与复核结果分离、知识元数据与向量文件分离、治理证据独立留存四项原则。用户和角色表保存身份基础信息；会话、消息、记录和 Trace 保存咨询过程；健康档案和复诊任务保存用户授权后的持续信息；知识文档表保存文档生命周期状态；临床复核和治理表保存人工决定及变更证据，如图 3-3 所示。




图 3-3 数据库 E-R 图

系统使用 Flyway 按版本执行数据库迁移，并将账户、会话、问诊、知识、复核和治理等数据按业务边界分开管理。基础迁移先建立核心业务实体，



后续迁移再补充消息、知识文档、医院身份关系、临床复核与治理证据，相关内容如表 3-4 所示。

表 3-4 问诊记录表(consultation_records)

字段	类型	长度	约束	备注
id	BIGINT	—	主键、自增	记录编号
user_id	BIGINT	—	非空	用户编号
session_id	VARCHAR	64	非空	会话编号
trace_id	VARCHAR	36	唯一	执行轨迹
symptoms	LONGTEXT	—	可空	结构化症状
department	VARCHAR	64	可空	推荐科室
risk_level	VARCHAR	16	可空	风险等级
answer	LONGTEXT	—	可空	系统建议
total_duration_ms	BIGINT	—	非空	总耗时

3.4.2 用户、会话与问诊记录

用户、会话和消息分别承担身份管理、对话组织与过程关联职责。用户实体保存账户状态、角色及必要的身份上下文；会话实体维护用户归属和活跃时间；消息实体按用户或助手角色保存对话内容，并与执行轨迹关联。这样的分层既支持会话所有权校验，也为历史消息回放提供稳定入口。

consultation_records 是一次咨询完成后的业务快照，关联用户、患者上下文、会话和执行轨迹，同时保存结构化症状、分诊结论、解释、回答、引用以及对话上下文。Trace 标识设置唯一约束，避免同一执行轨迹生成重复主记录；需要保持结构的内容由后端统一序列化和解析。

3.4.3 Trace 与审计数据

consultation_traces 以 trace_id 为唯一键，保存一次咨询的事件序列、引用快照、终态、追问标记、失败原因和耗时等过程信息。它用于还原节点执行顺序并区分完成、升级和失败等结果。audit_logs 则面向受保护接口记录操作者、角色、动作、响应状态和耗时，为权限审计与异常定位提供依据，相关内容如表 3-5 所示。

表 3-5 Trace 表(consultation_traces)

字段	类型	长度	约束	备注
trace_id	VARCHAR	36	唯一、非空	轨迹编号
session_id	VARCHAR	36	非空	会话编号
events_json	LONGTEXT	—	非空	事件序列
citations_json	LONGTEXT	—	非空	引用快照
terminal_phase	VARCHAR	32	非空	终态阶段
followup_pending	BOOLEAN	—	非空	是否追问



字段	类型	长度	约束	备注
failure_code	VARCHAR	64	可空	失败代码

3.4.4 健康档案、复诊与医疗关系

健康档案与复诊任务分别保存经用户授权的背景信息和后续提醒，并通过问诊记录建立关联。面向医院扩展的患者、就诊和医疗关系实体用于表达组织、院区、科室及责任医生边界；紧急授权则单独保存目的、理由、有效期和撤销记录。这样可以把背景资料、业务任务和临床访问关系分开管理，相关内容如表 3-6 所示。

表 3-6 健康档案表(health_profiles)

字段	类型	长度	约束	备注
id	BIGINT	—	主键、自增	档案编号
user_id	BIGINT	—	唯一、非空	用户编号
profile_json	LONGTEXT	—	非空	档案内容
consent_granted	BOOLEAN	—	非空	授权标识
updated_at	TIMESTAMP	—	非空	更新时间

3.4.5 知识文档与治理数据

knowledge_documents 聚焦知识文档的来源、适用科室、版本、许可、摘要、解析、向量化和审核生命周期，不直接保存 FAISS 向量本体。向量文件与分片元数据由 AI 服务的索引目录管理，检索证据记录所使用的索引版本，相关内容如表 3-7 所示。

表 3-7 知识文档表(knowledge_documents)

字段	类型	长度	约束	备注
doc_id	VARCHAR	128	主键	文档编号
title	VARCHAR	512	非空	标题
department	VARCHAR	32	非空	所属科室
institution	VARCHAR	256	非空	机构
url	VARCHAR	2048	非空	来源链接
checksum	VARCHAR	64	非空	内容摘要
parsing_status	VARCHAR	32	非空	解析状态
review_status	VARCHAR	16	非空	审核状态

治理数据按照模型发布、临床评测、知识来源、变更审批、红队测试、回滚演练、运行监测和安全事件等业务聚合分别保存。各聚合承担版本追踪、验证、审批或事件处置职责，避免在同一记录中混合模型状态与治理结论。

3.5 系统权限与安全设计

3.5.1 认证与会话安全

系统采用无状态 JWT 认证，后端通过 JwtAuthFilter 解析 Cookie 中的令牌，并结合 token_version 支持令牌失效。登录和 CSRF 接口公开，其他业务接口默认需要认证。CSRF 令牌由 CookieCsrfTokenRepository 生成，Cookie 设置 Strict SameSite 属性；生产环境的 cookie 安全属性、JWT 密钥和服务令牌由环境变量提供。

3.5.2 角色授权矩阵

权限设计按“资源—动作—角色”划分。患者资源按患者身份边界隔离；临床记录还需要与组织、院区、科室和医疗关系匹配。DOCTOR 与 REVIEWER 可访问临床复核；KNOWLEDGE_EDITOR 可提交知识和模型相关证据；ADMIN 拥有用户、治理执行、模型冻结和回滚等高风险操作权限；AUDITOR 只读监控和审计资源。前端路由元数据用于页面导航，后端 SecurityConfig 是最终授权依据。

3.5.3 数据加密与敏感访问

DataEncryptionService 使用 AES-256-GCM 对需要保护的医疗数据执行加密转换，密钥通过环境变量注入。健康档案、问诊记录、附件和患者身份关联信息按不同业务边界访问，接口不返回超出调用者角色和医疗关系范围的数据。break-glass 访问只允许医生发起，必须记录患者、组织范围、目的、理由、起止时间和撤销信息，并通过审计日志形成可追溯记录。

3.5.4 知识与模型治理闸门

知识来源进入系统后，先保存来源登记和 checksum，再经历解析、向量化和人工审核；只有审核通过且索引激活后才能参与普通检索。医疗 RAG 系统综述指出，数据集、检索方法、评价框架和伦理要求尚未形成统一标准[22]。多源证据组织研究也提示，来源之间的关系需要在检索和审核阶段显式保存[19]。因此，模型发布记录权重摘要、签名、提示词版本、嵌入版本和知识索引版本，审批、冻结和回滚由不同权限角色执行。

3.6 Trace 监控、知识治理与复核流程设计

3.6.1 Trace 事件模型

每条事件都遵循统一协议，事件类型分别表达节点执行、回答增量、正常终止和流程错误。事件同时携带本轮会话的阶段状态及结构化业务结果，使前



端能够渐进式展示，后端能够按序校验并保存完整轨迹。

事件模型的关键设计是顺序验证。前端可以按事件到达顺序渲染，但后端必须检查序号连续性、节点状态和终态一致性。若 `compose` 节点完成但没有 `done` 事件，或 `error` 事件之后仍出现 `completed` 终态，后端应将 `Trace` 标记为失败，不保存为正常问诊记录。该设计把流式传输的不确定性转化为可审计的状态机。

3.6.2 知识生命周期

知识生命周期分为登记、入库、解析、向量化、审核、索引构建、激活和退役。登记阶段保存来源机构、标题、URL、发布日期、版本和 `checksum`；解析阶段记录解析状态和错误；向量化阶段记录 `vector_status` 和 `chunk_count`；审核阶段由具有相应权限的人员提交决定；激活阶段生成新的索引版本并切换活动标记。检索结果携带 `index_version`，确保后续能够还原回答所使用的知识环境。

3.6.3 医生复核闸门

`clinical_reviews` 与 `consultation_records` 一对一关联，既保留 AI 原始建议及其 `Trace` 标识，也保存领取、复核、最终决定、理由和处理时间。临床决策支持 workflow 评估表明，分诊、转诊和诊断任务需要分别考察流程表现[11]；因此，AI 原始结果在复核过程中保持不变，医生决定作为独立结果写入复核聚合，队列状态和领取动作采用并发控制，避免同一任务被重复处理。

表 3-8 临床复核表(`clinical_reviews`)

字段	类型	长度	约束	备注
<code>review_id</code>	VARCHAR	36	唯一、非空	复核编号
<code>consultation_record_id</code>	BIGINT	—	唯一、非空	问诊记录
<code>status</code>	VARCHAR	32	非空	复核状态
<code>decision</code>	VARCHAR	16	可空	复核决定
<code>reviewer_user_id</code>	BIGINT	可空	复核人员	处理人
<code>final_department</code>	VARCHAR	128	可空	最终科室
<code>final_risk_level</code>	VARCHAR	32	可空	最终风险
<code>decision_reason</code>	LONGTEXT	—	可空	决定理由

3.6.4 监控与审计闭环

监控模块从 `Trace` 中计算节点数量、耗时、失败和终态分布，健康接口则显示模型、索引、共享状态和治理组件的可用性。审计拦截器记录受保护接口的动作、角色、状态和耗时，导出接口提供审计证据的离线分析。监控发现异常

后，可通过治理模块创建安全事件、登记纠正措施和关联证据；这使运行监控、变更审批和安全事件处置形成连续链路，相关内容如表 3-9 所示。

表 3-9 审计日志表(audit_logs)

字段	类型	长度	约束	备注
event_id	VARCHAR	36	唯一、非空	审计事件
actor_username	VARCHAR	64	可空	操作者
actor_role	VARCHAR	32	可空	操作者角色
method	VARCHAR	16	非空	HTTP 方法
action	VARCHAR	160	非空	动作
status	INT	—	非空	响应状态
success	BOOLEAN	—	非空	是否成功
duration_ms	BIGINT	—	非空	耗时

3.7 本章小结

表 3-10 角色权限矩阵

资源	USER	DOCTOR	REVIEWER	KNOWLEDGE_EDITOR	ADMIN/AUDITOR
个人问诊记录	本人读写	按关系读取	按任务读取	无	按审计权限
临床复核	无	读写	读写	无	管理员查看
知识文档	无	读取	审核	入库	管理/审计
模型治理	无	审核	审核	提交	执行/查看
审计日志	无	无	无	无	ADMIN/AUDITOR 读

本章完成了 MedPilot 的总体设计。系统采用前端、业务后端和 AI 服务分层，将用户咨询、知识维护、临床复核、监控审计和治理管理划分为相互关联但权限独立的模块。多智能体流程以安全筛查为前置，以信息充分性决定追问或检索路径，以 RAG 证据支撑辅助分诊，并通过 NDJSON 和 Trace 记录全过程。数据库设计将用户、会话、记录、Trace、健康档案、知识文档、复核和治理证据分开保存；权限设计则结合角色、组织范围、院区、科室和医疗关系。第 4 章将围绕这些模块展开详细实现和页面功能说明。

4 系统详细设计与实现

4.1 用户认证与角色权限模块

4.1.1 登录认证实现

用户登录由后端`AuthController`提供接口。登录请求经过参数校验后，系统



根据用户名查询用户，使用 BCrypt 校验密码，确认账户处于启用状态后生成 JWT。JWT 通过 HttpOnly Cookie 返回浏览器，前端只保存登录状态，不保存 AI 服务令牌。当前用户信息由 `/api/auth/me` 返回，退出登录时通过令牌版本和 Cookie 清理使当前会话失效。

认证过滤器 `JwtAuthFilter` 在业务请求进入控制器之前解析 JWT，提取用户名和角色并创建 Spring Security 认证对象。后端不相信前端路由提供的角色字段，所有资源访问仍需要经过服务端授权规则。若令牌缺失、签名无效、账户不存在或账户已失效，请求直接返回未认证状态。

4.1.2 CSRF 与内部服务令牌

系统使用 Cookie 方式传递 JWT，因此需要额外防范跨站请求伪造。后端通过 `CookieCsrfTokenRepository` 生成 CSRF 令牌，并将 Cookie 设置为 Strict SameSite；前端在写请求中带回对应令牌。AI 服务令牌只用于 Spring Boot 与 FastAPI 之间的内部调用，前端代码和浏览器请求中不出现该令牌。

4.1.3 角色授权实现

`SecurityConfig` 按路径和 HTTP 方法配置角色边界。临床复核接口由 DOCTOR 和 REVIEWER 访问；知识文档上传、入库和版本构建由 ADMIN 或 KNOWLEDGE_EDITOR 操作；知识审核、模型评测审核和模型回滚需要 ADMIN、REVIEWER 或 DOCTOR；模型冻结和治理变更执行限制为 ADMIN。审计和监控读取分别开放给 ADMIN、AUDITOR 及规定的复核角色。

前端路由元数据同步声明页面角色。患者端问诊、记录、健康档案和设置页面只要求已登录；知识库页面要求 ADMIN、KNOWLEDGE_EDITOR、REVIEWER 或 DOCTOR；临床复核页面要求 REVIEWER 或 DOCTOR；监控和审计页面要求 ADMIN 或 AUDITOR。路由守卫只负责改善用户体验，不能替代后端授权。

为使权限控制规则与页面角色划分能够相互核对，程序清单 4-1 截取了知识库、监控和审计资源的服务端授权配置。

程序清单 4-1 关键资源角色授权规则

```
.requestMatchers(HttpMethod.POST,
    "/api/knowledge/ingest",
    "/api/knowledge/upload",
    "/api/knowledge/versions/build")
    .hasAnyRole("ADMIN", "KNOWLEDGE_EDITOR")
.requestMatchers(HttpMethod.DELETE, "/api/knowledge/**")
    .hasAnyRole("ADMIN", "KNOWLEDGE_EDITOR")
.requestMatchers(HttpMethod.GET, "/api/knowledge/**")
    .hasAnyRole("ADMIN", "KNOWLEDGE_EDITOR",
"REVIEWER", "DOCTOR", "AUDITOR")
    .hasAnyRole("ADMIN", "AUDITOR")
.requestMatchers("/api/audit/**")
    .hasAnyRole("ADMIN", "AUDITOR")
.requestMatchers("/api/knowledge/**", "/api/monitor/**",
"/api/dashboard/**")
    .hasRole("ADMIN")
.anyRequest().authenticated()
```

代码按 HTTP 方法和资源路径区分写入、读取与审计权限，所有未单独放行的请求仍要求完成认证。对应的用户权限管理页面如图 4-1 所示。

ACCESS CONTROL

用户权限

按职责分离访问知识库、监控和审计数据；敏感操作由服务端再次校验。

创建用户

刷新

账号总数

7

已启用

7

当前操作者

admin

ROLE MATRIX

账号与职责

不会展示密码、令牌或问诊正文

账号	职责	状态	创建时间	安全提示	操作
admin	系统管理员	已启用	2026/07/27 20:38	当前会话	编辑 删除
user	患者用户	已启用	2026/07/27 20:38	患者用户	编辑 删除
editor	知识编辑	已启用	2026/08/10 14:06	知识编辑	编辑 删除
reviewer	医学审核员	已启用	2026/08/10 14:06	医学审核员	编辑 删除
doctor	医生顾问	已启用	2026/08/10 14:06	医生顾问	编辑 删除
auditor	审计员	已启用	2026/08/10 14:06	审计员	编辑 删除

图 4-1 用户权限管理页面

图 4-1 集中展示系统管理员、患者用户、知识编辑、医学审核员、医生顾问和审计员等角色账号，便于管理员核对账号状态与职责分配；具体访问是否允许仍由后端授权规则进行最终校验。

4.1.4 医疗数据加密实现

‘DataEncryptionService’使用 AES-256-GCM 保护敏感字符串和附件流。系统要求活动密钥解码后长度为 32 字节，每次加密生成 12 字节随机 Nonce，并使用 128 位认证标签验证密文完整性。字符串密文增加‘enc:v1’前缀和密钥标识，附件流使用独立文件前缀保存密钥标识和 Nonce。

服务支持由多个‘id=base64’条目组成的密钥环，写入时使用活动密钥，读取时根据密文中的密钥标识选择旧密钥或新密钥，从而支持不中断读取的密钥轮换。JPA 属性转换器在写入数据库时自动加密，在实体读取时自动解密；未知密钥、认证失败或密文过短均抛出数据加密异常，不返回未经验证的明文。

4.2 智能问诊核心模块

4.2.1 危险信号筛查实现

危险信号筛查位于 AI 服务 run_consult_stream 的最前端。match_danger_signs 首先将用户输入按标点、换行和转折词切分为语句片段，再匹配规范危险信号和同义词。当前同义词包括“气短”对应呼吸困难、“黑便”对应便血、“昏倒”对应晕厥，以及“咳血”“咳出血”对应咯血。急诊分诊研究强调时间敏感性，危险表现需要优先处理[2]；因此，规则还结合句子边界和否定词判断某个表现是“出现”还是“被否认”，命中后直接生成包含危险信号、规则名称、风险等级和就医时效的分诊结果，不执行普通检索路径。

筛查器使用否定表达式判断某个信号是否被否认，并在“和、及、以及、或、也、并”等连接词下继承前一危险信号的否定状态。这样可以区分“没有胸痛，也没有呼吸困难”和“没有胸痛，但出现呼吸困难”。筛查结果被转换为‘SafetyScreenResult’，用于承载是否命中、命中项、风险路径和规则标识。

命中危险信号时，系统调用‘classify’的高风险规则，生成风险等级为“高”的‘TriageResult’。随后流式输出安全筛查、辅助分诊、回答编排和 done 事件，回答内容由确定性模板组成，包括检测到的危险信号、规则名称和就医时效。该路径不调用普通抽取、向量检索和自由回答生成，因而减少了模型或索引异常对高风险提示的影响。

危险信号处理的关键在于区分用户确认出现的症状与明确否认的症状，程序清单 4-2 给出了否定感知匹配逻辑。



```
def match_danger_signs(text: str) -> tuple[str, ...]:  
    """Return canonical danger signs that are asserted, not explicitly negated."""  
    asserted: set[str] = set()  
    for clause in _CLAUSE_BOUNDARY.split(text):  
        previous_end = 0  
        previous_negated = False  
        for start, end, canonical in _clause_matches(clause):  
            prefix = clause[:start]  
            connector = clause[previous_end:start]  
            directly_negated = _TARGETED_NEGATION.search(prefix) is not  
None  
            inherited_negation = (  
                previous_negated  
                and _COORDINATING_TEXT.fullmatch(connector) is not None  
            )  
            negated = directly_negated or inherited_negation  
            if not negated:  
                asserted.add(canonical)
```

匹配器在每个语句片段内计算直接否定和连接词继承否定，仅将未被否定的规范危险信号加入结果集合。高风险规则的运行结果如图 4-2 所示。

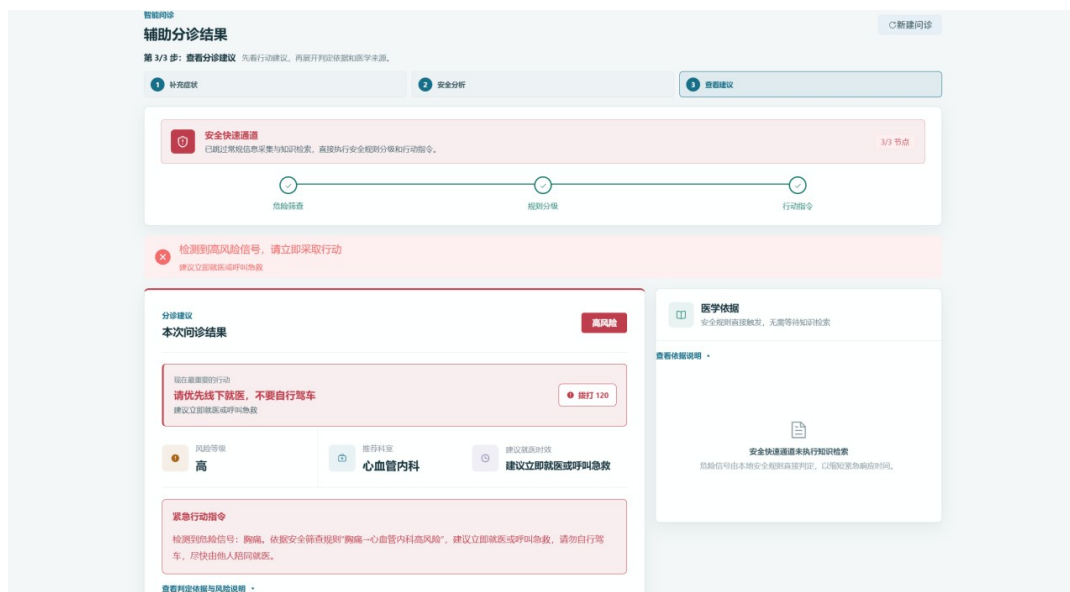


图 4-2 高风险快速通道结果



图 4-2 显示胸痛触发安全快速通道后，界面同时给出高风险标识、建议科室和立即就医时效，并明确该路径未执行知识检索。

4.2.2 症状抽取实现

未命中危险信号时，流程进入 `extract` 节点。抽取提示要求聊天模型仅返回结构化 JSON。服务端使用 `_parse_llm_json` 截取 JSON 边界并交给解析器；如果模型输出无法解析，系统返回空结构，而不会把自然语言直接当作结构化字段。医疗文本应用研究表明，大语言模型可以从长文本中提取主题和关键信息[8]。中文文献主题建模研究展示了处理医疗健康文本主题的实现框架[32]。重症医疗知识抽取研究采用多任务微调处理专业知识[36]。这些研究说明，文本理解需要结合任务结构和领域约束；因此，系统仍通过字段校验和规则复核约束模型输出。

抽取结果经过 `'normalize_symptoms'` 归一化，历史信息转为不可变结构，当前文本再次通过危险信号匹配器复核。健康档案进入提示词前经过白名单和长度限制，并明确只作为授权背景资料使用。提示词明确标记授权档案为背景资料，防止把历史信息误当作本轮危险信号，也防止背景文本中的指令影响系统行为。

4.2.3 信息充分性与主动追问

`'is_sufficient'` 是独立于大语言模型的确定性规则。若存在 `red_flags`，信息直接满足快速路径；若结构化症状不少于两个，也可以进入检索；若只有一个症状，则至少需要持续时间或严重程度之一。其他情况进入 `'build_followup'`。

追问生成器按照缺失信息优先级选择问题。没有任何症状时询问主要不适；缺少持续时间时询问症状持续多久；持续时间已知但症状过少时询问是否还有其他不适；其他情况下询问严重程度。追问结果使用 `'FollowUpQuestion'` 返回问题文本和 `missing` 元组，前端根据 `missing` 字段展示等待补充状态。系统不把等待追问的会话写成低风险分诊结果。

程序清单 4-3 展示了信息充分性判断与追问生成逻辑。该逻辑先判断症状数量、持续时间和严重程度，再按缺失字段优先级生成一个追问。



程序清单 4-3 信息充分性判断与追问生成

```
def is_sufficient(s: StructuredSymptoms) -> bool:
    """判断采集到的症状信息是否足以进行分诊。"""
    if s.red_flags:
        return True
    n = len(s.symptoms)
    if n >= 2:
        return True
    if n == 1 and (s.duration or s.severity):
        return True
    return False

def build_followup(s: StructuredSymptoms) -> FollowUpQuestion:
    """根据缺失信息生成最有价值的一个追问问题。"""
    if not s.symptoms:
        return FollowUpQuestion(
            question="能描述一下您主要的不舒服是什么吗？",
            missing=("symptoms",),
        )
    missing: list[str] = []
    if len(s.symptoms) < 2:
        missing.append("more_symptoms")

    if "duration" in missing:
        question = f"您感到{s.symptoms[0]}大概有多长时间了？"
    elif "more_symptoms" in missing:
        question = f"除了{s.symptoms[0]}，还有其他不舒服的地方吗？"
    else:
        question = f"您的{s.symptoms[0]}程度如何？是轻微、中等还是严重？"
    return FollowUpQuestion(question=question, missing=tuple(missing))
```

主动追问在运行界面中的交互状态如图 4-3 所示。




图 4-3 主动追问交互页面

图 4-3 中，用户仅输入咳嗽后，系统询问症状持续时间，知识检索和辅助分诊节点保持等待，避免在信息不足时提前输出科室结论。

4.2.4 检索增强与科室判断

信息充分后，`_retrieve_node` 将原始文本和结构化症状连接为检索查询。检索器先调用 `expand_query_with_aliases` 扩展医学同义表达，再通过 `bge-m3` 生成向量并执行 FAISS 归一化内积检索。候选集合大小为 `Top-K` 的四倍，系统对候选分片计算字符二元组词法重合度，并按 0.8 的向量分数和 0.2 的词法分数得到综合分。检索增强研究指出，候选重排和证据组织会影响医学问答质量 [16]；因此，系统保留通过审核的证据、来源文档和索引版本，并在后续按科室分数加权。

低于 `'MEDPILOT_RAG_MIN_SCORE'` 的结果被丢弃，剩余证据按综合分排序后截取 `Top-K`。每条结果构造为 `'RankedEvidence'`，并保存可定位来源、科室、证据原文、分数、索引版本及审核状态的元数据。

`'classify'` 首先再次检查高风险规则，然后过滤出呼吸内科、消化内科、心血管内科和皮肤科证据。证据按科室累加分数，最高科室作为推荐科室，并根据最高科室占总分比例计算支持分和置信度。若没有有效证据，系统输出全科/建议线下分诊台，风险等级为低，`abstained` 为真，解释文本提示补充信息或线下分诊。

为兼顾医学语义相近和短中文症状的字面命中，检索器采用向量分数与词法重合度融合排序，核心实现如程序清单 4-4 所示。



程序清单 4-4 向量与词法融合检索

```
k = min(max(top_k * 4, top_k), len(chunks))
scores, ids = index.search(vec, k)

candidates: list[tuple[float, float, int]] = []
for score, idx in zip(scores[0], ids[0]):
    if idx < 0:
        continue
    dense_score = float(score)
    lexical_score = _lexical_overlap(retrieval_query, chunks[idx].text)
    combined_score = 0.8 * dense_score + 0.2 * lexical_score
    if combined_score < min_score:
        continue
    candidates.append((combined_score, dense_score, int(idx)))

results: list[RankedEvidence] = []
for combined_score, _dense_score, idx in sorted(
    candidates, key=lambda item: (-item[0], item[2])
)[:top_k]:
    c = chunks[idx]
    results.append(RankedEvidence(
        citation_id=c.chunk_id,
        doc_id=c.doc_id,
        chunk_id=c.chunk_id,
        department=c.department,
        source=c.source,
        source_type=c.source_type,
        quote=c.text,
        score=round(float(combined_score), 4),
        index_version=index_version,
        institution=c.institution,
        title=c.title,
```

检索器先扩大向量候选池，再按 0.8 和 0.2 的权重融合向量分数与词法分数，并在阈值过滤后返回 Top-K 证据。对应结果页面如图 4-4 所示。




图 4-4 检索证据支持的辅助分诊结果

图 4-4 同时展示呼吸内科建议、风险等级、就医时效与三条医学来源，体现候选证据既参与科室评分，也作为用户查看判定依据的入口。

4.2.5 确定性回答编排

当前实现的 `compose` 函数不会把聊天模型自由生成的回答直接写入系统。它先通过 `_is_trusted_evidence` 检查证据的科室、审核状态、HTTPS URL、机构、题名、发布日期、版本和许可字段，并过滤包含确诊、处方、剂量、用药等受限内容的证据。Almanac 工作强调，临床回答需要以可追溯的外部证据为基础[23]；因此，系统仅对通过治理检查的引用进行渲染，证据不足时返回低证据提示和人工复核入口。

通过校验的 `'TriageResult'` 由 `'_render_answer'` 确定性渲染，输出推荐科室、风险等级、就医时效和执业医师复核提示。科室、风险和就医时效不在允许枚举范围内时，渲染器使用安全回退值。最终结果同时携带安全边界声明，明确系统提供辅助分诊建议，不替代医生诊断和治疗。该设计牺牲部分自然语言灵活性，换取输出字段可控和失败关闭。

4.2.6 NDJSON 流式返回

AI 服务使用 `'EventEmitter'` 为每个会话生成 Trace ID 和序列号。普通流程先发送 `'safety_screen'` 事件，再发送 `extract`、`ask_followup` 或 `retrieve`、`classify`、`compose` 节点事件；回答内容拆分为 `answer_delta` 事件，最后发送 `done`。节点异常会产生 `error` 事件，超时由服务层转换为带有 `inference_timeout` 代码的终态错误。



业务后端的`ConsultController`通过 WebClient 打开 AI 服务流，并以 Reactor Flux 逐行处理。每行事件先交给`ConsultationEventAccumulator`解析和校验，再发布到`LiveTraceRegistry`供监控页面订阅。后端只在 done 事件存在、累计器未标记终态错误且记录条件满足时调用持久化服务；流提前结束则生成 INCOMPLETE_STREAM 错误。

程序清单 4-5 给出了统一事件封装逻辑。事件发射器为每条事件写入协议版本、Trace、会话、递增序号、阶段状态和节点数据，使前端进度展示与后端持久化使用同一事件依据。

程序清单 4-5 NDJSON 事件封装与递增序号

```
def emit(
    self,
    event_type: EventType | str,
    *,
    phase: ConsultPhase,
    status: str,
    node: str | None = None,
    label: str | None = None,
    data: dict | None = None,
) -> dict:
    if event_type not in {"node", "answer_delta", "error", "done"}:
        raise ValueError(f"unsupported event type: {event_type}")
    if event_type == "answer_delta":
        if status != "streaming" or phase != "composing":
            raise ValueError("answer_delta must be a composing stream event")
        data = AnswerDeltaData.model_validate(data or {}).model_dump()
    self._sequence += 1
    event = {
        "protocol_version": "1.0",
        "trace_id": self.trace_id,
        "session_id": self.session_id,
        "sequence": self._sequence,
        "type": event_type,
```

基于该事件序列，前端能够把多智能体协同过程转换为连续的节点进度，运行状态如图 4-5 所示。




图 4-5 多智能体协同分析过程

图 4-5 将安全筛查、信息采集、知识检索、辅助分诊和建议生成依次呈现，并同步显示当前完成比例与会话内容，便于用户理解系统仍处于分析过程。

4.3 问诊记录与健康档案模块

4.3.1 会话历史与消息持久化

问诊开始时，后端通过 `SessionOwnershipService` 校验并认领会话，防止不同用户交叉使用同一会话。系统先保存本轮用户消息，再按用户与会话读取历史上下文；AI 服务返回回答或追问后，后端追加助手消息。历史内容按用户和助手角色保存，并可在后续轮次采用完整历史或摘要上下文。

4.3.2 记录与 Trace 幂等持久化

`ConsultationPersistenceService` 使用事务保存 Trace、事件和问诊结果，并在写入前检查执行轨迹是否已经存在，以保证重复提交不会生成重复记录。只有在终态明确且业务结果完整时，系统才保存科室、风险、置信度、支持度、解释、回答、引用和对话上下文。

问诊记录保存成功后，如果临床复核模块已启用且记录尚无复核聚合，系统在同一事务中创建 `ClinicalReview`。AI 原始结果在复核流程中保持不变，医生最终决定写入独立字段。这样既能让用户查看 AI 原始建议，也能在后续复核完成后展示最终科室、风险等级和就医时效。

4.3.3 健康档案与复诊任务

`HealthProfileController` 提供档案查询、更新和删除接口。更新时，系统将

用户授权的过敏史、既往情况、用药信息和备注保存为受控背景上下文，并记录是否同意将其用于问诊。读取操作始终依据当前认证身份执行，不能通过请求参数访问其他用户的档案。

复诊任务由 `FollowUpTask` 与问诊记录关联，系统提供任务列表、单条任务查询、完成和更新状态等操作。到期任务按照当前用户和开放状态筛选，避免把其他用户的提醒混入当前列表。

4.3.4 记录详情页面

`RecordDetailView.vue` 将一条记录拆分为分诊概览、症状摘要、判定依据、系统建议、会话内容、记录信息和依据与参考几个区域。页面同时展示 AI 推荐科室、AI 风险、支持度和就医时效；如果复核字段存在，则单独显示医生最终科室、风险和时效。引用区域展示来源、科室、证据原文、`chunk_id` 和 `index_version`，Trace ID 则位于记录元数据中。

记录详情页面根据 `reviewStatus` 显示等待复核、医生确认、医生调整、急诊人工流程或系统接管等状态。高风险记录额外显示紧急提示。页面文案把 AI 结果称为辅助分诊概览，并将医生决定与 AI 原始输出分开留存，避免用户误以为系统已完成临床诊断。

问诊记录详情不仅保存最终文本，还把风险等级、就医时效、检索支持度和证据关系进行可视化，具体页面如图 4-6 所示。



图 4-6 问诊记录的风险与证据链可视化

图 4-6 把症状节点、检索依据与科室、风险和时效结论连接起来, 同时在支持度区域标注该数值不代表临床诊断结论, 从展示层面保留辅助分诊边界。

4.4 医学知识库与 RAG 模块

4.4.1 文档入库

知识库入库支持结构化文本和文件上传两种方式。上传时系统校验科室、机构、题名、来源链接、发布日期、版本和许可等必要信息, 并根据文件类型执行文本解析; 同时限制文件大小、计算 SHA-256 摘要并保留来源信息。PDF 文本由 PDFBox 提取, 解析失败时保留失败状态和原因。

业务层在转发给 AI 服务前执行 `sanitizeIngestPayload`, 移除客户端不应提交的审核信息, 强制新文档进入待审核状态, 并重新计算摘要以防止元数据被篡改。文档元数据保存于 MySQL, 切片和向量化结果由 AI 服务管理。

知识文档进入 AI 服务前, 业务后端会清洗审核字段并重新计算摘要, 关键实现如程序清单 4-6 所示。



```
static Map<String, Object> sanitizeIngestPayload(Map<String, ?> body) {  
    Map<String, Object> sanitized = new LinkedHashMap<>();  
    if (body != null) sanitized.putAll(body);  
    sanitized.remove("reviewer");  
    sanitized.remove("reviewed_at");  
    sanitized.remove("checksum");  
    sanitized.put("review_status", "pending");  
    Object text = sanitized.get("text");  
    if (text != null) sanitized.put("checksum", sha256(text.toString()));  
    return sanitized;  
}
```

该处理移除客户端提交的审核人、审核时间和摘要，强制新文档进入 pending 状态，从入口处防止前端伪造审核结果或内容校验值。

4.4.2 审核与版本构建

文档通过审核后，审核接口通过 X-MedPilot-Reviewer 传递当前认证主体，将审核结果同步给 AI 服务，并更新文档的审核人和审核时间。知识版本接口负责构建新的索引版本、切换活动版本和比较版本差异。TRIPOD-LLM 指南要求医疗大语言模型研究交代数据、任务、评价过程和适用边界[30]；本系统将审核结果、索引版本和变更记录作为知识治理证据保存。

检索结果写入索引版本标识，引用快照因此能够保留本次咨询实际使用的知识环境。知识文档的删除、审核、版本切换和索引操作均受角色权限约束；解析状态和向量状态分开记录，避免把“已入库”误认为“可供检索”。

医学知识库页面将文档统计、解析与向量状态、索引版本及激活动作集中展示，运行界面如图 4-7 所示。




图 4-7 医学知识库与索引版本管理页面

图 4-7 能够同时查看知识文档数量、切片数量、科室覆盖、可用索引版本和当前激活状态，使文档审核、版本构建与版本切换形成可核对的管理流程。

4.4.3 前端知识库页面

`KnowledgeView.vue` 提供知识统计、文档列表、版本管理、版本差异和入库表单。入库表单支持文件模式和正文模式，要求填写科室、机构、题名、来源链接、发布日期、版本和许可信息；审核状态由后端审核接口最终控制。页面还提供版本构建、版本激活和文档审核操作，使知识生命周期能够在管理端闭环完成。

4.5 医生复核与治理模块

4.5.1 复核队列

临床复核控制器提供记录详情、领取和决定接口。复核列表按状态和创建时间查询，领取动作使用版本与状态检查，防止多个复核人员同时处理同一任务；领取成功后，任务进入 `IN_REVIEW` 状态并记录处理时间。

4.5.2 复核决定

前端复核表单提供 `CONFIRM`、`MODIFY`、`REJECT` 和 `ESCALATE` 四类决定。`CONFIRM` 保留 AI 原始结果；`MODIFY` 需要提交最终科室、风险等级、就医时效和复核依据；`REJECT` 表示退回人工处理；`ESCALATE` 将任务转入急诊人工流程。复核依据为必填项，决定接口同时记录复核人、员工号、理由和处理时间。



`ClinicalReviewView.vue`在列表中显示待复核数量、状态筛选和原始分诊信息，选中任务后展示 AI 建议与最终决定表单。高风险或急诊升级状态会显示院内流程提示，页面明确 AI 结果只是待复核草案。该设计把复核从“修改一条 AI 记录”变成独立工作流。

4.5.3 模型与知识治理

治理控制器提供模型发布、评测、回滚、知识来源登记、变更审批、红队测试、回滚演练、监控快照和安全事件等入口。模型发布需要记录版本、签名、提示词与嵌入配置、知识索引版本、硬件基线和审批证据；高风险动作由具备相应权限的角色执行。算法偏见研究强调，人工智能决策需要配套偏差治理机制[43]；因此，治理模块把模型发布、评测、回滚和安全事件作为可审计的独立操作。

治理模块采用角色分离。模型和知识证据由管理员或知识编辑人员提交，审核人员或医生复核，冻结、执行和回滚等高风险操作限制为管理员。系统不会因为存在某个模型记录就自动切换模型，模型和知识版本必须经过明确审批并激活。

4.6 监控、审计与异常处理模块

4.6.1 Trace 监控页面

`MonitorView.vue`维护健康状态、历史 Trace、实时 Trace、节点状态和事件列表。页面通过健康接口获取模型服务、知识索引和治理状态，通过 Trace 列表查询历史运行，通过事件流定位当前活动。节点列表展示安全筛查、症状采集、追问、知识检索、辅助分诊和回答编排的状态。

Trace 详情按会话、阶段和轮次展示事件序列，并汇总节点耗时、失败原因、终态和引用数量以辅助定位问题。监控图表只反映已采集的运行样本，不把样本量或耗时直接解释为医疗质量指标。

监控模块先提供系统与 Trace 总览，展示模型服务、活动会话、知识文档、向量索引及链路统计，页面如图 4-8 所示。




图 4-8 智能体运行监控页面

图 4-8 用于定位服务可用性和链路运行状态。选择具体 Trace 后，系统进一步显示事件级调用链路，如图 4-9 所示。





图 4-9 问诊调用链路详情

图 4-9 按事件序列列出安全筛查、症状采集、主动追问和流程完成状态，并保留各事件耗时及输出摘要，便于从单次会话追踪条件路由结果。

4.6.2 审计日志

‘AuditLogInterceptor’ 为受保护 Web 请求记录操作者、角色、HTTP 方法、动作、响应状态、请求标识、地址摘要和耗时，并将成功或失败结果写入审计日志。监控与审计页面分别提供查询和导出口，不同角色只能读取其权限范围内的记录。

审计日志页面支持按操作者和响应状态筛选，并以时间、角色、动作、结果和耗时为主要字段展示访问记录，如图 4-10 所示。



AUDIT TRAIL
审计日志
记录访问边界、变更结果与耗时，不保存请求正文、令牌或医疗文本。

刷新 上脱敏导出

按操作者筛选 响应状态 应用筛选 重置

时间	操作者	角色	动作	结果	耗时
2026/8/27 10:10:44	admin	ROLE_ADMIN	/api/admin/users	200 成功	1 ms
2026/8/27 10:10:44	admin	ROLE_ADMIN	/api/admin/users	201 成功	148 ms
2026/8/27 10:09:39	admin	ROLE_ADMIN	/api/admin/users	200 成功	3 ms
2026/8/27 10:09:12	anonymousUser	ROLE_ANONYMOUS	/api/monitor/health	200 成功	1 ms
2026/8/27 10:09:11	admin	ROLE_ADMIN	/api/monitor/stats	200 成功	13 ms
2026/8/27 10:09:11	admin	ROLE_ADMIN	/api/monitor/traces	200 成功	10 ms
2026/8/27 10:08:50	admin	ROLE_ADMIN	/api/monitor/trace/{id}	200 成功	1 ms
2026/8/27 10:08:50	admin	ROLE_ADMIN	/api/monitor/trace/{id}	200 成功	3 ms
2026/8/27 10:08:49	admin	ROLE_ADMIN	/api/monitor/traces	200 成功	8 ms
2026/8/27 10:08:48	admin	ROLE_ADMIN	/api/monitor/traces	200 成功	10 ms
2026/8/27 10:08:45	admin	ROLE_ADMIN	/api/monitor/traces	200 成功	13 ms
2026/8/27 10:08:44	admin	ROLE_ADMIN	/api/monitor/traces	200 成功	13 ms
2026/8/27 10:08:43	admin	ROLE_ADMIN	/api/monitor/trace/{id}	200 成功	3 ms
2026/8/27 10:08:42	admin	ROLE_ADMIN	/api/monitor/trace/{id}	200 成功	1 ms
2026/8/27 10:08:42	anonymousUser	ROLE_ANONYMOUS	/api/monitor/health	200 成功	1 ms

图 4-10 审计日志查询页面

图 4-10 中的记录覆盖用户管理、监控统计与 Trace 查询等操作；页面只保留访问边界、结果和耗时，不保存请求正文、令牌或医疗文本。

4.6.3 错误与取消处理

后端对 AI 服务异常分为连接失败、HTTP 错误、请求过大、会话冲突、容量超限、推理超时和流不完整等类型。首次事件前的可重试错误使用指数退避进行有限重试；请求参数错误、冲突和超大请求不重复提交。流式过程中如果客户端取消，后端保存取消 Trace 并释放上游连接；如果 AI 服务没有发送 done 事件，累计器生成 INCOMPLETE_STREAM 错误。

异常持久化采用“错误优先返回”原则。若数据库同时不可用，系统不会用持久化失败覆盖原始 AI 错误，而是尽量向客户端返回可操作的错误代码。LiveTraceRegistry 也会收到 failed 或 cancelled 状态，使监控端不会把异常请求留在运行中。



4.7 前端主要页面实现

4.7.1 智能问诊页面

`ConsultView.vue` 提供症状输入、历史消息、健康档案上下文、流式节点状态、追问、分诊结果、引用和安全边界展示。用户提交后，页面先显示安全筛查状态，再根据事件更新症状采集、知识检索、辅助分诊和回答编排节点。追问状态显示缺失信息类别，用户补充内容后继续下一轮；高风险状态使用单独的警示区域显示就医时效。

4.7.2 知识库、复核和监控页面

知识库页面采用列表、统计卡片、版本切换和入库表单组合；复核页面采用左侧队列和右侧决定表单组合；监控页面采用服务状态卡、节点进度、Trace 详情、实时事件和历史列表组合。三类管理页面都根据角色显示操作按钮，后端响应失败时保留错误提示和刷新入口。

4.7.3 响应式与状态反馈

前端页面对加载、空数据、错误、正常完成和风险升级分别设置界面状态。问诊和记录详情在窄屏下将双栏布局改为单栏，引用、Trace ID 和长文本使用换行策略避免溢出。页面中的 AI 推荐、医生最终决定和安全声明使用不同的视觉区域，避免把三者混为一个结果。

4.8 本章小结

本章从代码实现角度说明了 MedPilot 的核心模块。系统通过否定感知的危险信号匹配器实现高风险快速通道，通过本地大语言模型完成结构化症状抽取，通过规则判断信息充分性并生成追问，通过 bge-m3 和 FAISS 完成证据检索，再由确定性渲染器输出辅助分诊说明。业务后端负责 JWT、CSRF、角色授权、会话所有权、事件累积、幂等持久化和异常处理；健康档案、知识库、医生复核、Trace 监控、审计和治理模块则补足了系统的持续使用边界。前端页面将这些状态和证据组织为问诊、记录、知识、复核和监控工作区。第 5 章将对上述功能进行系统测试并分析统计结果。



5 系统测试与分析

5.1 测试环境与测试策略

5.1.1 测试环境

MedPilot 的测试环境由前端、业务后端、AI 服务、数据库、模型服务和向量索引组成。前端运行在 Node.js 环境，业务后端使用 Java 17 和 Spring Boot，AI 服务使用 Python 3.11、FastAPI 和 LangGraph，MySQL 保存用户、问诊、知识和治理数据，Ollama 提供 qwen2.5:7b 聊天模型与 bge-m3 嵌入模型，FAISS 保存医学知识分片索引。测试阶段使用本地部署方式，服务之间通过回环地址通信，避免把测试文本发送到第三方推理平台。

表 5-1 给出主要测试环境配置。

表 5-1 主要测试环境配置

项目	配置
前端	Vue 3、Vite、Node.js、Element Plus
业务后端	Java 17、Spring Boot 3.3.4、JPA、Spring Security
AI 服务	Python 3.11、FastAPI、LangGraph、Pydantic
聊天模型	Ollama / qwen2.5:7b
嵌入模型	Ollama / bge-m3
检索索引	FAISS IndexFlatIP，向量归一化内积
数据库	MySQL 8，Flyway 迁移
流式协议	NDJSON
测试方式	规则测试、检索测试、接口测试、页面流程测试

5.1.2 测试策略

测试策略按照“单节点—业务链路—系统边界”的顺序设计。单节点测试关注危险信号匹配、否定表达、信息充分性、追问生成、科室投票、证据门控和数据加密；业务链路测试关注从登录到问诊、从问诊到记录、从知识入库到索引激活、从 AI 结果到医生复核的完整过程；系统边界测试关注权限、超时、容量、断流、模型不可用和数据库异常。TRIPOD-LLM 报告规范要求明确说明任务、数据和评价过程[29]。TRIPOD-LLM 指南还要求交代研究适用边界和报

告细节[14]。因此本文同时记录测试集构成、固定种子、指标定义和失败样本。

测试输入分为高风险、证据支持、低证据和信息不足四类。测试集由固定种子 20260831 生成并在运行前冻结，逐条记录金标准、扰动等级和预期路径。高风险文本调用生产安全筛查；证据支持与低证据文本调用现有 bge-m3、FAISS 和证据加权分类；信息不足样本调用结构化症状充分性与追问规则。自由文本回答生成不计入分类指标，避免把随机生成质量混入确定性组件评测。

5.1.3 指标定义

危险信号召回率用于衡量已标注危险信号是否被系统识别，计算公式为：该指标只反映规则筛查对测试样本的覆盖情况。医疗大语言模型的人类评价框架指出，安全与伤害应作为独立评价维度[13]；因此，本文将危险信号召回率与否定表达、未登录表达和普通样本误触发情况分开统计。

危险信号召回率 = 正确识别的危险信号样本数 / 危险信号样本总数

科室和风险等级采用 Precision、Recall 和 F1 进行统计。Precision 表示系统输出某标签的样本中有多少与金标准一致，Recall 表示某金标准标签的样本中有多少被系统识别，F1 为二者的调和平均。Macro-F1 先分别计算各标签 F1，再对标签进行算术平均，以避免样本较多的类别完全主导结果。

信息不足样本不纳入科室和风险 F1，而单独统计追问触发率。证据支持样本统计 Recall@3 与 MRR；科室指标分别报告四个受支持科室的 Macro-F1，以及加入全科/线下回退类别后的五分类 Macro-F1。组件耗时从函数实际开始执行到返回结果为止，不包含并发队列、浏览器、业务后端、数据库和网络传输，因此不等同于线上端到端延迟。上述指标只描述当前 Demo 在人工构造工程测试集上的行为，不用于推断临床准确率。

5.2 测试集设计与功能测试

5.2.1 测试集分布

本次固定种子工程测试集共 1000 条，具体分布如表 5-2 所示。

表 5-2 扩展工程测试集分布

测试类别	数量	覆盖内容
高风险危险信号	320	8 类危险信号，每类 40 条；5 级扰动各 64 条
证据支持的中风险	320	4 个受支持科室，每科 80 条；5 级扰动各 64 条
低证据回退	200	10 类知识库外症状；5 级扰动各 40 条
信息不足追问	160	无症状或单症状缺字段；5 级

测试类别	数量	覆盖内容
		扰动各 32 条
合计	1000	固定种子 20260831，逐条保存预测、证据与耗时

高风险样本覆盖胸痛、呼吸困难、气促、咯血、便血、晕厥、意识不清和大出血，每类 40 条。全部样本按 P0 至 P4 划分为规范表达、口语与同义表达、组合与背景干扰、否定与跨症状干扰、错别字与未登录改写五级。证据支持样本围绕心血管内科、呼吸内科、消化内科和皮肤科构造；低证据样本来自当前知识库未覆盖的骨科、耳鼻喉、眼科、口腔、泌尿等症状；信息不足样本只保留空症状或单症状且不提供持续时间和严重程度。

5.2.2 功能测试项目

功能测试覆盖认证、问诊、记录、健康档案、知识库、复核、监控和审计八类模块。测试用例如表 5-3 所示。

表 5-3 核心功能测试用例

编号	测试项目	输入或操作	预期结果
1	用户登录	输入有效用户名和密码	返回 JWT Cookie 并进入授权页面
2	错误登录	输入错误密码	返回未认证结果，不创建有效会话
3	危险信号筛查	提交包含胸痛或呼吸困难的文本	进入高风险快速通道
4	否定表达	提交“没有胸痛，也没有呼吸困难”	不触发危险信号规则
5	信息不足追问	仅提交“有点头晕”	返回追问问题和缺失字段
6	证据检索	提交喘息、咳嗽和运动后加重	返回呼吸内科证据
7	辅助分诊	使用有效证据完成检索	返回科室、风险和支撑因素
8	低证据回退	提交知识库未覆盖的一般不适	返回全科/线下分诊台并暂缓判断
9	记录保存	正常完成 done 事件	保存问诊记录、消息和 Trace
10	断流处理	AI 服务未发送 done 事件	记录 INCOMPLETE_STREAM 错误
11	健康档案	更新并授权过敏史等背景信息	档案保存并按授权传入问诊

编号	测试项目	输入或操作	预期结果
12	医生复核	领取任务并提交决定	保存独立复核结果
13	知识审核	上传文档并审核	文档状态和审核人被记录
14	监控查询	输入 Trace ID	显示节点事件、耗时和终态
15	审计导出	查询并导出审计记录	返回当前角色允许范围内的 CSV

功能测试的判断标准不是页面是否能够点击，而是请求、业务状态、持久化结果和页面反馈是否一致。例如，追问接口返回问题但不应生成低风险记录；高风险快速通道不应等待普通 RAG 检索；医生修改结果后，AI 原始分诊仍然保留。

5.3 多智能体流程测试

5.3.1 安全筛查节点

安全筛查节点在普通模型调用前执行。320 条高风险样本中，P0 至 P3 共 256 条全部命中，P4 的 64 条错别字或未登录改写全部漏检，总体召回率为 80.00%。其余 680 条非高风险样本没有触发危险信号，工程测试特异度为 100.00%。该结果说明否定与转折处理在已登记词形上保持稳定，但规则对词表外语义改写缺少泛化能力，如图 5-1 所示。




图 5-1 不同扰动强度下的任务性能

图 5-1 按扰动等级比较四条测试路径。P0 至 P3 的危险信号召回率均为 100%，P4 下降为 0；证据分诊准确率在 P3 为 92.19%，其余等级为 96.88%；主

动追问始终为 100%，低证据回退始终为 0。不同曲线的分母分别为每级 64、64、32 和 40 条，不能将曲线间的高低直接解释为同一临床能力。

5.3.2 信息充分性与主动追问

信息充分性规则根据症状数量、持续时间和严重程度决定是否进入检索。160 条信息不足样本全部触发追问，触发率为 100.00%。该结果验证的是结构化症状对象上的纯规则行为；本轮没有把 qwen2.5:7b 自由抽取结果并入该指标，因此不能据此声称任意口语输入都能被正确抽取。

追问测试验证了一个工程边界：没有危险信号不等于信息已经充分。空症状对象会询问主要不适；单症状且缺少持续时间和程度时，会优先询问持续时间或其他症状。该分支在固定结构化输入上能够阻止提前分诊，但真实使用效果仍取决于上游症状抽取是否完整。

5.3.3 检索、分诊与回答编排

320 条证据支持样本均返回至少一条索引证据，证据返回率为 100.00%；但 Top-3 中包含预先标注的可接受文档的比例为 71.88%，MRR@3 为 0.6255。这说明“返回了证据”与“返回了目标证据”不是同一指标。检索结果继续按科室分数加权，回答层只渲染结构化分诊字段与通过治理检查的引用，如图 5-2 所示。




图 5-2 科室与回退类别混淆矩阵



图 5-2 给出 320 条受支持科室样本与 200 条低证据样本的五分类混淆矩阵。仅在四个受支持科室内统计时，准确率为 95.94%，Macro-F1 为 0.9585；加入回退类别后，准确率降至 59.04%，Macro-F1 为 0.5861。200 条知识库外症状全部被分配到四个受支持科室，回退类别召回率为 0，说明当前相似度阈值没有形成有效的分布外拒答边界。

回答编排测试验证了失败关闭逻辑。证据不满足审核状态、HTTPS 来源、发布日期、版本或许可信息时，不进入引用列表；分诊字段不在允许枚举范围时，渲染器使用安全回退值。聊天模型输出的自由文本不会覆盖最终分诊字段，因而可以避免模型在回答中自行添加处方、剂量或确定性诊断。

5.4 危险信号与风险分级结果

5.4.1 危险信号统计

图 5-1 的横坐标为五个扰动等级，纵坐标为各路径的样本级比例。八类危险信号每类 40 条，均表现为 P0 至 P3 命中 32 条、P4 漏检 8 条，因此各类别召回率均为 0.8000，总体召回率也是 0.8000。一致的 80%并不表示类别难度完全相同，而是本测试设计为每类固定配置 8 条未登录改写。

64 条漏检样本包括“胸口像被压住一样疼”“神志模糊叫不醒”“伤口一直血流不止”等未包含规范词形的表达。漏检后，这些文本进入普通检索路径，无法恢复为高风险标签。后续不能只机械加入字符串，还需要结合语境约束、同义归一化与人工复核，防止扩大词表后引入新的误报。

5.4.2 风险等级与处理耗时统计

在排除 160 条追问样本后，风险标签统计覆盖 840 条输入。低、中、高风险 F1 分别为 0.0000、0.7080 和 0.8889，Macro-F1 为 0.5323，准确率为 68.57%。低风险 F1 为 0 源于低证据回退未触发，高风险召回损失源于 64 条 P4 改写漏检。图 5-3 进一步比较不同路径的离线组件耗时，如图 5-3 所示。




图 5-3 不同测试路径的离线组件耗时分布

图 5-3 显示，256 条规则命中样本的 P50 和 P95 耗时分别为 0.014 ms 和 0.020 ms；64 条高危漏检样本进入检索后，P50 和 P95 增至 690.715 ms 和 913.475 ms。证据支持与低证据测试的 P50 分别为 686.198 ms 和 670.048 ms，主动追问规则 P50 为 0.012 ms。图中使用对数坐标，数据只表示本机离线组件处理时间。

5.5 知识检索与引用追踪测试

5.5.1 检索功能测试

检索测试检查空查询、索引缺失、低分过滤、Top-K 截取、同义词扩展和活动版本切换。空查询与索引异常的失败关闭行为通过既有自动化测试验证；千例评测则暴露了阈值边界：200 条知识库外症状均获得高于当前阈值的候选证据，低证据回退率为 0.00%。因此，阈值过滤在本次负样本上没有实现预期的无关证据拒绝。

活动索引通过 active.json 指针切换。新版本先在临时目录构建向量和元数据，再验证向量数量与分片数量一致，最后原子替换活动指针。检索器使用活动标记刷新进程级缓存，检索结果写入新的 index_version。该过程保证版本切换不会产生半完成索引。

5.5.2 引用可追溯性测试

引用测试继续检查引用是否具备完整的来源、分片、链接、日期、版本、许可和审核信息。320 条证据支持样本均返回结构化引用，但 Recall@3 为



71.88%，表明元数据完整不能代替相关性判断。医疗 RAG 系统综述将检索方法和评价框架列为仍待统一的问题[22]；因此，记录详情页和 Trace 可以追溯本次引用来源与索引版本，评测文件同时保存每条样本的 Top-3 文档及其排序分数。

这种设计把“来源存在”和“来源可信”区分开。知识库可以保存待审核、解析失败或未向量化的文档，但这些文档不能参与普通分诊。系统保留失败状态和审核状态，方便管理人员定位知识问题，也避免在论文中把检索命中数量直接解释为医学回答质量。

5.6 权限、安全与异常处理测试

5.6.1 权限测试

权限测试分别使用 USER、DOCTOR、KNOWLEDGE_EDITOR、REVIEWER、ADMIN 和 AUDITOR 身份访问对应接口。测试检查患者是否只能读取自己的记录，医生是否能够处理复核任务，知识编辑人员是否能够提交知识，审核人员是否能够审核知识和复核结果，管理员是否能够执行治理操作，审计人员是否只能读取监控和审计资源。对未授权请求，后端返回未认证或禁止访问状态，前端路由守卫不作为唯一判断依据。

特别测试了紧急授权接口。break-glass 接口只允许 DOCTOR 调用，必须提交患者、组织范围、院区、科室、目的和理由，并记录授权起止时间。授权过期或撤销后不能继续读取相应患者上下文。该测试验证的是访问控制流程，不是对医院身份系统接入效果的评价。

5.6.2 数据保护测试

数据保护测试验证 JWT Cookie 的 HttpOnly 属性、CSRF 令牌、内部 AI 服务令牌隔离和 AES-256-GCM 加密。加密服务要求 32 字节密钥，使用 12 字节随机 Nonce 和 128 位认证标签；密钥环测试验证旧密钥数据仍可读取，新写入数据使用活动密钥。修改密文、使用未知密钥或传入过短密文时，系统抛出认证失败异常，不返回明文。

5.6.3 异常与恢复测试

异常测试覆盖 AI 服务不可用、聊天模型缺失、嵌入模型缺失、知识索引损坏、请求过大、会话冲突、容量超限、推理超时、客户端取消和流式断开。首次事件前的临时网络错误可以有限重试，参数错误、冲突和请求过大不重试；流式中中断生成错误 Trace；客户端取消释放推理租约；数据库持久化失败不会遮盖原始 AI 错误。

健康检查将 Ollama、聊天模型、嵌入模型、知识索引、模型治理和共享状态分别列出。任一关键组件不可用时，接口返回 degraded 状态，前端显示降级提示。监控页面通过 LiveTraceRegistry 接收 failed、cancelled 和 completed 状态，避免异常请求长期停留在运行中。

5.7 测试结果分析

5.7.1 科室分诊结果

在预先限定为四个受支持科室的 320 条样本上，科室 Macro-F1 为 0.9585。呼吸内科 F1 最高，为 0.9877；心血管内科 F1 最低，为 0.9189。然而加入 200 条知识库外症状后，五分类 Macro-F1 降至 0.5861。前一结果描述封闭类别内的区分能力，后一结果描述开放输入下的回退能力，两者不能相互替代。

5.7.2 风险分级结果

风险 Macro-F1 为 0.5323，没有达到旧测试中的近满分水平。高风险 F1 为 0.8889，反映未登录表达的漏检；中风险 F1 为 0.7080，其精度受到低证据样本被错误接纳的影响；低风险 F1 为 0。该结果表明当前风险标签高度依赖规则词表与证据阈值，尚不能在开放输入上形成稳定的高、中、低路径划分。

5.7.3 测试结果的工程含义

千例评测同时验证了成功路径和失败路径。已登录危险词形能够绕过普通模型流程，结构化信息不足能够触发追问，受支持科室在封闭标签内保持较高区分度；但未登录危险表达不会触发快速通道，知识库外症状也没有进入预期回退。医疗大语言模型评价研究强调，测试结果需要结合任务边界和评价方法解释[25]；因此，统计图用于展示这些工程行为及其边界，不把失败样本删除，也不把组件指标解释为医疗效果。

结果给出四项优先改进方向。第一，为危险信号增加经审核的同义归一化与语境识别，并用未登录表达持续回归。第二，使用知识库外硬负样本重新标定检索阈值，或增加独立的分布外检测与拒答判据。第三，针对心血管内科易混样本和 Recall@3 未命中样本检查查询扩展、分片内容和排序权重。第四，将上游症状抽取、知识版本、引用相关性和人工复核纳入后续端到端评测。

5.8 本章小结

本章使用固定种子生成并执行 1000 条人工构造工程测试。危险信号召回率为 80.00%，四个受支持科室的 Macro-F1 为 0.9585，加入回退类别后的五分类 Macro-F1 为 0.5861，风险 Macro-F1 为 0.5323，Recall@3 为 71.88%，追问触

发率为 100.00%，低证据回退率为 0.00%。结果说明当前 Demo 在封闭科室分诊和结构化追问上较稳定，但在未登录危险表达与知识库外拒答方面存在明确缺口。上述结果只用于工程验证，不作为临床准确率或医疗效果结论。

6 总结与展望

6.1 研究工作总结

本文围绕“基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统”开展了需求分析、总体设计、详细实现和工程测试，完成了 MedPilot 系统 Demo。

在需求分析方面，本文将系统使用者划分为普通用户、医生、知识编辑人员、审核人员、管理员和审计人员，分别梳理了智能问诊、主动追问、辅助分诊、健康档案、知识审核、医生复核、Trace 监控和审计等业务需求。分析结果表明，医疗健康咨询不能只看最终回答，还需要处理危险信号、信息缺失、知识来源、权限和记录保存等问题。

在总体设计方面，系统采用用户端、业务后端、AI 服务、数据存储和治理管理分层。AI 服务以 LangGraph 组织安全筛查、症状抽取、信息充分性判断、主动追问、知识检索、辅助分诊和回答编排。业务后端负责认证、角色授权、会话所有权、事件累积、持久化和异常处理。数据库将用户、会话、问诊记录、Trace、健康档案、知识文档、临床复核和治理证据分开保存，避免 AI 原始结果、医生最终决定和知识生命周期相互覆盖。

在详细实现方面，系统首先通过否定感知的危险信号匹配器识别胸痛、呼吸困难、气促、咯血、便血、晕厥、意识不清和大出血等表现，并在命中后进入高风险快速通道。未命中危险信号时，本地大语言模型负责将用户描述整理为结构化症状；信息不足时，系统返回带缺失字段的主动追问；信息充分时，bge-m3 和 FAISS 完成医学证据检索，分诊模块根据证据所属科室进行加权判断。最终回答由经过字段和证据校验的确定性渲染器生成，避免自由生成文本直接覆盖分诊字段。

在业务支撑方面，系统实现了问诊记录、健康档案、复诊任务、知识文档和索引版本管理、医生复核、模型与知识治理、Trace 监控及审计日志。JWT、CSRF、AES-256-GCM、医疗关系和紧急授权共同构成访问边界。AI 原始分诊结果在临床复核中保持不可变，医生的确认、修改、退回或急诊升级决定单独保存。

在测试方面，本文构建了覆盖高风险、证据支持、低证据回退和信息不足追问的扩展工程测试集，验证了安全筛查、检索、分诊、追问、权限、加密、断流、超时和索引异常等路径。测试结果以危险信号召回率、科室 F1 和风险等



级 F1 统计图展示，用于说明当前 Demo 的工程行为和规则覆盖情况。

6.2 后续展望

后续工作可以沿着数据、模型、流程和工程四个方向展开。数据方面，可以在现有公开和审核知识的基础上继续补充多专科资料，完善医学术语归一化、同义词映射和危险信号语境标注，并为每次知识更新保留更细的版本差异。

模型方面，可以比较不同本地聊天模型和嵌入模型在症状抽取、追问生成和检索排序上的差异，引入更严格的结构化输出约束和人工评价流程。评价指标应同时覆盖信息完整性、危险信号召回、证据相关性、解释一致性和回答安全性，不能只比较文本相似度。

流程方面，可以把医生复核反馈用于规则和知识的回归分析，建立从异常 Trace 到变更请求、验证证据和回滚结果的闭环。对于需要医院流程接入的场景，还需要在获得机构授权后对接统一身份、患者主索引、就诊关系和院内科室编码，并重新确认数据访问范围。

工程方面，可以继续完善并发控制、缓存策略、索引切换、监报告警和备份恢复，开展更大规模的压力测试和故障演练。前端还可以在保持当前状态边界的基础上，优化移动端问诊、引用查看和复核协同体验。



参考文献

- [1] [1] 张建同,俞文杰,李君昌,等.基于大语言模型的在线问诊医疗主题识别:以医患交流文本为驱动[J].图书与情报,2026,(3):88-102.
- [2] [2] 齐雅萱,刘勤明,叶春明,等.基于投影迭代优化算法与多特征权重急诊患者动态调度[J/OL].计算机应用,1-14[2026-08-26].<https://link.cnki.net/urlid/51.1307.TP.20260707.1549.012>.
- [3] [3] 杨霞,刘义兰,孙丽,等.人工智能门诊分导诊对分诊准确率及患者满意度的影响[J].护理学杂志,2025,40(18):10-13.
- [4] [4] 徐伟,张洪辉,林文凤.急性主动脉夹层患者急诊分诊筛查及预测工具的研究进展[J].护理学杂志,2025,40(18):18-21.
- [5] [5] 王崇金,周铿,徐乃伟,等.以患者体验为导向的互联网医院就医流程构建[J].中国医院,2025,29(8):13-16.DOI:10.19660/j.issn.1671-0592.2025.8.04.
- [6] [6] 张玉晨,王传涛,夏海梁,等.基于大语言模型的医疗智能助手应用研究进展[J].协和医学杂志,2025,16(6):1511-1518.
- [7] [7] 陈紫林,祝帆帆,罗宇昕,等.大语言模型在医疗健康领域的应用现状与前景展望[J].医学与哲学,2025,46(12):32-37.
- [8] [8] 田崇腾,刘静,王晓燕,等.大语言模型 GPT 在医疗文本中的应用综述[J].计算机科学与探索,2025,19(8):2043-2056.
- [9] [9] 闫温馨,胡健,曾华堂,等.人工智能大语言模型在基层医疗卫生服务中的应用与挑战[J].中国全科医学,2025,28(1):1-6.
- [10] [10] CHEN X, YI H, YOU M, et al. Enhancing diagnostic capability with



multi-agents conversational large language models[J]. npj Digital Medicine, 2025, 8(1): 159. DOI:10.1038/s41746-025-01550-0.

[11] [11] GABER F, SHAIK M, ALLEGA F, et al. Evaluating large language model workflows in clinical decision support for triage and referral and diagnosis[J]. npj Digital Medicine, 2025, 8(1): 263. DOI:10.1038/s41746-025-01684-1.

[12] [12] HAGER P, JUNGSMANN F, HOLLAND R, et al. Evaluation and mitigation of the limitations of large language models in clinical decision-making[J]. Nature Medicine, 2024, 30(9): 2613-2622. DOI:10.1038/s41591-024-03097-1.

[13] [13] TAM T Y C, SIVARAJKUMAR S, KAPOOR S, et al. A framework for human evaluation of large language models in healthcare derived from literature review[J]. npj Digital Medicine, 2024, 7(1): 258. DOI:10.1038/s41746-024-01258-7.

[14] [14] GALLIFANT J, AFSHAR M, AMEEN S, et al. The TRIPOD-LLM reporting guideline for studies using large language models[J]. Nature Medicine, 2025, 31(1): 60-69. DOI:10.1038/s41591-024-03425-5.

[15] [15] 王鑫林,李岩,马超凡,等.检索增强生成综述:方法与应用[J].计算机科学,2026,53(7):101-117.

[16] [16] 刘澳迪,奚雪峰,周国栋.面向大语言模型生成能力提升的检索增强生成研究进展[J/OL]. 软件学报,1-30[2026-08-26].<https://doi.org/10.13328/j.cnki.jos.007684>.

[17] [17] 李艳鹏,斯琴图,王斯日古楞.面向医学问答的检索增强生成方法综述[J/OL]. 计算机科学与探索,1-24[2026-08-26].<https://link.cnki.net/urlid/11.5602.TP.20260615.0939.002>.

[18] [18] 向洋,李理,韩东轩,等.融合反思机制与检索增强生成技术的中医问诊模型[J/OL]. 计算机工程与应用,1-15[2026-08-26].<https://link.cnki.net/urlid/11.2127.tp.20260604.1348.008>.

[19] [19] 冯朔,张清华,高满,等.基于粒计算的医疗检索增强生成方法[J/OL].重庆邮电大学学报(自然科学版),1-12[2026-08-26].<https://link.cnki.net/urlid/50.1181.N.20260522.1051.002>.

- [20] [20] 刘婕,郝舒欣,刘博涵,等.智能问答模型构建以及在公共卫生领域应用:基于检索增强生成技术[J].中国公共卫生,2026,42(5):556-562.
- [21] [21] 马鑫,王芳,张峰,等.慢性病智能医疗问答系统构建与评价:一种基于 GraphRAG 与 MoE 的混合建模方法[J].情报学报,2026,45(3):447-462.
- [22] [22] AMUGONGO L M, MASCHERONI P, BROOKS S, et al. Retrieval augmented generation for large language models in healthcare: A systematic review[J]. PLOS Digital Health, 2025, 4(6): e0000877. DOI:10.1371/journal.pdig.0000877.
- [23] [23] ZAKKA C, SHAD R, CHAURASIA A, et al. Almanac—Retrieval-augmented language models for clinical medicine[J]. NEJM AI, 2024, 1(2). DOI:10.1056/AIoa2300068.
- [24] [24] QIU J, LAM K, LI G, et al. LLM-based agentic systems in medicine and healthcare[J]. Nature Machine Intelligence, 2024, 6(12): 1418-1420. DOI:10.1038/s42256-024-00944-1.
- [25] [25] 邢倩,何达.医疗大语言模型的评价现状及思考[J].健康发展与政策研究,2025,28(1):65-72+79.
- [26] [26] 肖建力,许东舟,王浩,等.医疗领域的大型语言模型综述[J].智能系统学报,2025,20(3):530-547.
- [27] [27] 王瑞,谭旭彤,赵从朴,等.医疗不良事件人工智能分类与手动分类的对比研究——以 DeepSeek 大语言模型为例[J].协和医学杂志,2026,17(3):828-833.
- [28] [28] 张志立,杨红,庞娟,等.大语言模型在医疗数据脱敏中的实践与表现[J].北京大学学报(自然科学版),2025,61(6):1057-1063.DOI:10.13209/j.0479-8023.2025.092.
- [29] [29] 陶立元,钟晓莹,代倩倩,等.医疗保健领域大语言模型研究报告规范 TRIPOD-LLM 的应用范围解析与现状调查[J].中华医学杂志,2025,105(38):3379-3383.

- [30] [30] 郑卿勇,吴景玲,李莫兰,等.TRIPOD-LLM 指南解读: 规范医疗领域大语言模型研究的报告标准[J].中国循证医学杂志,2025,25(8):967-978.
- [31] [31] ALBER D A, YANG Z, ALYAKIN A, et al. Medical large language models are vulnerable to data-poisoning attacks[J]. Nature Medicine, 2025, 31(2): 618-626. DOI:10.1038/s41591-024-03445-1.
- [32] [32] 陈紫林,祝帆帆,卢龙.基于大语言模型的中文文献主题建模框架与实证研究——以医疗健康数据要素领域为例[J/OL].图书情报工作,1-18[2026-08-26].<https://link.cnki.net/urlid/11.1541.G2.20260817.1322.012>.
- [33] [33] 王玲.医疗领域智能化语言服务的特点及研究趋势[J].东南大学学报(哲学社会科学版),2026,28(3):143-152+164.DOI:10.13916/j.cnki.issn1671-511x.2026.03.009.
- [34] [34] 熊励,郭佳璐.大语言模型赋能医疗卫生智库转型路径研究[J].智库理论与实践,2026,11(1):102-110.DOI:10.19318/j.cnki.issn.2096-1634.20250124.0007.
- [35] [35] 李颖婷,夏苏迪,杨春花,等.基于专利数据的我国医疗大语言模型应用现状与发展特征研究[J].健康发展与政策研究,2026,29(1):24-32.
- [36] [36] 王会勇,苏秋雨,张晓明.基于多任务微调大语言模型的重症医疗知识抽取方法研究[J].计算机科学与探索,2026,20(4):1031-1045.
- [37] [37] 王嘉杰,李天逸,丁天,等.基于大语言模型合成数据的在线医疗社区虚假评论识别研究[J].情报理论与实践,2025,48(10):120-129.DOI:10.16353/j.cnki.1000-7490.2025.10.014.
- [38] [38] 王子星,齐乐,廉晓丹,等.医疗领域聊天机器人的发展与应用: 从传统方法到大语言模型[J].协和医学杂志,2025,16(5):1170-1178.
- [39] [39] 牛奔,朱晓倩,杨辰,等.基于 CiteSpace 的国内外医疗大语言模型研究热点演进及趋势分析[J].中国全科医学,2025,28(25):3200-3208.

- [40] [40] 孙丽萍,童子龙,钱乾,等.基于医疗临床数据的两阶段专业级大语言模型微调[J]. 计算机应用研究,2024,41(10):2906-2910.DOI:10.19734/j.issn.1001-3695.2024.03.0071.
- [41] [41] 杨渐雨,刘星亮.人工智能嵌入临终关怀的伦理困境及其超越[J/OL].健康发展与政策研究,1-8[2026-08-26].<https://link.cnki.net/urlid/31.2200.R.20260821.1512.001>.
- [42] [42] 苏敏,杨黎明,李政蓉.数字赋能健康治理创新的机理、样态和路径[J/OL]. 内蒙古社会科学,1-9[2026-08-26].<https://link.cnki.net/urlid/15.1011.C.20260811.1007.020>.
- [43] [43] 于蓓莉,蒲青云,冯梅,等.我国人工智能算法偏见治理的政策体系与优化路径研究[J/OL]. 图书与情报,1-12[2026-08-26].<https://link.cnki.net/urlid/62.1026.G2.20260811.1046.002>.
- [44] [44] 郝春亮,赵静,傅宏宇,等.推动“智能向善”:人工智能应用伦理安全治理的多维阐释[J].电子政务,2026,(8):2-18.DOI:10.16582/j.cnki.dzzw.2026.08.001.



致谢

回首往昔，大一初入校园时的懵懂与好奇仍历历在目。转眼间大学生活已近尾声，时光总是在不经意间悄然流逝，我也即将挥别这段珍贵的大学岁月。在这几年的求学历程中，有父母无微不至的关怀与支持，有学院各位老师的辛勤培育与悉心指引，有学长学姐们的倾囊相授，亦有同窗好友相伴前行的温情时光。正因有你们的一路相伴，才使我的大学生活充实而丰满。在此，我谨致以最真诚的感谢。

首先，我最想要感谢的是我的爸爸妈妈。父母之爱深沉而厚重，无论我走得有多远，他们始终是我坚实的后盾。在大学求学期间，是他们的默默付出、无私包容与殷切期望，给予了我勇往直前的力量与底气。我在学业与成长路上迈出的每一步，都凝聚着他们的心血与汗水。在今后的人生道路上，我定会加倍努力、奋力拼搏，不辜负父母多年来的养育之恩与殷殷期盼。

其次，我要由衷感谢李润东、宗科、荆梓恒学长，以及夏妍欢、沈欣怡、倪霜霜学姐。在我的大学生活中，学长学姐们无论是在专业学习、竞赛项目还是生活经验上，都给予了我许多无私的帮助与宝贵的建议。每当我遇到困惑与难题时，总能得到你们热心的指点与鼓励。在此衷心祝愿各位学长学姐前程似锦，山高路远，顺遂无虞；他日相逢，再叙深情厚谊。

同时，我要由衷感谢我的同学刘坤和樊诗煜。在大学期间，我们一起度过了无数充实而难忘的时光。无论是在日常学习、项目合作中的相互协作、共同探讨，还是在课后与生活中的彼此鼓励、真诚陪伴，都给予了我莫大的支持与动力。大学时光因有你们的同行而格外珍贵，在此祝愿你们在未来的道路上前程广阔、万事顺遂、平安喜乐！

接下来，我要感谢我的辅导员王群老师。在大学期间，王老师在日常学习、生活管理以及思想引导上始终给予我们无微不至的关怀与负责耐心的指导，为我们的大学生活保驾护航，陪伴并见证了我们的成长与蜕变。

同时，我要向石玲老师致以诚挚的谢意。在专业学习与实践探索的过程中，石老师严谨治学的态度、扎实的专业功底以及耐心的指导点拨，使我受益匪浅，不仅拓宽了我的专业视野，更培养了我独立思考与解决问题的能力。

最后，我要特别感谢我的论文指导老师王伟老师和陈祥老师。在本次毕业设计论文撰写的整个过程中，两位老师倾注了大量的心血与关怀。从课题的选定、方案的论证，到系统实现的细节打磨以及论文的反复修改，老师们都给

予了极具针对性、细致且严谨的指导。正是在两位指导老师的严格要求与悉心点拨下，我的毕业设计论文才得以顺利完成。在此，向王伟老师和陈祥老师致以最崇高的敬意与衷心的感谢，并祝愿各位老师工作顺利、桃李芬芳、身体安康！