


存档日期: _____

存档编号: _____



江苏师范大学科文学院

JIANGSU NORMAL UNIVERSITY KEWEN COLLEGE

本科生毕业设计

题 目: 基于多智能体协同与大语言模型的
多专科医疗健康咨询及辅助分诊系统

姓 名: 窦成皓

专 业: 软件工程

年 级: 2023 级

学 号: 7230264110

指 导 教 师: 王伟、陈祥

江苏师范大学科文学院印制

设计原创性声明

本人郑重声明：所呈交的毕业设计，是在导师的指导下，独立进行研究所取得的成果，所有数据、图片资料真实可靠。除文中已经注明引用的内容外，本设计的研究成果不包含他人享有著作权的内容。对本设计所涉及的研究工作做出贡献的个人和集体，均已在设计中以明确的方式标明。本设计的知识产权归属培养单位。

本人签名： 梁成皓

2026 年 5 月 12

日



设计版权使用授权书

本设计“基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统”是本人在校期间所完成学业的组成部分，是在江苏师范大学科文学院教师的指导下完成的，因此，本人特授权江苏师范大学科文学院可将本毕业设计的全部或部分内容编入有关书籍、数据库保存，可采用复制、印刷、网页制作等方式将设计文本和经过编辑、批注等处理的设计文本提供给读者查阅、参考，可向有关学术部门和国家有关部门或机构呈送复印件和电子文档。本毕业设计无论做何种处理，必须尊重本人的著作权，署明本人姓名。

作者签名： 裴成皓
陈祥

指导教师签名： 王伟

2026 年 5 月 12 日

2026 年 5 月 12 日



基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统

摘 要

随着互联网医疗、医学知识库和大语言模型技术的发展，自然语言交互逐渐成为健康信息服务的重要入口。医疗健康咨询涉及症状表述、风险识别、专科知识和服务流程衔接，单一生成模型难以同时承担信息整理、安全判断、证据检索和结果说明。针对这一场景，本文设计并实现了基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统 MedPilot。

系统采用 Vue 3、Spring Boot 和 FastAPI 构建分层架构，AI 服务以 LangGraph 条件工作流组织危险信号筛查、症状抽取、信息充分性判断、主动追问、医学知识检索、科室判断和回答编排。普通咨询通过 Ollama 本地大语言模型理解用户描述，结合 bge-m3、FAISS 与词法匹配检索医学证据；高风险场景优先进入规则驱动的提示流程，问诊结果同时保留风险等级、就医时效和来源信息。

系统还实现了问诊记录、授权健康档案、复诊任务、医生复核、医学知识审核与索引版本管理、Trace 监控、审计日志以及角色权限控制。前端以流式事件呈现各处理阶段，业务后端负责身份校验、数据持久化和异常处理，形成从用户咨询到结果展示、复核治理和运行追踪的完整实现。

关键词：多智能体协同；大语言模型；检索增强生成；医疗健康咨询；辅助分

诊

Design and Implementation of a Multi-Specialty Healthcare Consultation and Auxiliary Triage System Based on Multi-Agent Collaboration and Large Language Models

Abstract

Natural-language interaction has become an important entry point for digital health services as Internet healthcare, medical knowledge bases, and large language models continue to develop. Healthcare consultation combines symptom description, risk identification, specialty knowledge, and service coordination. A single generative model is therefore unsuitable for handling information organization, safety decisions, evidence retrieval, and result presentation as one undifferentiated task. This thesis designs and implements MedPilot, a multi-specialty healthcare consultation and assisted triage system based on multi-agent collaboration and large language models.

MedPilot uses Vue 3, Spring Boot, and FastAPI in a layered architecture. Its AI service coordinates danger-signal screening, symptom extraction, information-sufficiency assessment, active follow-up questioning, medical knowledge retrieval, department analysis, and answer composition through a conditional LangGraph workflow. Ordinary consultations use a locally deployed language model together with bge-m3 embeddings, FAISS retrieval, and lexical matching. High-risk scenarios enter a rule-driven warning path first, while each consultation result retains the risk level, recommended care timing, and evidence sources.

The system also provides consultation records, consent-scoped health profiles, follow-up tasks, physician review, medical knowledge approval and index-version management, trace monitoring, audit logging, and role-based access control. Streaming events expose processing stages to the front end, while the business service performs identity validation, persistence, and exception handling. These components form an integrated implementation from user consultation and result presentation to



review governance and operational traceability.

Key Words: Multi-Agent Collaboration; Large Language Models; Retrieval-Augmented Generation; Healthcare Consultation; Auxiliary Triage



目 录

摘 要.....	I
Abstract.....	II
图清单.....	V
表清单.....	VII
1 绪论.....	1
1.1 研究目的和意义.....	1
1.2 国内外发展现状.....	2
1.3 研究内容.....	3
1.4 本章小结.....	3
2 分析.....	4
2.1 可行性分析.....	4
2.2 需求分析.....	5
2.3 相关技术与开发基础.....	5
2.4 本章小结.....	6
3 概要设计.....	7
3.1 项目系统的功能与整体设计.....	7
3.2 项目系统的数据库设计.....	23
3.3 本章小结.....	30
4 系统详细设计与实现.....	31
4.1 用户认证与角色权限模块.....	31
4.2 智能问诊核心模块.....	33
4.3 问诊记录与健康档案模块.....	43
4.4 医学知识库与 RAG 模块.....	46
4.5 医生复核与治理模块.....	48



4.6 监控、审计与异常处理模块.....	51
4.7 前端主要页面实现.....	55
4.8 本章小结.....	57
5 系统测试与分析.....	58
5.1 测试环境与测试策略.....	58
5.2 测试集设计与功能测试.....	59
5.3 多智能体流程测试.....	61
5.4 危险信号与风险分级结果.....	63
5.5 知识检索与引用追踪测试.....	64
5.6 权限、安全与异常处理测试.....	65
5.7 测试结果分析.....	66
5.8 本章小结.....	66
6 总结与展望.....	68
6.1 总结.....	68
6.2 展望.....	69
参考文献.....	70
致谢.....	73

图清单

图序号	图名称	页码
图 3-1	总体功能结构图	12
图 3-2	管理员端设计图	13
图 3-3	用户端设计图	14
图 3-4	E-R 图	15
图 3-5	用户用例图	16
图 3-6	管理员用例图	17
图 3-7	User 实体类图	19
图 3-8	Patient 实体类图	20
图 3-9	ConsultationSession 实体类图	21
图 3-10	ConsultationRecord 实体类图	23
图 3-11	ConsultationMessage 实体类图	23
图 3-12	ConsultationTrace 实体类图	24
图 3-13	HealthProfile 实体类图	25
图 3-14	FollowUpTask 实体类图	26
图 3-15	KnowledgeDocument 实体类图	27
图 3-16	ClinicalReview 实体类图	29
图 4-1	用户权限管理页面	40
图 4-2	高风险快速通道结果	43
图 4-3	主动追问交互页面	46
图 4-4	检索证据支持的辅助分诊结果	48
图 4-5	多智能体协同分析过程	50
图 4-6	问诊记录的风险与证据链可视化	53
图 4-7	医学知识库与索引版本管理页面	55
图 4-8	医生复核任务列表	58

图序号	图名称	页码
图 4-9	智能体运行监控页面	61
图 4-10	问诊调用链路详情	61
图 4-11	审计日志查询页面	62
图 4-12	智能问诊页面	65
图 5-1	不同扰动强度下的任务性能	70
图 5-2	科室与回退类别混淆矩阵	71
图 5-3	不同测试路径的离线组件耗时分布	72

表清单

表序号	表名称	页码
表 3-1	users 表	30
表 3-2	patients 表	31
表 3-3	consultation_sessions 表	32
表 3-4	consultation_records 表	32
表 3-5	consultation_messages 表	33
表 3-6	consultation_traces 表	34
表 3-7	health_profiles 表	34
表 3-8	follow_up_tasks 表	35
表 3-9	knowledge_documents 表	35
表 3-10	clinical_reviews 表	36
表 5-1	主要测试环境配置	66
表 5-2	扩展工程测试集分布	68
表 5-3	核心功能测试用例	68
表 5-4	基线与消融结果	0

1 绪论

本章从研究目的、应用意义和国内外发展现状出发，说明 MedPilot 的研究范围与主要工作。本文所称辅助分诊，是指在不替代医生诊断的前提下，对用户描述进行结构化整理，识别需要优先处理的风险表现，并给出就医时效与专科方向。

1.1 研究目的和意义

1.1.1 研究目的

本研究旨在把自然语言问诊、多智能体流程、医学知识检索和安全治理组合为一套可运行的软件系统。系统需要完成症状信息采集、危险信号筛查、信息充分性判断、主动追问、证据检索、辅助分诊和结果展示，并使每一次处理都能回溯到相应的流程阶段和知识来源。

在实现层面，研究重点不是让多个模型自由讨论，而是为不同职责建立固定节点和结构化输入输出。危险信号筛查先于模型推理，信息不足时转入追问，证据满足条件后再形成科室建议；业务后端负责认证、持久化与审计，医生复核和知识治理构成后续人工控制环节。

1.1.2 研究意义

从应用角度看，系统能够把用户口语化描述转化为有序的问诊信息，并在结果页面同时呈现风险提示、就医时效、建议科室和参考来源，使健康咨询由单段回答转变为可理解的业务流程。

从工程角度看，多智能体条件 workflow 将安全筛查、信息采集、检索和回答编排拆分为可单独测试的节点；知识审核、版本管理、Trace 与审计记录则为医疗类生成系统提供了可检查的实现路径。多智能体医疗系统研究也强调，工具使用、工作流衔接与安全约束需要在同一架构中统筹考虑^[1]。

1.2 国内外发展现状

1.2.1 国外发展现状

2024 年，Hager 团队基于 2400 个真实病例和 4 类常见腹部疾病构建临床流程模拟，研究表明医学考试成绩不能直接替代真实决策流程评价^[2]。同年，Tam 团队将医疗大语言模型的人类评价划分为信息质量、理解与推理、表达与角色、安全与伤害、信任与信心 5 个维度，为系统级评价提供了更细的观察框架^[3]。

2025 年，Chen 团队在 302 个罕见病病例上比较单模型与多智能体会话框架，最优配置由 4 个医生智能体和 1 个监督智能体构成，说明角色分工可以作为复



杂医学任务的一种组织方式^[4]。Gaber 团队又在 2000 个来源于 MIMIC 的病例上

评估分诊、转诊和诊断 workflow，将检索增强纳入统一的决策支持流程^[5]。

2026 年，Kang 团队使用 6624 份三级医院转诊信开展本地大模型分诊研究，在 680 份留出集上获得 75.4% 的基线一致率，经专家裁决不一致样本后为 84.7%，另有 5.9% 的转诊材料信息不足以唯一分配专科^[6]。Flanders 团队分析 29766 份影像报告，比较 8 个开源模型、GPT-4o 与模型共识，并以 1490 份人工复核报告评价多模型组合，研究重点已从单次输出转向持续监测与共识评估^[7]。这些结果反映出国外研究正在从模型问答能力比较，转向真实流程、人工复核和运行治理。

1.2.2 国内发展现状

国内研究在 2024—2026 年间逐步形成模型适配、门诊分导诊、在线问诊理解和医学检索增强几条路线。2024 年，孙丽萍团队采用医疗临床数据开展两阶段专业级大语言模型微调，为领域适配提供了实现思路^[8]。2025 年，杨霞团队把分诊准确率和患者满意度纳入人工智能门诊分导诊评价，体现出研究对象已由算法输出扩展到服务效果^[9]。



2025 年的医疗智能助手综述系统归纳了文本处理、问答与辅助决策等应用方向^[10]。到 2026 年，张建同团队以医患交流文本研究在线问诊医疗主题识别，关注自然语言入口的信息理解问题^[11]。同年，公共卫生智能问答研究将检索增强用于具体健康服务场景^[12]。慢性病问答研究进一步结合 GraphRAG 与混合专家模型组织多源知识^[13]。

现有成果为本文提供了模型应用、分诊评价、检索增强和多智能体协同等基础。结合本科毕业设计的实现目标，MedPilot 将这些方向收敛到一条固定条件 workflow 中，并把权限、复核、知识版本与运行追踪纳入同一系统边界。

1.3 研究内容

本文首先分析用户、管理员、医生复核人员和知识维护人员的业务需求，论证系统在技术、经济、操作和社会层面的可行性，并说明 LangGraph、FastAPI、Ollama、FAISS 与 NDJSON 等技术在系统中的作用。研究方法采用工程设计研究与可复现软件评测相结合的方式：以项目源代码、Flyway 迁移脚本、审核后的知识文档和页面流程作为设计依据，以固定种子生成的人工构造测试集作为工程验证数据，不把它们解释为临床病例。技术路线按照“需求分



析—分层架构—条件 workflow 实现—数据与治理落地—千例回归测试—结果解释”的顺序展开，评价指标包括危险信号召回率与特异度、科室和风险等级 Macro-F1、Recall@3、MRR、追问触发率及组件耗时，并用否定感知规则的消融对照检验关键设计的作用。

其次，本文完成系统概要设计，给出总体功能、用户端与管理员端结构、核心实体关系、角色用例、实体类和数据库表设计。概要设计以真实前后端代码和数据库迁移为依据，使图、类与表之间保持对应。

再次，本文围绕认证授权、智能问诊、记录档案、医学知识库、医生复核、监控审计和前端页面说明详细实现。每个主要功能按照设计思路、实现代码和项目展示页面三个部分展开，使文字说明与系统实现相互印证。

最后，本文使用固定种子的千例工程测试集验证多智能体流程、危险信号处理、知识检索、引用追踪、权限控制和异常处理，并从软件工程角度分析测试结果。

1.4 本章小结



本章明确了系统的研究目的和工程意义，并结合 2024—2026 年国内外研究说明医疗大语言模型正在由单模型问答走向流程化、证据化和可治理的应用形态。在此基础上，本文将 MedPilot 定位为面向多专科健康咨询的辅助分诊系统。

2 分析

本章从可行性、需求和技术基础三个方面分析系统建设条件。分析对象既包括用户问诊和结果查看，也包括知识维护、医生复核、运行监控与安全审计。

2.1 可行性分析

2.1.1 技术可行性分析

系统采用 Vue 3、Spring Boot、FastAPI、MySQL、Ollama 与 FAISS 等成熟组件。前端负责交互与状态呈现，Spring Boot 承担认证、业务规则和持久化，FastAPI 运行多智能体工作流，本地模型与向量索引提供语言理解和知识检索。各服务通过 REST 与 NDJSON 协议连接，现有代码、测试和部署脚本能够覆盖主要业务链路，因此具备实现条件。

2.1.2 经济可行性分析



项目以开源框架和本地开发环境为主，不依赖专用商业接口。模型推理可在普通开发设备或实验室服务器上运行，数据库、前端和后端均可通过现有工具完成部署。主要成本集中在开发时间、测试数据整理和后续运行维护，符合本科毕业设计的资源范围。

2.1.3 操作可行性分析

用户端以症状输入和连续对话为主要操作，系统通过节点状态、追问提示和结果分区降低使用门槛。管理端按照知识库、复核、监控、用户和审计划分页面，操作对象与角色职责相匹配；加载、空数据、失败和完成状态均有反馈，便于日常使用。

2.1.4 社会可行性分析

系统明确辅助分诊边界，不把输出表述为确诊或处方。敏感数据通过身份认证、角色授权、医疗关系校验、加密和审计进行保护，知识文档在进入检索前需要审核。系统的功能定位与健康信息服务、就医引导和医疗安全治理需求相符。

2.2 需求分析

2.2.1 用户需求



普通用户需要完成登录、症状描述、附件上传、主动追问回复、分诊结果查看、历史记录查询、健康档案维护、复诊任务管理和健康知识检索。用户关注的结果不仅是建议科室，还包括风险提示、就医时效、形成依据和可查看的知识来源。

2.2.2 功能需求

系统应提供账号认证、角色授权、智能问诊、危险信号筛查、症状抽取、信息充分性判断、医学检索、辅助分诊、回答编排、问诊记录、健康档案、复诊任务、医生复核、知识治理、Trace 监控和审计日志等功能。管理员还应能够管理用户与角色，知识维护人员负责文档入库和版本构建，医生或复核人员负责临床复核。

2.2.3 性能需求

系统需要在问诊过程中持续返回节点状态和回答片段，避免长时间无反馈；流式事件必须保持递增顺序并具有明确终态。常用记录查询和管理列表应支持筛选，知识索引切换不应中断正在使用的版本，异常请求结束后应及时释放连接和运行状态。

2.2.4 安全需求



安全需求包括登录认证、Cookie 与 CSRF 防护、服务间令牌、后端角色校验、会话归属隔离、医疗关系和多因素认证、敏感字段加密、附件类型与大小检查、知识来源审核、操作审计和异常失败关闭。医疗文本、令牌和密钥不进入审计正文。

2.3 相关技术与开发基础

2.3.1 LangGraph 条件 workflow

LangGraph 使用有向图表示具有状态和条件分支的处理流程。本文将“多智能体”限定为多个具有固定职责、独立输入输出契约和可观测事件的流程节点：安全筛查节点负责危险信号识别，症状节点负责结构化抽取，追问节点负责信息补全，检索节点负责证据召回，分诊节点负责规则化投票，回答节点负责确定性编排。节点之间通过共享状态传递结果，由条件边决定下一步路径；它们不是可以脱离系统边界独立诊断的自治医生。该定义使每个节点都能单独测试、替换和回溯，也与多智能体会话研究所强调的职责分工相一致[10]。

2.3.2 FastAPI 与 Pydantic 结构化契约



FastAPI 用于提供 AI 服务接口，Pydantic 用于约束输入、节点状态、证据、分诊结果和事件载荷。结构化契约可以在模型输出进入业务流程前执行解析与校验，并使 Spring Boot、前端和测试使用一致的数据定义。

2.3.3 Ollama 本地大语言模型与嵌入模型

Ollama 为本地模型提供统一调用接口。系统使用聊天模型完成结构化症状理解，并使用 bge-m3 生成医学文本向量。模型在本地运行，便于固定版本、控制调用范围并与知识索引协同。

2.3.4 FAISS 向量检索与词法融合

FAISS 用于保存医学知识切片的向量并执行归一化内积检索，归一化后可视为余弦相似度。设向量分数为 S_{dense} ，中文字符二元组重合度为 S_{lex} ，系统采用 $S = 0.8S_{\text{dense}} + 0.2S_{\text{lex}}$ 作为综合分；候选池取 $\min(4K, N)$ ，其中 $K=3$ 、 N 为索引分片数，过滤阈值为 $S \geq 0.35$ ，最终返回综合分最高的 Top-3。
0.8/0.2 的设置用于保持语义相似度的主导地位，同时让短症状中的字面命中能够参与排序；0.35 和 Top-3 是当前 Demo 的工程默认值，依据低分噪声过滤页面证据数量和响应开销之间的平衡确定，不把它们表述为全局最优参数。检索增强生成研究将外部证据引入生成流程，并强调检索模块与生成模块之间的



接口约束[14]。医疗服务调度研究提示，优先级和资源分配也需要在流程层显式表达[15]。医学 RAG 综述指出，文档切分、查询表达和候选重排都会影响检索效果[16]。

2.3.5 NDJSON 事件流与 Trace

NDJSON 以一行一个 JSON 对象传输节点事件，适合在 HTTP 响应中持续返回安全筛查、症状抽取、追问、检索、分诊、回答片段和终态。Trace 将同一次咨询的事件按标识和序号关联，供前端显示进度、后端判断持久化条件以及管理端追踪调用链。

2.4 本章小结

本章说明系统在技术、经济、操作和社会层面具备建设条件，明确了用户、功能、性能与安全需求，并介绍了多智能体 workflow、本地模型、混合检索和事件追踪等开发基础。

3 概要设计

概要设计将需求分析转化为系统功能、业务角色、数据实体和数据库结构。

本章图件均依据现有前端页面、后端实体与 Flyway 迁移生成，图中对象与项目实现保持一致。



3.1 项目系统的功能与整体设计

3.1.1 总体功能结构图

系统功能以智能问诊为中心，并由账号访问、风险控制、记录档案、知识治理和运行审计共同支撑。总体功能结构如图 3-1 所示。




图 3-1 总体功能结构图

图 3-1 将系统划分为登录与身份认证、智能问诊、危险信号筛查、主动追问、医学知识检索、辅助分诊、问诊记录、健康档案、医生复核、知识治理、运行监控和审计管理。前六项构成咨询主流程，后六项负责数据留存、人工复核和持续治理。

3.1.2 用户端、管理员端功能结构图

管理员端围绕数据看板、知识库、复核治理、运行监控和权限审计组织功能，具体结构如图 3-2 所示。




图 3-2 管理员端设计图

管理员可查看咨询与风险分布，维护知识文档和索引版本，处理复核与模型治理任务，查看 Trace 和异常状态，并完成用户、角色与审计管理。各项操作由后端角色规则控制。

用户端以账号访问、智能问诊、分诊结果、问诊记录、健康管理和知识服务为主线，具体结构如图 3-3 所示。




图 3-3 用户端设计图

用户登录后可以填写症状、上传附件和回答追问；系统在结果页展示风险提示、科室建议和证据引用。问诊结束后，用户可查询记录与执行轨迹，维护健康档案和复诊计划，并使用知识检索与常见问题页面。

3.1.3 E-R 图设计

系统核心数据围绕用户、会话、消息、问诊记录、执行轨迹、健康档案、临床复核、知识文档和审计日志展开，其关系如图 3-4 所示。




图 3-4 E-R 图

一个用户可以创建多个问诊会话，一个会话包含多条消息并形成一条问诊记录；问诊记录关联多条流程事件，可进入独立的临床复核任务，也可引用多份知识文档。健康档案与用户保持一对一关系，审计日志记录受保护资源的操作结果。

3.1.4 用例图设计

用户的主要用例包括智能问诊、问诊记录、健康档案和知识服务，各主用例包含的操作如图 3-5 所示。




图 3-5 用户用例图

智能问诊包含症状填写、追问回复和结果查看；问诊记录包含筛选、详情和证据链；健康档案包含档案维护和复诊任务；知识服务包含健康知识检索与常见问题查看。

管理员用例覆盖用户权限、知识库、复核治理和监控审计，具体关系如图 3-6 所示。





图 3-6 管理员用例图

管理员可以新增用户、编辑角色和调整账号状态；在知识库中完成上传、审核和版本切换；在治理模块中查看复核队列、登记模型版本和处理变更；在监控审计模块中查看 Trace、调用链和审计日志。

3.1.5 类图设计

为突出与用户问诊主流程直接相关的对象，本文选取 10 个核心实体类进行说明。图件均由 IntelliJ IDEA 根据项目实际 Java 源码导出，按照账号、患者、问诊、健康管理、知识库和临床复核的业务链路排列。

User 实体承担用户账号、身份来源、角色和组织范围，图 3-7 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 users 表保持同名映射，便于从对象层追踪到持久化层。



Powered by yUml

图 3-7 User 实体类图


Patient 实体承担医院主患者索引映射信息，图 3-8 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 patients 表保持同名映射，便于从对象层追踪到持久化层。

© ⓘ Patient		
ⓕ ⓘ	active	boolean
ⓕ ⓘ	sourceUpdatedAt	Instant
ⓕ ⓘ	updatedAt	Instant
ⓕ ⓘ	id	Long
ⓕ ⓘ	sourceSystem	String
ⓕ ⓘ	mpild	String
ⓕ ⓘ	organizationCode	String
ⓕ ⓘ	createdAt	Instant
Ⓜ ⓘ	Patient()	
Ⓜ ⓘ	Patient(String, String, String)	

Powered by yU'lan

图 3-8 Patient 实体类图

ConsultationSession 实体承担问诊会话归属与最近活动时间，图 3-9 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 consultation_sessions 表保持同名映射，便于从对象层追踪到持久化层。



Powered by eFos

图 3-9 ConsultationSession 实体类图

ConsultationRecord 实体承担问诊结果、风险等级、科室建议与证据快照，

图 3-10 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数

据库中的 `consultation_records` 表保持同名映射，便于从对象层追踪到持久化层。



© ConsultationRecord		
f	encounterNumber	String
f	matchedRule	String
f	userId	Long
f	organizationCode	String
f	department	String
f	abstained	boolean
f	explanation	String
f	patientMpild	String
f	campusCode	String
f	encounterDepartmentCode	String
f	triageFactors	String
f	traceld	String
f	urgency	String
f	riskLevel	String
f	confidence	Double
f	citations	String
f	symptoms	String
f	createdAt	Instant
f	supportScore	Double
f	answer	String
f	conversationHistory	String
f	id	Long
f	sessionId	String
m	ConsultationRecord(Long, String)	
m	ConsultationRecord()	

图 3-10 ConsultationRecord 实体类图

ConsultationMessage 实体承担多轮问诊中的用户消息与系统消息，图 3-11

展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 consultation_messages 表保持同名映射，便于从对象层追踪到持久化层。

© ConsultationMessage		
ⓕ	⚭	userId Long
ⓕ	⚭	role String
ⓕ	⚭	id Long
ⓕ	⚭	traceld String
ⓕ	⚭	content String
ⓕ	⚭	createdAt Instant
ⓕ	⚭	sessionId String
Ⓜ	⦿	ConsultationMessage(Long, String, String, String, String)
Ⓜ	⦿	ConsultationMessage()

Powered by yUml

图 3-11 ConsultationMessage 实体类图

ConsultationTrace 实体承担多智能体流程事件、终态与处理耗时，图 3-12


展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 consultation_traces 表保持同名映射，便于从对象层追踪到持久化层。

© ConsultationTrace		
f	sessionId	String
f	createdAt	Instant
f	followupPending	boolean
f	totalDurationMs	long
f	traceId	String
f	terminalPhase	String
f	eventsJson	String
f	userId	Long
f	citationsJson	String
f	id	Long
f	failureCode	String
m	ConsultationTrace()	
m	ConsultationTrace(Long, Snapshot)	

Powered by yUml

图 3-12 ConsultationTrace 实体类图

HealthProfile 实体承担用户授权的健康档案背景信息，图 3-13 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 health_profiles 表保持同名映射，便于从对象层追踪到持久化层。




Powered by gFlow

图 3-13 HealthProfile 实体类图

FollowUpTask 实体承担复诊任务、到期时间与处理状态，图 3-14 展示了该

实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的

follow_up_tasks 表保持同名映射，便于从对象层追踪到持久化层。



Powered by yUml

图 3-14 FollowUpTask 实体类图

KnowledgeDocument 实体承担医学知识文档、审核状态与向量状态，图 3-15 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 knowledge_documents 表保持同名映射，便于从对象层追踪到持久化层。



© KnowledgeDocument		
f	institution	String
f	parsingStatus	String
f	reviewedAt	Instant
f	createdAt	Instant
f	checksum	String
f	sizeBytes	long
f	processingError	String
f	reviewer	String
f	sourceType	String
f	url	String
f	mediaType	String
f	reviewStatus	String
f	updatedAt	Instant
f	originalFilename	String
f	sourceVersion	String
f	chunkCount	int
f	docId	String
f	vectorStatus	String
f	publishedDate	String
f	license	String
f	department	String
f	title	String
m	KnowledgeDocument(String)	
m	KnowledgeDocument()	

Powered by yUml

图 3-15 KnowledgeDocument 实体类图

ClinicalReview 实体承担医生复核任务、决定与人工处理结果，图 3-16 展示了该实体在 IDEA 中识别出的字段、构造方法和业务方法。它与数据库中的 clinical_reviews 表保持同名映射，便于从对象层追踪到持久化层。




图 3-16 ClinicalReview 实体类图

3.2 项目系统的数据库设计

系统使用 MySQL 保存业务数据，Flyway 负责按版本创建和扩展表结构。

本节围绕一次问诊从身份确认、患者映射、会话交互到结果复核的主链路，选

取 10 张核心业务表进行说明。选表依据是对象一表的一致映射、主链路中的直接引用关系以及结果可追溯所需的最小字段集合；模型发布、红队测试和回滚演练等治理表仍由迁移脚本维护，但不在本节逐表展开。表中“约束”综合标记主键、非空、自增、唯一、外键和默认值，外键或业务归属字段用于限制跨用户读取和跨会话写入。

`users` 表保存系统账号、身份来源和角色信息，是认证授权的根实体。其主键被问诊会话、审计日志等业务对象引用，角色与 `active` 状态共同决定用户可访问的功能范围。字段结构如表 3-1 所示。

表 3-1 `users` 表

字段	类型	长度	约束	备注
<code>id</code>	BIGINT NOT	—	主键、自增	主键编号
<code>username</code>	VARCHAR	64	非空、唯一	用户名
<code>password_hash</code>	VARCHAR	255	可空	密码摘要
<code>role</code>	VARCHAR	16	非空	角色
<code>active</code>	BOOLEAN NOT	—	可空	是否启用
<code>created_at</code>	TIMESTAMP	6	非空	创建时间
<code>token_version</code>	BIGINT NOT	—	默认 0	token 版本
<code>identity_provider</code>	VARCHAR	16	非空、默认'LOCAL'	identityprovider
<code>external_subject</code>	VARCHAR	255	可空	externalsubject
<code>employee_number</code>	VARCHAR	64	可空	员工编号
<code>organization_code</code>	VARCHAR	64	可空	机构编码
<code>campus_code</code>	VARCHAR	64	可空	院区编码
<code>department_code</code>	VARCHAR	64	可空	科室编码



字段	类型	长度	约束	备注
patient_mpi_id	VARCHAR	128	可空	患者主索引
mfa_assurance_level	INT NOT	—	默认 0	mfaassurancelevel
last_authenticated_at	TIMESTAMP	6	可空	lastauthenticated 时间
account_expires_at	TIMESTAMP	6	可空	accountexpires 时间
local_password_enabled	BOOLEAN NOT	—	默认 TRUE	localpasswordenabled

patients 表维护医院主索引中的患者映射，用于把系统用户与院内患者标识建立受控关联。该表不保存完整病历，只提供医疗关系校验所需的最小索引信息。字段结构如表 3-2 所示。

表 3-2 patients 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
mpi_id	VARCHAR	128	非空、唯一	主患者索引
organization_code	VARCHAR	64	非空	机构编码
source_system	VARCHAR	64	非空	来源系统
active	BOOLEAN NOT	—	默认 TRUE	是否启用
source_updated_at	TIMESTAMP	6	可空	来源 updated 时间
created_at	TIMESTAMP	6	非空	创建时间
updated_at	TIMESTAMP	6	非空	更新时间

consultation_sessions 表表示一次连续的问诊会话，记录会话所属用户、状态和最近活动时间。它为多轮消息和问诊结果提供稳定的归属边界，便于恢复会话与隔离不同用户的数据。字段结构如表 3-3 所示。

表 3-3 consultation_sessions 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
session_id	VARCHAR	36	非空、唯一	会话标识
user_id	BIGINT NOT	—	可空	用户编号
created_at	TIMESTAMP	6	非空	创建时间
last_active_at	TIMESTAMP	6	非空	lastactive 时间

consultation_records 表保存一次问诊形成的结构化结果，包括风险等级、

建议科室、就医时效、回答文本和证据快照。该表是结果页面、历史记录和临

床复核读取的主要数据来源。字段结构如表 3-4 所示。

表 3-4 consultation_records 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
user_id	BIGINT NOT	—	可空	用户编号
session_id	VARCHAR	64	非空	会话标识
trace_id	VARCHAR	36	唯一	调用链标识
symptoms	LONGTEXT NULL	—	可空	症状信息
department	VARCHAR	64	可空	建议科室
risk_level	VARCHAR	16	可空	风险等级
confidence	DOUBLE NULL	—	可空	置信度
support_score	DOUBLE NULL	—	可空	证据支持度
abstained	BOOLEAN NOT	—	默认 FALSE	是否回退
urgency	TEXT NULL	—	可空	就医时效
matched_rule	VARCHAR	128	可空	命中规则
triage_factors	LONGTEXT NULL	—	可空	分诊依据
explanation	LONGTEXT NULL	—	可空	结果说明



字段	类型	长度	约束	备注
answer	LONGTEXT NULL	—	可空	系统回答
citations	LONGTEXT NULL	—	可空	引用证据快照
conversation_history	LONGTEXT NULL	—	可空	会话历史
created_at	TIMESTAMP	6	非空	创建时间
patient_mpi_id	VARCHAR	128	可空	患者主索引
encounter_number	VARCHAR	128	可空	就诊编号
organization_code	VARCHAR	64	可空	机构编码
campus_code	VARCHAR	64	可空	院区编码
encounter_department_code	VARCHAR	64	可空	encounterdepartment 编码

consultation_messages 表按顺序保存用户输入、系统追问和最终回答等消息

内容，并通过会话外键关联到 consultation_sessions。消息序号保证多轮对话能

够按原始顺序重放。字段结构如表 3-5 所示。

表 3-5 consultation_messages 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
session_id	VARCHAR	36	非空	会话标识
user_id	BIGINT NOT	—	可空	用户编号
role	VARCHAR	16	非空	角色
content	LONGTEXT NOT	—	可空	内容
trace_id	VARCHAR	36	可空	调用链标识
created_at	TIMESTAMP	6	非空	创建时间



consultation_traces 表记录危险信号筛查、症状抽取、检索、分诊和回答编

排等节点事件。它与问诊记录建立关联，既用于前端展示处理进度，也为异常

定位和审计回溯提供依据。字段结构如表 3-6 所示。

表 3-6 consultation_traces 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
trace_id	VARCHAR	36	非空、唯一	调用链标识
session_id	VARCHAR	36	非空	会话标识
user_id	BIGINT NOT	—	可空	用户编号
events_json	LONGTEXT NOT	—	可空	流程事件集合
citations_json	LONGTEXT NOT	—	可空	引用事件集合
terminal_phase	VARCHAR	32	非空	流程终止阶段
followup_pending	BOOLEAN NOT	—	可空	是否等待追问
failure_code	VARCHAR	64	可空	失败代码
total_duration_ms	BIGINT NOT	—	默认 0	总处理耗时
created_at	TIMESTAMP	6	非空	创建时间

health_profiles 表保存用户主动授权的过敏史、慢病背景和用药提示等健康

上下文。档案与用户保持一对一关系，问诊服务仅在授权范围内读取这些信息。

字段结构如表 3-7 所示。

表 3-7 health_profiles 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
user_id	BIGINT NOT	—	唯一	用户编号
profile_json	LONGTEXT NOT	—	可空	健康档案内容
consent_granted	BOOLEAN NOT	—	默认 FALSE	是否授权使用



字段	类型	长度	约束	备注
updated_at	TIMESTAMP	6	非空	更新时间

follow_up_tasks 表管理复诊提醒和随访任务，记录任务类型、到期时间、完成状态及其关联问诊。它把一次性咨询结果延伸为可跟踪的健康管理事项。

字段结构如表 3-8 所示。

表 3-8 follow_up_tasks 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
user_id	BIGINT NOT	—	可空	用户编号
record_id	BIGINT NULL	—	可空	问诊记录编号
title	LONGTEXT NOT	—	可空	标题
notes	LONGTEXT NULL	—	可空	备注
due_at	TIMESTAMP	6	非空	到期时间
status	VARCHAR	16	非空	状态
created_at	TIMESTAMP	6	非空	创建时间

knowledge_documents 表登记医学知识文档及其审核、版本和索引状态。

文档只有经过审核才能进入检索集合，问诊结果中的引用通过文档标识回溯到来源信息。字段结构如表 3-9 所示。

表 3-9 knowledge_documents 表

字段	类型	长度	约束	备注
doc_id	VARCHAR	128	主键、非空	知识文档标识
title	VARCHAR	512	非空	标题
department	VARCHAR	32	非空	建议科室
source_type	VARCHAR	64	非空	来源类型



字段	类型	长度	约束	备注
institution	VARCHAR	256	非空	发布机构
url	VARCHAR	2048	非空	来源地址
published_date	VARCHAR	10	可空	发布日期
source_version	VARCHAR	256	可空	来源版本
license_name	VARCHAR	512	可空	许可信息
original_filename	VARCHAR	512	可空	原始文件名
media_type	VARCHAR	128	可空	媒体类型
size_bytes	BIGINT NOT	—	默认 0	文件大小
checksum	VARCHAR	64	非空	内容摘要
parsing_status	VARCHAR	32	非空	解析状态
vector_status	VARCHAR	32	非空	向量状态
review_status	VARCHAR	16	非空	审核状态
chunk_count	INT NOT	—	默认 0	切片数量
processing_error	TEXT NULL	—	可空	processingerror
reviewer	VARCHAR	128	可空	审核人
reviewed_at	TIMESTAMP	6	可空	审核时间
created_at	TIMESTAMP	6	非空	创建时间
updated_at	TIMESTAMP	6	非空	更新时间

clinical_reviews 表保存医生对系统建议的领取、确认、修改、退回或升级

决定，并记录处理人和处理时间。独立的复核记录与 AI 原始结果分离，便于

责任追踪和治理统计。字段结构如表 3-10 所示。

表 3-10 clinical_reviews 表

字段	类型	长度	约束	备注
id	BIGINT NOT	—	主键、自增	主键编号
review_id	VARCHAR	36	非空、唯一	复核任务标识
consultation_record_id	BIGINT NOT	—	唯一、外键 →consultation_records.id	问诊记录编号

字段	类型	长度	约束	备注
patient_mpi_id	VARCHAR	128	可空	患者主索引
organization_code	VARCHAR	64	可空	机构编码
campus_code	VARCHAR	64	可空	院区编码
encounter_department_code	VARCHAR	64	可空	encounterdepartment 编码
ai_trace_id	VARCHAR	36	可空	aitraceid
original_department	VARCHAR	128	可空	原始值 department
original_risk_level	VARCHAR	32	可空	原始值 risklevel
original_urgency	TEXT NULL	—	可空	原始值 urgency
status	VARCHAR	32	非空	状态
decision	VARCHAR	16	可空	复核决定
claimed_by_user_id	BIGINT NULL	—	可空	领取人用户编号
reviewer_user_id	BIGINT NULL	—	可空	复核人用户编号
reviewer_employee_number	VARCHAR	64	可空	reviewer 员工编号
claimed_at	TIMESTAMP	6	可空	claimed 时间
final_department	VARCHAR	128	可空	最终值 department
final_risk_level	VARCHAR	32	可空	最终值 risklevel
final_urgency	TEXT NULL	—	可空	最终值 urgency
decision_reason	LONGTEXT NULL	—	可空	复核依据
decided_at	TIMESTAMP	6	可空	决定时间
emergency_escalated_at	TIMESTAMP	6	可空	emergencyescalated 时间
created_at	TIMESTAMP	6	非空	创建时间
updated_at	TIMESTAMP	6	非空	更新时间
version	BIGINT NOT	—	默认 0	乐观锁版本

3.3 本章小结



本章完成系统概要设计，给出了总体功能、管理员端与用户端结构、核心

E-R 关系、角色用例、10 个核心实体类和 10 张核心数据库表。实体类图来自

IntelliJ IDEA 的 Java 源码分析，数据库结构来自 Flyway 迁移与实体映射，

为下一章的详细设计与实现提供了可追踪的对象一表对应关系。

4 系统详细设计与实现

4.1 用户认证与角色权限模块

(1) 设计思路

4.1.1 登录认证实现

用户登录由后端`AuthController`提供接口。登录请求经过参数校验后，系统根据用户名查询用户，使用 BCrypt 校验密码，确认账户处于启用状态后生成 JWT。JWT 通过 HttpOnly Cookie 返回浏览器，前端只保存登录状态，不保存 AI 服务令牌。当前用户信息由`/api/auth/me`返回，退出登录时通过令牌版本和 Cookie 清理使当前会话失效。

认证过滤器`JwtAuthFilter`在业务请求进入控制器之前解析 JWT，提取用户名和角色并创建 Spring Security 认证对象。后端不相信前端路由提供的角色字段，所有资源访问仍需要经过服务端授权规则。若令牌缺失、签名无效、账户不存在或账户已失效，请求直接返回未认证状态。

4.1.2 CSRF 与内部服务令牌

系统使用 Cookie 方式传递 JWT，因此需要额外防范跨站请求伪造。后端通过`CookieCsrfTokenRepository`生成 CSRF 令牌，并将 Cookie 设置为 Strict SameSite；前端在写请求中带回对应令牌。AI 服务令牌只用于 Spring Boot 与 FastAPI 之间的内部调用，前端代码和浏览器请求中不出现该令牌。

4.1.3 角色授权实现



`SecurityConfig` 按路径和 HTTP 方法配置角色边界。临床复核接口由 DOCTOR 和 REVIEWER 访问；知识文档上传、入库和版本构建由 ADMIN 或 KNOWLEDGE_EDITOR 操作；知识审核、模型评测审核和模型回滚需要 ADMIN、REVIEWER 或 DOCTOR；模型冻结和治理变更执行限制为 ADMIN。审计和监控读取分别开放给 ADMIN、AUDITOR 及规定的复核角色。

前端路由元数据同步声明页面角色。患者端问诊、记录、健康档案和设置页面只要求已登录；知识库页面要求 ADMIN、KNOWLEDGE_EDITOR、REVIEWER 或 DOCTOR；临床复核页面要求 REVIEWER 或 DOCTOR；监控和审计页面要求 ADMIN 或 AUDITOR。路由守卫只负责改善用户体验，不能替代后端授权。

为使权限控制规则与页面角色划分能够相互核对，程序清单 4-1 截取了知识库、监控和审计资源的服务端授权配置。

(2) 实现代码

程序清单 4-1 关键资源角色授权规则

```
.requestMatchers(HttpMethod.POST,
    "/api/knowledge/ingest",
    "/api/knowledge/upload",
    "/api/knowledge/versions/build")
    .hasAnyRole("ADMIN", "KNOWLEDGE_EDITOR")
.requestMatchers(HttpMethod.DELETE, "/api/knowledge/**")
    .hasAnyRole("ADMIN", "KNOWLEDGE_EDITOR")
.requestMatchers(HttpMethod.GET, "/api/knowledge/**")
    .hasAnyRole("ADMIN", "KNOWLEDGE_EDITOR",
"REVIEWER", "DOCTOR", "AUDITOR")
    .hasAnyRole("ADMIN", "AUDITOR")
.requestMatchers("/api/audit/**")
    .hasAnyRole("ADMIN", "AUDITOR")
.requestMatchers("/api/knowledge/**", "/api/monitor/**",
"/api/dashboard/**")
    .hasRole("ADMIN")
.anyRequest().authenticated()
```

(3) 项目展示页面

代码按 HTTP 方法和资源路径区分写入、读取与审计权限，所有未单独放行的请求仍要求完成认证。对应的用户权限管理页面如图 4-1 所示。




图 4-1 用户权限管理页面

图 4-1 集中展示系统管理员、患者用户、知识编辑、医学审核员、医生顾问和审计员等角色账号，便于管理员核对账号状态与职责分配；具体访问是否允许仍由后端授权规则进行最终校验。

4.1.4 医疗数据加密实现

‘DataEncryptionService’使用 AES-256-GCM 保护敏感字符串和附件流。系统要求活动密钥解码后长度为 32 字节，每次加密生成 12 字节随机 Nonce，并使用 128 位认证标签验证密文完整性。字符串密文增加‘enc:v1’前缀和密钥标识，附件流使用独立文件前缀保存密钥标识和 Nonce。

服务支持由多个‘id=base64’条目组成的密钥环，写入时使用活动密钥，读取时根据密文中的密钥标识选择旧密钥或新密钥，从而支持不中断读取的密钥轮换。JPA 属性转换器在写入数据库时自动加密，在实体读取时自动解密；未知密钥、认证失败或密文过短均抛出数据加密异常，不返回未经验证的明文。

4.2 智能问诊核心模块



(1) 设计思路

4.2.1 危险信号筛查实现

危险信号筛查位于 AI 服务 `run_consult_stream` 的最前端。词表来源限定为项目内由 `DANGER_SIGN_TERMS` 和 `_ALIASES` 维护的工程规则：规范词包括胸痛、呼吸困难、气促、咯血、便血、意识不清、晕厥和大出血，当前登记的同义词覆盖气短、黑便、昏倒、咳血、咳出血和咳出了血。该词表用于软件路径控制，不等同于临床指南或疾病诊断标准。`match_danger_signs` 首先按标点、换行和转折词切分语句，再判断词项前是否存在“没有、否认、未见、无”等否定表达，并在“和、及、以及、或、也、并”等连接词下继承前一词项的否定状态；只有被断言出现的规范词才进入高风险路径。

筛查器使用否定表达式判断某个信号是否被否认，并在“和、及、以及、或、也、并”等连接词下继承前一危险信号的否定状态。这样可以区分“没有胸痛，也没有呼吸困难”和“没有胸痛，但出现呼吸困难”。筛查结果被转换为 `'SafetyScreenResult'`，用于承载是否命中、命中项、风险路径和规则标识。

命中危险信号时，系统调用 `'classify'` 的高风险规则，生成风险等级为“高”的 `'TriageResult'`。随后流式输出安全筛查、辅助分诊、回答编排和 `done` 事件，回答内容由确定性模板组成，包括检测到的危险信号、规则名称和就医时效。该路径不调用普通抽取、向量检索和自由回答生成，因而减少了模型或索引异常对高风险提示的影响。

危险信号处理的关键在于区分用户确认出现的症状与明确否认的症状，程序清单 4-2 给出了否定感知匹配逻辑。



(2) 实现代码

程序清单 4-2 否定感知危险信号匹配

```
def match_danger_signs(text: str) -> tuple[str, ...]:
    """Return canonical danger signs that are asserted, not explicitly negated."""
    asserted: set[str] = set()
    for clause in _CLAUSE_BOUNDARY.split(text):
        previous_end = 0
        previous_negated = False
        for start, end, canonical in _clause_matches(clause):
            prefix = clause[:start]
            connector = clause[previous_end:start]
            directly_negated = _TARGETED_NEGATION.search(prefix) is not
None
            inherited_negation = (
                previous_negated
                and _COORDINATING_TEXT.fullmatch(connector) is not None
            )
            negated = directly_negated or inherited_negation
            if not negated:
                asserted.add(canonical)
```

(3) 项目展示页面

匹配器在每个语句片段内计算直接否定和连接词继承否定，仅将未被否定的规范危险信号加入结果集合。高风险规则的运行结果如图 4-2 所示。

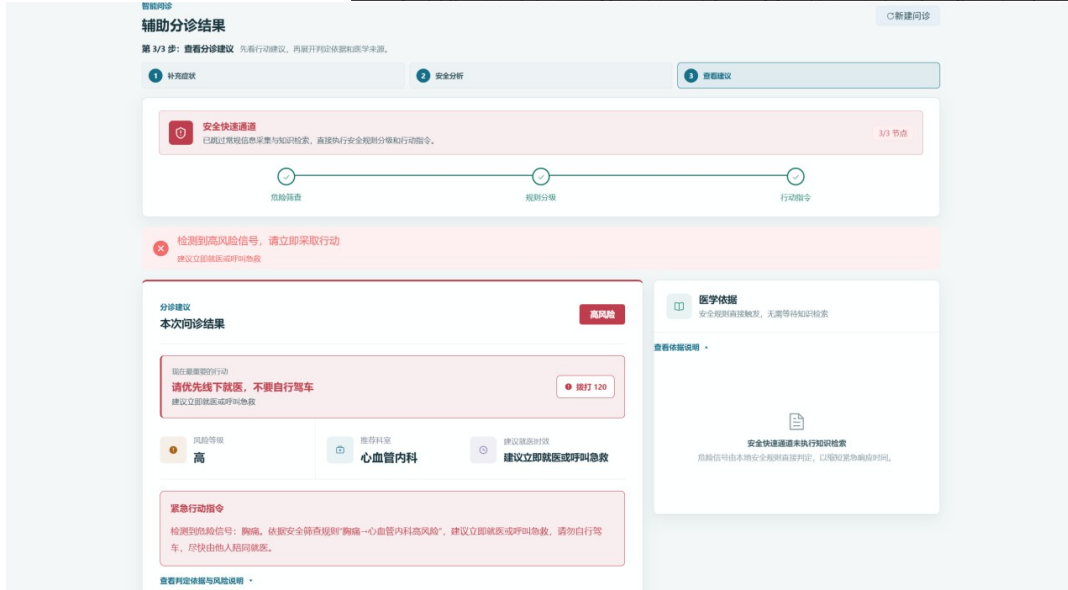


图 4-2 高风险快速通道结果

图 4-2 显示胸痛触发安全快速通道后, 界面同时给出高风险标识、建议科室和立即就医时效, 并明确该路径未执行知识检索。

4.2.2 症状抽取实现

未命中危险信号时, 流程进入 `extract` 节点。抽取提示要求聊天模型仅返回结构化 JSON。服务端使用 `_parse_llm_json` 截取 JSON 边界并交给解析器; 如果模型输出无法解析, 系统返回空结构, 而不会把自然语言直接当作结构化字段。医疗文本应用研究表明, 大语言模型可以从长文本中提取主题和关键信息^[16]。中文文献主题建模研究展示了处理医疗健康文本主题的实现框架^[17]。重症医疗知识抽取研究采用多任务微调处理专业知识^[18]。这些研究说明, 文本理解需要结合任务结构和领域约束; 因此, 系统仍通过字段校验和规则复核约束模型输出。

抽取结果经过 `'normalize_symptoms'` 归一化, 历史信息转为不可变结构, 当前文本再次通过危险信号匹配器复核。健康档案进入提示词前经过白名单和长度限制, 并明确只作为授权背景资料使用。提示词明确标记授权档案为背景资料, 防止把历史信息误当作本轮危险信号, 也防止背景文本中的指令影响系统行为。

4.2.3 信息充分性与主动追问

`'is_sufficient'` 是独立于大语言模型的确定性规则。若存在 `red_flags`, 信息直接满足快速路径; 若结构化症状不少于两个, 也可以进入检索; 若只有一个症状, 则至少需要持续时间或严重程度之一。其他情况进入 `'build_followup'`。



追问生成器按照缺失信息优先级选择问题。没有任何症状时询问主要不适；缺少持续时间时询问症状持续多久；持续时间已知但症状过少时询问是否还有其他不适；其他情况下询问严重程度。追问结果使用`FollowUpQuestion`返回问题文本和 missing 元组，前端根据 missing 字段展示等待补充状态。系统不把等待追问的会话写成低风险分诊结果。

程序清单 4-3 展示了信息充分性判断与追问生成逻辑。该逻辑先判断症状数量、持续时间和严重程度，再按缺失字段优先级生成一个追问。



程序清单 4-3 信息充分性判断与追问生成

```
def is_sufficient(s: StructuredSymptoms) -> bool:
    """判断采集到的症状信息是否足以进行分诊。"""
    if s.red_flags:
        return True
    n = len(s.symptoms)
    if n >= 2:
        return True
    if n == 1 and (s.duration or s.severity):
        return True
    return False

def build_followup(s: StructuredSymptoms) -> FollowUpQuestion:
    """根据缺失信息生成最有价值的一个追问问题。"""
    if not s.symptoms:
        return FollowUpQuestion(
            question="能描述一下您主要的不舒服是什么吗？",
            missing=("symptoms",),
        )
    missing: list[str] = []
    if len(s.symptoms) < 2:
        missing.append("more_symptoms")

    if "duration" in missing:
        question = f"您感到{s.symptoms[0]}大概有多长时间了？"
    elif "more_symptoms" in missing:
        question = f"除了{s.symptoms[0]}，还有其他不舒服的地方吗？"
    else:
        question = f"您的{s.symptoms[0]}程度如何？是轻微、中等还是严重？"
    return FollowUpQuestion(question=question, missing=tuple(missing))
```

主动追问在运行界面中的交互状态如图 4-3 所示。




图 4-3 主动追问交互页面

图 4-3 中，用户仅输入咳嗽后，系统询问症状持续时间，知识检索和辅助分诊节点保持等待，避免在信息不足时提前输出科室结论。

4.2.4 检索增强与科室判断

信息充分后，`_retrieve_node` 将原始文本和结构化症状连接为检索查询。检索器先调用 `expand_query_with_aliases` 扩展医学同义表达，再通过 `bge-m3` 生成归一化向量，在 `FAISS` 中取得 `Top-3` 的四倍候选集合。对每个候选分片计算 `S_dense` 与 `S_lex`，并按 $S=0.8S_{dense}+0.2S_{lex}$ 融合；综合分低于 0.35 的候选被过滤，剩余结果按分数排序后保留 3 条。0.8 的向量权重来自语义检索的主任务地位，0.2 的词法权重用于保留短症状的直接命中；阈值和 `K` 值与 2.3.4 节保持一致，便于测试复现。检索增强研究指出，候选重排和证据组织会影响医学问答质量[16]；因此，系统保留通过审核的证据、来源文档和索引版本，并在后续按科室分数加权。

低于 `'MEDPILOT_RAG_MIN_SCORE'` 的结果被丢弃，剩余证据按综合分排序后截取 `Top-K`。每条结果构造为 `'RankedEvidence'`，并保存可定位来源、科室、证据原文、分数、索引版本及审核状态的元数据。

`'classify'` 首先再次检查高风险规则，然后过滤出呼吸内科、消化内科、心血管内科和皮肤科证据。证据按科室累加分数，最高科室作为推荐科室，并根据最高科室占总分比例计算支持分和置信度。若没有有效证据，系统输出全科/建议线下分诊台，风险等级为低，`abstained` 为真，解释文本提示补充信息或线下分诊。

为兼顾医学语义相近和短中文症状的字面命中，检索器采用向量分数与词



法重合度融合排序，核心实现如程序清单 4-4 所示。

程序清单 4-4 向量与词法融合检索

```
k = min(max(top_k * 4, top_k), len(chunks))
scores, ids = index.search(vec, k)

candidates: list[tuple[float, float, int]] = []
for score, idx in zip(scores[0], ids[0]):
    if idx < 0:
        continue
    dense_score = float(score)
    lexical_score = _lexical_overlap(retrieval_query, chunks[idx].text)
    combined_score = 0.8 * dense_score + 0.2 * lexical_score
    if combined_score < min_score:
        continue
    candidates.append((combined_score, dense_score, int(idx)))

results: list[RankedEvidence] = []
for combined_score, _dense_score, idx in sorted(
    candidates, key=lambda item: (-item[0], item[2])
)[:top_k]:
    c = chunks[idx]
    results.append(RankedEvidence(
        citation_id=c.chunk_id,
        doc_id=c.doc_id,
        chunk_id=c.chunk_id,
        department=c.department,
        source=c.source,
        source_type=c.source_type,
        quote=c.text,
        score=round(float(combined_score), 4),
        index_version=index_version,
        institution=c.institution,
        title=c.title,
```

检索器先扩大向量候选池，再按 0.8 和 0.2 的权重融合向量分数与词法分数，

并在阈值过滤后返回 Top-K 证据。对应结果页面如图 4-4 所示。




图 4-4 检索证据支持的辅助分诊结果

图 4-4 同时展示呼吸内科建议、风险等级、就医时效与三条医学来源，体现候选证据既参与科室评分，也作为用户查看判定依据的入口。

4.2.5 确定性回答编排

当前实现的 `compose` 函数不会把聊天模型自由生成的回答直接写入系统。它先通过 `_is_trusted_evidence` 检查证据的科室、审核状态、HTTPS URL、机构、题名、发布日期、版本和许可字段，并过滤包含确诊、处方、剂量、用药等受限内容的证据。Almanac 工作强调，临床回答需要以可追溯的外部证据为基础^[19]；因此，系统仅对通过治理检查的引用进行渲染，证据不足时返回低证据提示和人工复核入口。

通过校验的 `TriageResult` 由 `_render_answer` 确定性渲染，输出推荐科室、风险等级、就医时效和执业医师复核提示。科室、风险和就医时效不在允许枚举范围内时，渲染器使用安全回退值。最终结果同时携带安全边界声明，明确系统提供辅助分诊建议，不替代医生诊断和治疗。该设计牺牲部分自然语言灵活性，换取输出字段可控和失败关闭。

4.2.6 NDJSON 流式返回

AI 服务使用 `EventEmitter` 为每个会话生成 Trace ID 和序列号。普通流程先发送 `safety_screen` 事件，再发送 `extract`、`ask_followup` 或 `retrieve`、`classify`、`compose` 节点事件；回答内容拆分为 `answer_delta` 事件，最后发送 `done`。节点异常会产生 `error` 事件，超时由服务层转换为带有 `inference_timeout` 代码的终态错



误。

业务后端的`ConsultController`通过 WebClient 打开 AI 服务流，并以 Reactor Flux 逐行处理。每行事件先交给`ConsultationEventAccumulator`解析和校验，再发布到`LiveTraceRegistry`供监控页面订阅。后端只在 done 事件存在、累计器未标记终态错误且记录条件满足时调用持久化服务；流提前结束则生成 INCOMPLETE_STREAM 错误。

程序清单 4-5 给出了统一事件封装逻辑。事件发射器为每条事件写入协议版本、Trace、会话、递增序号、阶段状态和节点数据，使前端进度展示与后端持久化使用同一事件依据。

程序清单 4-5 NDJSON 事件封装与递增序号

```
def emit(
    self,
    event_type: EventType | str,
    *,
    phase: ConsultPhase,
    status: str,
    node: str | None = None,
    label: str | None = None,
    data: dict | None = None,
) -> dict:
    if event_type not in {"node", "answer_delta", "error", "done"}:
        raise ValueError(f"unsupported event type: {event_type}")
    if event_type == "answer_delta":
        if status != "streaming" or phase != "composing":
            raise ValueError("answer_delta must be a composing stream event")
        data = AnswerDeltaData.model_validate(data or {}).model_dump()
    self._sequence += 1
    event = {
        "protocol_version": "1.0",
        "trace_id": self.trace_id,
        "session_id": self.session_id,
        "sequence": self._sequence,
        "type": event_type,
```

基于该事件序列，前端能够把多智能体协同过程转换为连续的节点进度，

运行状态如图 4-5 所示。




图 4-5 多智能体协同分析过程

图 4-5 将安全筛查、信息采集、知识检索、辅助分诊和建议生成依次呈现，并同步显示当前完成比例与会话内容，便于用户理解系统仍处于分析过程。

4.3 问诊记录与健康档案模块

(1) 设计思路

4.3.1 会话历史与消息持久化

问诊开始时，后端通过 `SessionOwnershipService` 校验并认领会话，防止不同用户交叉使用同一会话。系统先保存本轮用户消息，再按用户与会话读取历史上下文；AI 服务返回回答或追问后，后端追加助手消息。历史内容按用户和助手角色保存，并可在后续轮次采用完整历史或摘要上下文。

4.3.2 记录与 Trace 幂等持久化

`ConsultationPersistenceService` 使用事务保存 Trace、事件和问诊结果，并在写入前检查执行轨迹是否已经存在，以保证重复提交不会生成重复记录。只有在终态明确且业务结果完整时，系统才保存科室、风险、置信度、支持度、解释、回答、引用和对话上下文。

问诊记录保存成功后，如果临床复核模块已启用且记录尚无复核聚合，系统在同一事务中创建 `ClinicalReview`。AI 原始结果在复核流程中保持不变，医生最终决定写入独立字段。这样既能让用户查看 AI 原始建议，也能在后续复核



完成后展示最终科室、风险等级和就医时效。

4.3.3 健康档案与复诊任务

‘HealthProfileController’ 提供档案查询、更新和删除接口。更新时，系统将用户授权的过敏史、既往情况、用药信息和备注保存为受控背景上下文，并记录是否同意将其用于问诊。读取操作始终依据当前认证身份执行，不能通过请求参数访问其他用户的档案。

复诊任务由 ‘FollowUpTask’ 与问诊记录关联，系统提供任务列表、单条任务查询、完成和更新状态等操作。到期任务按照当前用户和开放状态筛选，避免把其他用户的提醒混入当前列表。

4.3.4 记录详情页面

‘RecordDetailView.vue’ 将一条记录拆分为分诊概览、症状摘要、判定依据、系统建议、会话内容、记录信息和依据与参考几个区域。页面同时展示 AI 推荐科室、AI 风险、支持度和就医时效；如果复核字段存在，则单独显示医生最终科室、风险和时效。引用区域展示来源、科室、证据原文、`chunk_id` 和 `index_version`，Trace ID 则位于记录元数据中。

记录详情页面根据 `reviewStatus` 显示等待复核、医生确认、医生调整、急诊人工流程或系统接管等状态。高风险记录额外显示紧急提示。页面文案把 AI 结果称为辅助分诊概览，并将医生决定与 AI 原始输出分开留存，避免用户误以为系统已完成临床诊断。



(2) 实现代码

程序清单 4-7 问诊记录与复核任务的事务持久化

```
ConsultationEventAccumulator.Snapshot snapshot) {  
    persist(userId, requestText, requestJson, snapshot, null);  
}  
  
@Transactional  
public void persist(  
    Long userId,  
    String requestText,  
    String requestJson,  
    ConsultationEventAccumulator.Snapshot snapshot,  
    PatientEncounterContext patientContext) {  
    if (traces.existsByTraceId(snapshot.traceId())) {  
        return;  
    }  
  
    traces.save(new ConsultationTrace(userId, snapshot));  
    if (messages != null && snapshot.answer() != null && !  
snapshot.answer().isBlank()) {  
        messages.appendAssistant(  
            userId, snapshot.sessionId(), snapshot.traceId(),  
snapshot.answer());  
    }  
    if (!snapshot.shouldCreateRecord()) {  
        return;  
    }  
  
    ConsultationRecord record = new ConsultationRecord(userId,  
snapshot.sessionId());  
    record.setTraceId(snapshot.traceId());
```


(3) 项目展示页面

问诊记录详情不仅保存最终文本，还把风险等级、就医时效、检索支持度和证据关系进行可视化，具体页面如图 4-6 所示。



图 4-6 问诊记录的风险与证据链可视化

图 4-6 把症状节点、检索依据与科室、风险和时效结论连接起来，同时在支持度区域标注该数值不代表临床诊断结论，从展示层面保留辅助分诊边界。

4.4 医学知识库与 RAG 模块

(1) 设计思路

4.4.1 文档入库

知识库入库支持结构化文本和文件上传两种方式。上传时系统校验科室、机构、题名、来源链接、发布日期、版本和许可等必要信息，并根据文件类型



执行文本解析；同时限制文件大小、计算 SHA-256 摘要并保留来源信息。PDF 文本由 PDFBox 提取，解析失败时保留失败状态和原因。

业务层在转发给 AI 服务前执行 `sanitizeIngestPayload`，移除客户端不应提交的审核信息，强制新文档进入待审核状态，并重新计算摘要以防止元数据被篡改。文档元数据保存于 MySQL，切片和向量化结果由 AI 服务管理。

知识文档进入 AI 服务前，业务后端会清洗审核字段并重新计算摘要，关键实现如程序清单 4-6 所示。

(2) 实现代码

程序清单 4-6 知识入库载荷清洗

```
static Map<String, Object> sanitizeIngestPayload(Map<String, ?> body) {  
    Map<String, Object> sanitized = new LinkedHashMap<>();  
    if (body != null) sanitized.putAll(body);  
    sanitized.remove("reviewer");  
    sanitized.remove("reviewed_at");  
    sanitized.remove("checksum");  
    sanitized.put("review_status", "pending");  
    Object text = sanitized.get("text");  
    if (text != null) sanitized.put("checksum", sha256(text.toString()));  
    return sanitized;  
}
```

该处理移除客户端提交的审核人、审核时间和摘要，强制新文档进入 pending 状态，从入口处防止前端伪造审核结果或内容校验值。

4.4.2 审核与版本构建

文档通过审核后，审核接口通过 X-MedPilot-Reviewer 传递当前认证主体，将审核结果同步给 AI 服务，并更新文档的审核人和审核时间。知识版本接口负责构建新的索引版本、切换活动版本和比较版本差异。TRIPOD-LLM 指南要求医疗大语言模型研究交代数据、任务、评价过程和适用边界^[20]；本系统将审核结果、索引版本和变更记录作为知识治理证据保存。

检索结果写入索引版本标识，引用快照因此能够保留本次咨询实际使用的知识环境。知识文档的删除、审核、版本切换和索引操作均受角色权限约束；解析状态和向量状态分开记录，避免把“已入库”误认为“可供检索”。

(3) 项目展示页面

医学知识库页面将文档统计、解析与向量状态、索引版本及激活动作集中展示，运行界面如图 4-7 所示。




图 4-7 医学知识库与索引版本管理页面

图 4-7 能够同时查看知识文档数量、切片数量、科室覆盖、可用索引版本和当前激活状态，使文档审核、版本构建与版本切换形成可核对的管理流程。

4.4.3 前端知识库页面

‘KnowledgeView.vue’ 提供知识统计、文档列表、版本管理、版本差异和入库表单。入库表单支持文件模式和正文模式，要求填写科室、机构、题名、来源链接、发布日期、版本和许可信息；审核状态由后端审核接口最终控制。页面还提供版本构建、版本激活和文档审核操作，使知识生命周期能够在管理端闭环完成。

4.5 医生复核与治理模块

(1) 设计思路

4.5.1 复核队列

临床复核控制器提供记录详情、领取和决定接口。复核列表按状态和创建时间查询，领取动作使用版本与状态检查，防止多个复核人员同时处理同一任务；领取成功后，任务进入 IN_REVIEW 状态并记录处理时间。



4.5.2 复核决定

前端复核表单提供 CONFIRM、MODIFY、REJECT 和 ESCALATE 四类决定。CONFIRM 保留 AI 原始结果；MODIFY 需要提交最终科室、风险等级、就医时效和复核依据；REJECT 表示退回人工处理；ESCALATE 将任务转入急诊人工流程。复核依据为必填项，决定接口同时记录复核人、员工号、理由和处理时间。

`ClinicalReviewView.vue`在列表中显示待复核数量、状态筛选和原始分诊信息，选中任务后展示 AI 建议与最终决定表单。高风险或急诊升级状态会显示院内流程提示，页面明确 AI 结果只是待复核草案。该设计把复核从“修改一条 AI 记录”变成独立工作流。

4.5.3 模型与知识治理

治理控制器提供模型发布、评测、回滚、知识来源登记、变更审批、红队测试、回滚演练、监控快照和安全事件等入口。模型发布需要记录版本、签名、提示词与嵌入配置、知识索引版本、硬件基线和审批证据；高风险动作由具备相应权限的角色执行。算法偏见研究强调，人工智能决策需要配套偏差治理机制^[21]；因此，治理模块把模型发布、评测、回滚和安全事件作为可审计的独立操作。

治理模块采用角色分离。模型和知识证据由管理员或知识编辑人员提交，审核人员或医生复核，冻结、执行和回滚等高风险操作限制为管理员。系统不会因为存在某个模型记录就自动切换模型，模型和知识版本必须经过明确审批并激活。



(2) 实现代码

程序清单 4-8 临床复核领取与决定逻辑

```
        : reviews.findByStatusOrderByCreatedAtDesc(status);
    return candidates.stream()
        .filter(review -> readableReview(actor, review))
        .toList();
    }

    @Transactional(readOnly = true)
    public ClinicalReview get(User actor, String idOrReviewId) {
        requireClinicalReviewer(actor);
        ClinicalReview review = find(idOrReviewId);
        requireReadable(actor, review);
        return review;
    }

    @Transactional
    public ClinicalReview claim(User actor, String idOrReviewId) {
        requireClinicalReviewer(actor);
        ClinicalReview review = find(idOrReviewId);
        ConsultationRecord record = requireReadable(actor, review);
        rejectSelfReview(actor, record);
        review.claim(actor, Instant.now());
        return reviews.save(review);
    }

    @Transactional
    public ClinicalReview decide(
        User actor,
        String idOrReviewId,
        ClinicalReviewDecision decision,
        String finalDepartment,
```



(3) 项目展示页面

医生复核任务以队列形式展示待处理记录，复核人员可查看原始建议并提交确认、修改、退回或升级决定，页面如图 4-8 所示。




图 4-8 医生复核任务列表

图 4-8 将任务状态、风险等级、建议科室和处理入口集中呈现，使人工复核形成独立于原始 AI 记录的业务流程。

4.6 监控、审计与异常处理模块

(1) 设计思路

4.6.1 Trace 监控页面

‘MonitorView.vue’维护健康状态、历史 Trace、实时 Trace、节点状态和事件列表。页面通过健康接口获取模型服务、知识索引和治理状态，通过 Trace 列表查询历史运行，通过事件流定位当前活动。节点列表展示安全筛查、症状采集、追问、知识检索、辅助分诊和回答编排的状态。

Trace 详情按会话、阶段和轮次展示事件序列，并汇总节点耗时、失败原因、

终态和引用数量以辅助定位问题。监控图表只反映已采集的运行样本，不把样本量或耗时直接解释为医疗质量指标。



(2) 实现代码

程序清单 4-9 实时 Trace 登记与事件发布

```
}

@Autowired
public LiveTraceRegistry(ObjectMapper mapper, RedisRuntimeState sharedState) {
    this.mapper = mapper;
    this.sharedState = sharedState;
}

public synchronized Handle start(String sessionId, Long userId) {
    Handle handle = new Handle(UUID.randomUUID().toString(), sessionId, userId);
    MutableTrace trace = new MutableTrace(handle);
    traces.put(handle.requestId(), trace);
    trimRecent();
    emit("started", trace);
    persistShared(trace);
    return handle;
}

public synchronized void publish(Handle handle, String traceId, String rawEvent) {
    MutableTrace trace = require(handle);
    if (!"active".equals(trace.status)) return;
    trace.traceId = preferTraceId(trace.traceId, traceId);
    trace.events.add(readEvent(rawEvent));
    trace.updatedAt = Instant.now();
    emit("event", trace);
    persistShared(trace);
}

public synchronized void complete(Handle handle, String traceId) {
    terminate(handle, traceId, "completed", null);
}
}
```

(3) 项目展示页面

监控模块先提供系统与 Trace 总览，展示模型服务、活动会话、知识文档、向量索引及链路统计，页面如图 4-9 所示。




图 4-9 智能体运行监控页面

图 4-9 用于定位服务可用性和链路运行状态。选择具体 Trace 后，系统进一步显示事件级调用链路，如图 4-10 所示。




图 4-10 问诊调用链路详情

图 4-10 按事件序号列出安全筛查、症状采集、主动追问和流程完成状态，并保留各事件耗时及输出摘要，便于从单次会话追踪条件路由结果。

4.6.2 审计日志

‘AuditLogInterceptor’ 为受保护 Web 请求记录操作者、角色、HTTP 方法、动作、响应状态、请求标识、地址摘要和耗时，并将成功或失败结果写入审计日志。监控与审计页面分别提供查询和导出入口，不同角色只能读取其权限范围内的记录。

审计日志页面支持按操作者和响应状态筛选，并以时间、角色、动作、结果和耗时为主要字段展示访问记录，如图 4-11 所示。

图 4-11 审计日志查询页面

图 4-11 中的记录覆盖用户管理、监控统计与 Trace 查询等操作；页面只保留访问边界、结果和耗时，不保存请求正文、令牌或医疗文本。

4.6.3 错误与取消处理

后端对 AI 服务异常分为连接失败、HTTP 错误、请求过大、会话冲突、容量超限、推理超时和流不完整等类型。首次事件前的可重试错误使用指数退避进行有限重试；请求参数错误、冲突和超大请求不重复提交。流式过程中如果客户端取消，后端保存取消 Trace 并释放上游连接；如果 AI 服务没有发送 done 事件，累计器生成 INCOMPLETE_STREAM 错误。



异常持久化采用“错误优先返回”原则。若数据库同时不可用，系统不会用持久化失败覆盖原始 AI 错误，而是尽量向客户端返回可操作的错误代码。LiveTraceRegistry 也会收到 failed 或 cancelled 状态，使监控端不会把异常请求留在运行中。

4.7 前端主要页面实现

(1) 设计思路

4.7.1 智能问诊页面

`ConsultView.vue` 提供症状输入、历史消息、健康档案上下文、流式节点状态、追问、分诊结果、引用和安全边界展示。用户提交后，页面先显示安全筛查状态，再根据事件更新症状采集、知识检索、辅助分诊和回答编排节点。追问状态显示缺失信息类别，用户补充内容后继续下一轮；高风险状态使用单独的警示区域显示就医时效。

4.7.2 知识库、复核和监控页面

知识库页面采用列表、统计卡片、版本切换和入库表单组合；复核页面采用左侧队列和右侧决定表单组合；监控页面采用服务状态卡、节点进度、Trace 详情、实时事件和历史列表组合。三类管理页面都根据角色显示操作按钮，后端响应失败时保留错误提示和刷新入口。

4.7.3 响应式与状态反馈

前端页面对加载、空数据、错误、正常完成和风险升级分别设置界面状态。问诊和记录详情在窄屏下将双栏布局改为单栏，引用、Trace ID 和长文本使用换行策略避免溢出。页面中的 AI 推荐、医生最终决定和安全声明使用不同的视觉区域，避免把三者混为一个结果。



(2) 实现代码

程序清单 4-10 前端 NDJSON 流读取与事件处理

```
async function requestConsult(text) {  
  stage.value = 'processing'  
  workflowStep.value = 0  
  progress.value = 0  
  requestError.value = ''  
  requestErrorSource.value = null  
  feedbackSelection.value = ''  
  feedbackSubmitted.value = false  
  followupQuestion.value = ''  
  structuredSymptoms.value = null  
  evidenceList.value = []  
  triageData.value = null  
  answerText.value = ''  
  answerCitations.value = []  
  safetyBoundary.value = ''  
  resultCreatedAt.value = null  
  
  const controller = new AbortController()  
  abortController.value = controller  
  
  const requestFailure = new Error(payload?.error || `问诊服务请求失败 ($  
{response.status})`)  
  requestFailure.status = response.status  
  throw requestFailure  
}  
if (!response.body) {  
  throw new Error('问诊服务未返回可读取的响应流。')  
}
```



(3) 项目展示页面

智能问诊页面将用户输入、会话内容和多智能体节点进度组合在同一工作区，页面如图 4-12 所示。



图 4-12 智能问诊页面

图 4-12 保留清晰的症状输入入口，并在咨询过程中持续展示问诊内容与处理状态，为主动追问和分诊结果提供统一交互空间。

4.8 本章小结

本章从代码实现角度说明了 MedPilot 的核心模块。系统通过否定感知的危险信号匹配器实现高风险快速通道，通过本地大语言模型完成结构化症状抽取，通过规则判断信息充分性并生成追问，通过 bge-m3 和 FAISS 完成证据检索，再由确定性渲染器输出辅助分诊说明。业务后端负责 JWT、CSRF、角色授权、会话所有权、事件累积、幂等持久化和异常处理；健康档案、知识库、医生复核、Trace 监控、审计和治理模块则补足了系统的持续使用边界。前端页面将这些状态和证据组织为问诊、记录、知识、复核和监控工作区。第 5 章将对上述功能进行系统测试并分析统计结果。



5 系统测试与分析

5.1 测试环境与测试策略

5.1.1 测试环境

MedPilot 的测试环境由前端、业务后端、AI 服务、数据库、模型服务和向量索引组成。前端运行在 Node.js 环境，业务后端使用 Java 17 和 Spring Boot，AI 服务使用 Python 3.11、FastAPI 和 LangGraph，MySQL 保存用户、问诊、知识和治理数据，Ollama 提供 qwen2.5:7b 聊天模型与 bge-m3 嵌入模型，FAISS 保存医学知识分片索引。测试阶段使用本地部署方式，服务之间通过回环地址通信，避免把测试文本发送到第三方推理平台。

表 5-1 给出主要测试环境配置。

表 5-1 主要测试环境配置

项目	配置
前端	Vue 3、Vite、Node.js、Element Plus
业务后端	Java 17、Spring Boot 3.3.4、JPA、Spring Security
AI 服务	Python 3.11、FastAPI、LangGraph、Pydantic
聊天模型	Ollama / qwen2.5:7b
嵌入模型	Ollama / bge-m3
检索索引	FAISS IndexFlatIP，向量归一化内积
数据库	MySQL 8，Flyway 迁移
流式协议	NDJSON
测试方式	规则测试、检索测试、接口测试、页面流程测试

5.1.2 测试策略

测试策略按照“单节点—业务链路—系统边界”的顺序设计。单节点测试关注危险信号匹配、否定表达、信息充分性、追问生成、科室投票、证据门控和数据加密；业务链路测试关注从登录到问诊、从问诊到记录、从知识入库到索引激活、从 AI 结果到医生复核的完整过程；系统边界测试关注权限、超时、容量、断流、模型不可用和数据库异常。每条测试输入在运行前写入固定字段：task 表示任务类别，gold_route 表示预期路径，gold_department 和 gold_risk 表示分类金标准，gold_red_flags 表示危险信号集合，acceptable_doc_ids 表示可接受证据。高风险样本以 gold_red_flags 非空为判定条件，证据分诊样本要

求结构化症状充分且存在目标科室，低证据样本来自受支持科室之外的信息不足输入，追问样本要求症状为空或只有单症状且缺少持续时间和严重程度。P0至P4只描述输入扰动强度，不改变金标准；测试集由 benchmark_1000.py 以种子 20260831 生成后冻结。TRIPOD-LLM 报告规范要求明确说明任务、数据和评价过程[22]。TRIPOD-LLM 指南还要求交代研究适用边界和报告细节[23]。

测试输入分为高风险、证据支持、低证据和信息不足四类。测试集由固定种子 20260831 生成并在运行前冻结，逐条记录金标准、扰动等级和预期路径。高风险文本调用生产安全筛查；证据支持与低证据文本调用现有 bge-m3、FAISS 和证据加权分类；信息不足样本调用结构化症状充分性与追问规则。自由文本回答生成不计入分类指标，避免把随机生成质量混入确定性组件评测。

5.1.3 指标定义

危险信号召回率用于衡量已标注危险信号是否被系统识别，定义为 $\text{Recall_safe} = \text{TP_safe} / (\text{TP_safe} + \text{FN_safe})$ 。该指标只反映规则筛查对测试样本的覆盖情况，不代表临床筛查性能。医疗大语言模型的人类评价框架指出，安全与伤害应作为独立评价维度[13]；因此，本文将危险信号召回率与否定表达、词表外表达和普通样本误触发情况分开统计。

危险信号召回率 = 正确识别的危险信号样本数 / 危险信号样本总数；非高风险特异度 = 正确未触发样本数 / 非高风险样本总数。

科室和风险等级采用 Precision、Recall 和 F1 进行统计： $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$ ， $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$ ， $\text{F1} = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$ 。Macro-F1 = $(1/C) \sum \text{F1}_c$ ，其中 C 为标签数量，先分别计算每个标签的 F1，再取算术平均，以避免样本较多的类别完全主导结果。

信息不足样本不纳入科室和风险 F1，而单独统计追问触发率。证据支持样本统计 $\text{Recall@3} = \text{命中可接受证据的样本数} / \text{证据支持样本数}$ ，并统计 $\text{MRR@3} = (1/M) \sum (1/r_i)$ ，其中 r_i 为第 i 条样本首个可接受证据在前三位中的名次，未命中时记为 0。科室指标分别报告四个受支持科室的 Macro-F1，以及加入全科/线下回退类别后的五分类 Macro-F1。组件耗时从函数实际开始执行到返回结果为止，不包含并发队列、浏览器、业务后端、数据库和网络传输，因此不等同于线上端到端延迟。上述指标只描述当前 Demo 在人工构造工程测试集上的行为，不用于推断临床准确率。

5.2 测试集设计与功能测试

5.2.1 测试集分布



本次固定种子工程测试集共 1000 条，具体分布如表 5-2 所示。

表 5-2 扩展工程测试集分布

测试类别	数量	覆盖内容
高风险危险信号	320	8 类危险信号，每类 40 条；5 级扰动各 64 条
证据支持的中风险	320	4 个受支持科室，每科 80 条；5 级扰动各 64 条
低证据回退	200	10 类知识库外症状；5 级扰动各 40 条
信息不足追问	160	无症状或单症状缺字段；5 级扰动各 32 条
合计	1000	固定种子 20260831，逐条保存预测、证据与耗时

高风险样本覆盖胸痛、呼吸困难、气促、咯血、便血、晕厥、意识不清和大出血，每类 40 条。全部样本按 P0 至 P4 划分为规范表达、口语与同义表达、组合与背景干扰、否定与跨症状干扰、错别字与词表外改写五级。证据支持样本围绕心血管内科、呼吸内科、消化内科和皮肤科构造；低证据样本来自骨科、耳鼻喉、眼科、口腔、泌尿等非目标专科症状；信息不足样本只保留空症状或单症状且不提供持续时间和严重程度。

5.2.2 功能测试项目

功能测试覆盖认证、问诊、记录、健康档案、知识库、复核、监控和审计八类模块。测试用例如表 5-3 所示。

表 5-3 核心功能测试用例

编号	测试项目	输入或操作	预期结果
1	用户登录	输入有效用户名和密码	返回 JWT Cookie 并进入授权页面
2	错误登录	输入错误密码	返回未认证结果，不创建有效会话
3	危险信号筛查	提交包含胸痛或呼吸困难的文本	进入高风险快速通道
4	否定表达	提交“没有胸痛，也没有呼吸困难”	不触发危险信号规则
5	信息不足追问	仅提交“有点头晕”	返回追问问题和缺失字段
6	证据检索	提交喘息、咳嗽和运动后加重	返回呼吸内科证据



编号	测试项目	输入或操作	预期结果
7	辅助分诊	使用有效证据完成检索	返回科室、风险和支撑因素
8	低证据回退	提交知识库未覆盖的一般不适	返回全科/线下分诊台并暂缓判断
9	记录保存	正常完成 done 事件	保存问诊记录、消息和 Trace
10	断流处理	AI 服务未发送 done 事件	记录 INCOMPLETE_STREAM 错误
11	健康档案	更新并授权过敏史等背景信息	档案保存并按授权传入问诊
12	医生复核	领取任务并提交决定	保存独立复核结果
13	知识审核	上传文档并审核	文档状态和审核人被记录
14	监控查询	输入 Trace ID	显示节点事件、耗时和终态
15	审计导出	查询并导出审计记录	返回当前角色允许范围内的 CSV

功能测试的判断标准不是页面是否能够点击，而是请求、业务状态、持久化结果和页面反馈是否一致。例如，追问接口返回问题但不应生成低风险记录；高风险快速通道不应等待普通 RAG 检索；医生修改结果后，AI 原始分诊仍然保留。

5.3 多智能体流程测试

5.3.1 安全筛查节点

安全筛查节点在普通模型调用前执行。320 条高风险样本中，P0 至 P3 共 256 条全部命中，P4 的 64 条错别字或词表外改写按照普通检索路径处理，总体召回率为 80.00%。其余 680 条非高风险样本没有触发危险信号，工程测试特异度为 100.00%。结果显示，安全规则对已登记词形及否定、转折表达的处理保持稳定，不同词表覆盖等级的统计结果如图 5-1 所示。




图 5-1 不同扰动强度下的任务性能

图 5-1 按扰动等级比较四条测试路径。P0 至 P3 的危险信号召回率均为 100%，P4 下降为 0；证据分诊准确率在 P3 为 92.19%，其余等级为 96.88%；主动追问始终为 100%，低证据回退始终为 0。不同曲线的分母分别为每级 64、64、32 和 40 条，不能将曲线间的高低直接解释为同一临床能力。

5.3.2 信息充分性与主动追问

信息充分性规则根据症状数量、持续时间和严重程度决定是否进入检索。160 条信息不足样本全部触发追问，触发率为 100.00%。该结果对应结构化症状对象上的纯规则行为，指标范围限定在信息充分性判断与追问节点，不扩展到 qwen2.5:7b 的自由抽取质量。

追问测试验证了一个工程边界：没有危险信号不等于信息已经充分。空症状对象会询问主要不适；单症状且缺少持续时间和程度时，会优先询问持续时间或其他症状。该分支在固定结构化输入上能够阻止提前分诊，本项结果对应上游症状抽取完成后的规则层行为。

5.3.3 检索、分诊与回答编排

320 条证据支持样本均返回至少一条索引证据，证据返回率为 100.00%；但 Top-3 中包含预先标注的可接受文档的比例为 71.88%，MRR@3 为 0.6255。这说明“返回了证据”与“返回了目标证据”不是同一指标。检索结果继续按科室分数加权，回答层只渲染结构化分诊字段与通过治理检查的引用，如图 5-2 所示。




图 5-2 科室与回退类别混淆矩阵

图 5-2 给出 320 条受支持科室样本与 200 条低证据样本的五分类混淆矩阵。仅在四个受支持科室内统计时，准确率为 95.94%，Macro-F1 为 0.9585；加入回退类别后，准确率降至 59.04%，Macro-F1 为 0.5861。200 条知识库外症状全部被分配到四个受支持科室，回退类别召回率为 0，说明当前相似度阈值没有形成有效的分布外拒答边界。

回答编排测试验证了失败关闭逻辑。证据不满足审核状态、HTTPS 来源、发布日期、版本或许可信息时，不进入引用列表；分诊字段不在允许枚举范围时，渲染器使用安全回退值。聊天模型输出的自由文本不会覆盖最终分诊字段，因而可以避免模型在回答中自行添加处方、剂量或确定性诊断。

5.4 危险信号与风险分级结果

5.4.1 危险信号统计

图 5-1 的横坐标为五个扰动等级，纵坐标为各路径的样本级比例。八类危险信号每类 40 条，均表现为 P0 至 P3 命中 32 条、P4 漏检 8 条，因此各类别召回率均为 0.8000，总体召回率也是 0.8000。一致的 80%并不表示类别难度完全相同，而是本测试设计为每类固定配置 8 条未登录改写。

P4 的 64 条样本包括“胸口像被压住一样疼”“神志模糊叫不醒”“伤口一直血流不止”等词表外表达。这些文本按照现有路由进入普通检索路径，体现危险信号规则以登记词形和同义归一化结果为识别边界。后续扩展词表时需同

步采用语境约束与人工复核，以维持规则召回和误报控制之间的平衡。

5.4.2 风险等级与处理耗时统计

在排除 160 条追问样本后，风险标签统计覆盖 840 条输入。低、中、高风险 F1 分别为 0.0000、0.7080 和 0.8889，Macro-F1 为 0.5323，准确率为 68.57%。低风险 F1 为 0 对应 200 条非目标专科样本均进入候选证据路径，高风险召回差异主要集中在 64 条 P4 词表外改写。图 5-3 进一步比较不同路径的离线组件耗时，如图 5-3 所示。




图 5-3 不同测试路径的离线组件耗时分布

图 5-3 显示，256 条规则命中样本的 P50 和 P95 耗时分别为 0.014 ms 和 0.020 ms；64 条高危漏检样本进入检索后，P50 和 P95 增至 690.715 ms 和 913.475 ms。证据支持与低证据测试的 P50 分别为 686.198 ms 和 670.048 ms，主动追问规则 P50 为 0.012 ms。图中使用对数坐标，数据只表示本机离线组件处理时间。

5.5 知识检索与引用追踪测试

5.5.1 检索功能测试

检索测试检查空查询、索引缺失、低分过滤、Top-K 截取、同义词扩展和活动版本切换。空查询与索引异常的失败关闭行为通过既有自动化测试验证；千例评测则暴露了阈值边界：200 条非目标专科症状均获得高于当前阈值的候选证据，低证据回退率为 0.00%。因此，当前阈值策略把这组输入归入候选证据路径，该结果用于界定本轮工程测试中的回退触发范围。



活动索引通过 `active.json` 指针切换。新版本先在临时目录构建向量和元数据，再验证向量数量与分片数量一致，最后原子替换活动指针。检索器使用活动标记刷新进程级缓存，检索结果写入新的 `index_version`。该过程保证版本切换不会产生半完成索引。

5.5.2 引用可追溯性测试

引用测试继续检查引用是否具备完整的来源、分片、链接、日期、版本、许可和审核信息。320 条证据支持样本均返回结构化引用，但 Recall@3 为 71.88%，表明元数据完整不能代替相关性判断。医疗 RAG 系统综述将检索方法和评价框架列为仍待统一的问题^[24]；因此，记录详情页和 Trace 可以追溯本次引用来源与索引版本，评测文件同时保存每条样本的 Top-3 文档及其排序分数。

这种设计把“来源存在”和“来源可信”区分开。知识库可以保存待审核、解析失败或未向量化的文档，但这些文档不能参与普通分诊。系统保留失败状态和审核状态，方便管理人员定位知识问题，也避免在论文中把检索命中数量直接解释为医学回答质量。

5.6 权限、安全与异常处理测试

5.6.1 权限测试

权限测试分别使用 USER、DOCTOR、KNOWLEDGE_EDITOR、REVIEWER、ADMIN 和 AUDITOR 身份访问对应接口。测试检查患者是否只能读取自己的记录，医生是否能够处理复核任务，知识编辑人员是否能够提交知识，审核人员是否能够审核知识和复核结果，管理员是否能够执行治理操作，审计人员是否只能读取监控和审计资源。对未授权请求，后端返回未认证或禁止访问状态，前端路由守卫不作为唯一判断依据。

特别测试了紧急授权接口。`break-glass` 接口只允许 DOCTOR 调用，必须提交患者、组织范围、院区、科室、目的和理由，并记录授权起止时间。授权过期或撤销后不能继续读取相应患者上下文。该测试验证的是访问控制流程，不是对医院身份系统接入效果的评价。

5.6.2 数据保护测试

数据保护测试验证 JWT Cookie 的 `HttpOnly` 属性、CSRF 令牌、内部 AI 服务令牌隔离和 AES-256-GCM 加密。加密服务要求 32 字节密钥，使用 12 字节随机 Nonce 和 128 位认证标签；密钥环测试验证旧密钥数据仍可读取，新写入数据使用活动密钥。修改密文、使用未知密钥或传入过短密文时，系统抛出认证失

败异常，不返回明文。

5.6.3 异常与恢复测试

异常测试覆盖 AI 服务不可用、聊天模型缺失、嵌入模型缺失、知识索引损坏、请求过大、会话冲突、容量超限、推理超时、客户端取消和流式断开。首次事件前的临时网络错误可以有限重试，参数错误、冲突和请求过大不重试；流式中中断生成错误 Trace；客户端取消释放推理租约；数据库持久化失败不会遮盖原始 AI 错误。

健康检查将 Ollama、聊天模型、嵌入模型、知识索引、模型治理和共享状态分别列出。任一关键组件不可用时，接口返回 degraded 状态，前端显示降级提示。监控页面通过 LiveTraceRegistry 接收 failed、cancelled 和 completed 状态，避免异常请求长期停留在运行中。

5.7 测试结果分析

5.7.1 科室分诊结果

在预先限定为四个受支持科室的 320 条样本上，科室 Macro-F1 为 0.9585。呼吸内科 F1 最高，为 0.9877；心血管内科 F1 最低，为 0.9189。然而加入 200 条知识库外症状后，五分类 Macro-F1 降至 0.5861。前一结果描述封闭类别内的区分能力，后一结果描述开放输入下的回退能力，两者不能相互替代。

5.7.2 风险分级结果

风险 Macro-F1 为 0.5323，相较旧测试中的近满分结果，更完整地呈现了扩展扰动后的路径分布。高风险 F1 为 0.8889，与 P4 词表外改写的路由结果对应；中风险 F1 为 0.7080，与非目标专科样本进入候选证据路径有关；低风险 F1 为 0。结果表明风险标签分布由规则词表与证据阈值共同决定，本轮指标适用于当前固定测试集与系统版本。

5.7.3 测试结果的工程含义

本轮结果按任务边界和评价方法解释，不把组件指标直接外推为医疗效果[25]。高风险优先规则的设计与急诊分诊筛查研究强调的时间敏感性相呼应[26]。互联网医院流程研究提示，入口、信息提交和路径衔接需要被视为连续服务过程[27]。医疗健康领域大语言模型综述将文本处理、问答和辅助决策视为主要应用方向[28]。基层医疗研究则强调部署时需要同步考虑场景约束和使用责任[29]。RAG 方法综述把检索、重排和生成之间的衔接作为系统设计对象[30]。



结果给出四项优先改进方向。第一，为危险信号增加经审核的同义归一化与语境识别，并用未登录表达持续回归。第二，使用知识库外硬负样本重新标定检索阈值，或增加独立的分布外检测与拒答判据。第三，针对心血管内科易混样本和 Recall@3 未命中样本检查查询扩展、分片内容和排序权重。第四，将上游症状抽取、知识版本、引用相关性和人工复核纳入后续端到端评测。

面向医学问答的检索增强研究进一步强调领域知识与证据组织的结合[31]。融合反思机制的研究说明，结果校验可以作为生成流程的附加控制环节[32]。粒计算检索研究为多粒度证据组织提供了可参考的实现视角[33]。医疗大语言模型综述显示，模型能力应放在具体任务和数据环境中评价[34]。医疗不良事件研究将模型分类与人工分类进行对比，说明工程评测需要设置可解释的参照方法[35]。

为区分否定感知和分句处理对安全筛查的贡献，本文在同一固定种子的1000 条测试输入上设置一个最小消融：完整方案使用 DANGER_SIGN_TERMS、同义词表和否定感知分句；消融方案仅保留规范词与同义词的简单子串匹配，去除否定和连接词继承逻辑。两种方案使用相同的金标准和统计口径，结果如表 5-4 所示。

表 5-4 基线与消融结果

方案	危险信号召回率	非高风险特异度	实现条件
完整方案	0.8000	1.0000	分句、否定感知、连接词继承



消融方案	0.7937	0.8941	规范词/同义词简单子串匹配
差值（完整-消融）	+0.0063	+0.1059	相同 1000 条输入与金标准

表 5-4 显示，完整方案与简单子串消融在召回率上差异较小，但非高风险特异度相差 10.59 个百分点。差异主要来自否定表达和连接词继承：消融方案会把“没有胸痛，也没有呼吸困难”中的词项直接视为命中，而完整方案先判断语句断言状态。该对照只用于说明软件规则的增量作用，不能替代临床人工评价。

5.8 本章小结

本章使用固定种子生成并执行 1000 条人工构造工程测试。危险信号召回率为 80.00%，四个受支持科室的 Macro-F1 为 0.9585，加入回退类别后的五分类 Macro-F1 为 0.5861，风险 Macro-F1 为 0.5323，Recall@3 为 71.88%，追问触发率为 100.00%，低证据回退率为 0.00%。结果说明当前 Demo 在封闭科室分诊和结构化追问上保持稳定；对于 P4 词表外表达和非目标专科输入，系统分别呈现普通检索路径和候选证据路径。上述结果只用于工程验证，不作为临床准确率或医疗效果结论。

6 总结与展望

6.1 总结

本文围绕“基于多智能体协同与大语言模型的多专科医疗健康咨询及辅助分诊系统”开展了需求分析、总体设计、详细实现和工程测试，完成了 MedPilot 系统 Demo。

在需求分析方面，本文将系统使用者划分为普通用户、医生、知识编辑人员、审核人员、管理员和审计人员，分别梳理了智能问诊、主动追问、辅助分诊、健康档案、知识审核、医生复核、Trace 监控和审计等业务需求。分析结果表明，医疗健康咨询不能只看最终回答，还需要处理危险信号、信息缺失、知识来源、权限和记录保存等问题。

在总体设计方面，系统采用用户端、业务后端、AI 服务、数据存储和治理管理分层。AI 服务以 LangGraph 组织安全筛查、症状抽取、信息充分性判断、主动追问、知识检索、辅助分诊和回答编排。业务后端负责认证、角色授权、会话所有权、事件累积、持久化和异常处理。数据库将用户、会话、问诊记录、Trace、健康档案、知识文档、临床复核和治理证据分开保存，避免 AI 原始结果、医生最终决定和知识生命周期相互覆盖。

在详细实现方面，系统首先通过否定感知的危险信号匹配器识别胸痛、呼吸困难、气促、咯血、便血、晕厥、意识不清和大出血等表现，并在命中后进入高风险快速通道。未命中危险信号时，本地大语言模型负责将用户描述整理为结构化症状；信息不足时，系统返回带缺失字段的主动追问；信息充分时，bge-m3 和 FAISS 完成医学证据检索，分诊模块根据证据所属科室进行加权判断。最终回答由经过字段和证据校验的确定性渲染器生成，避免自由生成文本直接覆盖分诊字段。

在业务支撑方面，系统实现了问诊记录、健康档案、复诊任务、知识文档和索引版本管理、医生复核、模型与知识治理、Trace 监控及审计日志。JWT、CSRF、AES-256-GCM、医疗关系和紧急授权共同构成访问边界。AI 原始分诊结果在临床复核中保持不可变，医生的确认、修改、退回或急诊升级决定单独保存。

在测试方面，本文构建了覆盖高风险、证据支持、低证据回退和信息不足追问的扩展工程测试集，验证了安全筛查、检索、分诊、追问、权限、加密、断流、超时和索引异常等路径。测试结果以危险信号召回率、科室 F1 和风险等



级 F1 统计图展示，用于说明当前 Demo 的工程行为和规则覆盖情况。

6.2 展望

后续工作可以沿着数据、模型、流程和工程四个方向展开。数据方面，医疗数据脱敏研究提示敏感字段处理需要与模型流程同时设计[36]；数据投毒研究说明知识来源和输入环境应纳入安全边界[37]；智能化语言服务研究则强调医疗文本交互的场景化特征[38]。结合本文实现，后续数据建设应继续维护词表、同义映射、知识来源和审核记录，并保持每次更新可追溯。

模型方面，可以比较不同本地聊天模型和嵌入模型在症状抽取、追问生成和检索排序上的差异。大语言模型赋能医疗卫生智库的研究提示，模型应用需要嵌入明确的知识服务流程[39]。基于专利数据的研究呈现了国内医疗大语言模型应用的技术分布[40]。在线医疗社区虚假评论识别研究说明，合成数据和模型输出的质量需要分别检查[41]。医疗聊天机器人研究梳理了从传统方法到大语言模型的演进路径[42]。CiteSpace 研究则反映出医疗大语言模型研究热点仍在持续变化[43]。因此，后续评价应同时覆盖信息完整性、危险信号召回、证据相关性、解释一致性和回答安全性，不能只比较文本相似度。

流程方面，可以把医生复核反馈用于规则和知识的回归分析，建立从异常 Trace 到变更请求、验证证据和回滚结果的闭环。人工智能嵌入临终关怀的伦理研究提醒，系统进入敏感服务流程时需要明确责任边界[44]。数字赋能健康治理研究强调，技术能力应与服务流程和治理机制协同建设[45]。人工智能应用伦理安全治理研究进一步提出，应把责任、审计和风险处置落实到可执行的管理环节[46]。对于需要医院流程接入的场景，还需要在获得机构授权后对接统一身份、患者主索引、就诊关系和院内科室编码，并重新确认数据访问范围。

工程方面，可以继续完善并发控制、缓存策略、索引切换、监报告警和备份恢复，开展更大规模的压力测试和故障演练。前端还可以在保持当前状态边界的基础上，优化移动端问诊、引用查看和复核协同体验。上述展望均以当前 Demo 的工程验证范围为前提，不把离线测试结果延伸为临床部署结论。



参考文献

- [1] QIU J, LAM K, LI G, et al. LLM-based agentic systems in medicine and healthcare[J]. Nature Machine Intelligence, 2024, 6(12): 1418-1420. DOI:10.1038/s42256-024-00944-1.
- [2] HAGER P, JUNGSMANN F, HOLLAND R, et al. Evaluation and mitigation of the limitations of large language models in clinical decision-making[J]. Nature Medicine, 2024, 30(9): 2613-2622. DOI:10.1038/s41591-024-03097-1.
- [3] TAM T Y C, SIVARAJKUMAR S, KAPOOR S, et al. A framework for human evaluation of large language models in healthcare derived from literature review[J]. npj Digital Medicine, 2024, 7(1): 258. DOI:10.1038/s41746-024-01258-7.
- [4] CHEN X, YI H, YOU M, et al. Enhancing diagnostic capability with multi-agents conversational large language models[J]. npj Digital Medicine, 2025, 8(1): 159. DOI:10.1038/s41746-025-01550-0.
- [5] GABER F, SHAIK M, ALLEGA F, et al. Evaluating large language model workflows in clinical decision support for triage and referral and diagnosis[J]. npj Digital Medicine, 2025, 8(1): 263. DOI:10.1038/s41746-025-01684-1.
- [6] KANG B, SON M, JEONG W, et al. Large language model-assisted referral triage automation in a tertiary hospital[J]. npj Digital Medicine, 2026: 1-8. DOI:10.1038/s41746-026-03067-6.
- [7] FLANDERS A E, PENG Y, PREVEDELLO L, et al. A multi-agent large language model framework to automatically assess performance of a clinical AI Triage tool[J]. npj Health Systems, 2026, 3(1): 1-7. DOI:10.1038/s44401-026-00100-4.
- [8] 孙丽萍,童子龙,钱乾,等.基于医疗临床数据的两阶段专业级大语言模型微调[J].计算机应用研究,2024,41(10):2906-2910.DOI:10.19734/j.issn.1001-3695.2024.03.0071.
- [9] 杨霞,刘义兰,孙丽,等.人工智能门诊分诊对分诊准确率及患者满意度的影响[J].护理学杂志,2025,40(18):10-13.
- [10] 张玉晨,王传涛,夏海梁,等.基于大语言模型的医疗智能助手应用研究进展[J].协和医学杂志,2025,16(6):1511-1518.
- [11] 张建同,俞文杰,李君昌,等.基于大语言模型的在线问诊医疗主题识别:以医患交流文本为驱动[J].图书与情报,2026,(3):88-102.
- [12] 刘婕,郝舒欣,刘博涵,等.智能问答模型构建以及在公共卫生领域应用:基于检索增强生成技术[J].中国公共卫生,2026,42(5):556-562.
- [13] 马鑫,王芳,张峰,等.慢性病智能医疗问答系统构建与评价:一种基于 GraphRAG 与 MoE 的混合建模方法[J].情报学报,2026,45(3):447-462.
- [14] 刘澳迪,奚雪峰,周国栋.面向大语言模型生成能力提升的检索增强生成研究进展[J/OL].软件学报,1-30[2026-08-26].<https://doi.org/10.13328/j.cnki.jos.007684>.
- [15] 齐雅萱,刘勤明,叶春明,等.基于投影迭代优化算法与多特征权重急诊患者动态调度[J/

- OL]. 计算机应用, 1-14[2026-08-26]. <https://link.cnki.net/urlid/51.1307.TP.20260707.1549.012>.
- [16] 田崇腾, 刘静, 王晓燕, 等. 大语言模型 GPT 在医疗文本中的应用综述[J]. 计算机科学与探索, 2025, 19(8): 2043-2056.
- [17] 陈紫林, 祝帆帆, 卢龙. 基于大语言模型的中文文献主题建模框架与实证研究——以医疗健康数据要素领域为例[J/OL]. 图书情报工作, 1-18[2026-08-26]. <https://link.cnki.net/urlid/11.1541.G2.20260817.1322.012>.
- [18] 王会勇, 苏秋雨, 张晓明. 基于多任务微调大语言模型的重症医疗知识抽取方法研究[J]. 计算机科学与探索, 2026, 20(4): 1031-1045.
- [19] ZAKKA C, SHAD R, CHAURASIA A, et al. Almanac—Retrieval-augmented language models for clinical medicine[J]. NEJM AI, 2024, 1(2). DOI:10.1056/AIoa2300068.
- [20] 郑卿勇, 吴景玲, 李莫兰, 等. TRIPOD-LLM 指南解读: 规范医疗领域大语言模型研究的报告标准[J]. 中国循证医学杂志, 2025, 25(8): 967-978.
- [21] 于蓓莉, 蒲青云, 冯梅, 等. 我国人工智能算法偏见治理的政策体系与优化路径研究[J/OL]. 图书与情报, 1-12[2026-08-26]. <https://link.cnki.net/urlid/62.1026.G2.20260811.1046.002>.
- [22] 陶立元, 钟晓莹, 代倩倩, 等. 医疗保健领域大语言模型研究报告规范 TRIPOD-LLM 的应用范围解析与现状调查[J]. 中华医学杂志, 2025, 105(38): 3379-3383.
- [23] GALLIFANT J, AFSHAR M, AMEEN S, et al. The TRIPOD-LLM reporting guideline for studies using large language models[J]. Nature Medicine, 2025, 31(1): 60-69. DOI:10.1038/s41591-024-03425-5.
- [24] AMUGONGO L M, MASCHERONI P, BROOKS S, et al. Retrieval augmented generation for large language models in healthcare: A systematic review[J]. PLOS Digital Health, 2025, 4(6): e0000877. DOI:10.1371/journal.pdig.0000877.
- [25] 邢倩, 何达. 医疗大语言模型的评价现状及思考[J]. 健康发展与政策研究, 2025, 28(1): 65-72+79.
- [26] 徐伟, 张洪辉, 林文凤. 急性主动脉夹层患者急诊分诊筛查及预测工具的研究进展[J]. 护理学杂志, 2025, 40(18): 18-21.
- [27] 王崇金, 周铿, 徐乃伟, 等. 以患者体验为导向的互联网医院就医流程构建[J]. 中国医院, 2025, 29(8): 13-16. DOI:10.19660/j.issn.1671-0592.2025.8.04.
- [28] 陈紫林, 祝帆帆, 罗宇昕, 等. 大语言模型在医疗健康领域的应用现状与前景展望[J]. 医学与哲学, 2025, 46(12): 32-37.
- [29] 闫温馨, 胡健, 曾华堂, 等. 人工智能大语言模型在基层医疗卫生服务中的应用与挑战[J]. 中国全科医学, 2025, 28(1): 1-6.
- [30] 王鑫林, 李岩, 马超凡, 等. 检索增强生成综述: 方法与应用[J]. 计算机科学, 2026, 53(7): 101-117.
- [31] 李艳鹏, 斯琴图, 王斯日古楞. 面向医学问答的检索增强生成方法综述[J/OL]. 计算机科学与探索, 1-24[2026-08-26]. <https://link.cnki.net/urlid/11.5602.TP.20260615.0939.002>.
- [32] 向洋, 李理, 韩东轩, 等. 融合反思机制与检索增强生成技术的中医问诊模型[J/OL]. 计算机工程与应用, 1-15[2026-08-26]. <https://link.cnki.net/urlid/11.2127.tp.20260604.1348.008>.
- [33] 冯朔, 张清华, 高满, 等. 基于粒计算的医疗检索增强生成方法[J/OL]. 重庆邮电大学学报(自然科学版), 1-12[2026-08-26]. <https://link.cnki.net/urlid/50.1181.N.20260522.1051.002>.
- [34] 肖建力, 许东舟, 王浩, 等. 医疗领域的大型语言模型综述[J]. 智能系统学报, 2025, 20(3): 530-

547.

- [35] 王瑞,谭旭彤,赵从朴,等.医疗不良事件人工智能分类与手动分类的对比研究——以 DeepSeek 大语言模型为例[J].协和医学杂志,2026,17(3):828-833.
- [36] 张志立,杨红,庞娟,等.大语言模型在医疗数据脱敏中的实践与表现[J].北京大学学报(自然科学版),2025,61(6):1057-1063.DOI:10.13209/j.0479-8023.2025.092.
- [37] ALBER D A, YANG Z, ALYAKIN A, et al. Medical large language models are vulnerable to data-poisoning attacks[J]. Nature Medicine, 2025, 31(2): 618-626. DOI:10.1038/s41591-024-03445-1.
- [38] 王玲.医疗领域智能化语言服务的特点及研究趋势[J].东南大学学报(哲学社会科学版),2026,28(3):143-152+164.DOI:10.13916/j.cnki.issn1671-511x.2026.03.009.
- [39] 熊励,郭佳璐.大语言模型赋能医疗卫生智库转型路径研究[J].智库理论与实践,2026,11(1):102-110.DOI:10.19318/j.cnki.issn.2096-1634.20250124.0007.
- [40] 李颖婷,夏苏迪,杨春花,等.基于专利数据的我国医疗大语言模型应用现状与发展特征研究[J].健康发展与政策研究,2026,29(1):24-32.
- [41] 王嘉杰,李天逸,丁天,等.基于大语言模型合成数据的在线医疗社区虚假评论识别研究[J].情报理论与实践,2025,48(10):120-129.DOI:10.16353/j.cnki.1000-7490.2025.10.014.
- [42] 王子星,齐乐,廉晓丹,等.医疗领域聊天机器人的发展与应用:从传统方法到大语言模型[J].协和医学杂志,2025,16(5):1170-1178.
- [43] 牛奔,朱晓倩,杨辰,等.基于 CiteSpace 的国内外医疗大语言模型研究热点演进及趋势分析[J].中国全科医学,2025,28(25):3200-3208.
- [44] 杨渐雨,刘星亮.人工智能嵌入临终关怀的伦理困境及其超越[J/OL].健康发展与政策研究,1-8[2026-08-26].<https://link.cnki.net/urlid/31.2200.R.20260821.1512.001>.
- [45] 苏敏,杨黎明,李政蓉.数字赋能健康治理创新的机理、样态和路径[J/OL].内蒙古社会科学,1-9[2026-08-26].<https://link.cnki.net/urlid/15.1011.C.20260811.1007.020>.
- [46] 郝春亮,赵静,傅宏宇,等.推动“智能向善”:人工智能应用伦理安全治理的多维阐释[J].电子政务,2026,(8):2-18.DOI:10.16582/j.cnki.dzzw.2026.08.001.

致谢

回首往昔，大一初入校园时的懵懂与好奇仍历历在目。转眼间大学生活已近尾声，时光总是在不经意间悄然流逝，我也即将挥别这段珍贵的大学岁月。在这几年的求学历程中，有父母无微不至的关怀与支持，有学院各位老师的辛勤培育与悉心指引，有学长学姐们的倾囊相授，亦有同窗好友相伴前行的温情时光。正因有你们的一路相伴，才使我的大学生活充实而丰满。在此，我谨致以最真诚的感谢。

首先，我最想要感谢的是我的爸爸妈妈。父母之爱深沉而厚重，无论我走得多远，他们始终是我坚实的后盾。在大学求学期间，是他们的默默付出、无私包容与殷切期望，给予了我勇往直前的力量与底气。我在学业与成长路上迈出的每一步，都凝聚着他们的心血与汗水。在今后的人生道路上，我定会加倍努力、奋力拼搏，不辜负父母多年来的养育之恩与殷殷期盼。

其次，我要由衷感谢李润东、宗科、荆梓恒学长，以及夏妍欢、沈欣怡、倪霜霜学姐。在我的大学生活中，学长学姐们无论是在专业学习、竞赛项目还是生活经验上，都给予了我许多无私的帮助与宝贵的建议。每当我遇到困惑与难题时，总能得到你们热心的指点与鼓励。在此衷心祝愿各位学长学姐前程似锦，山高路远，顺遂无虞；他日相逢，再叙深情厚谊。

同时，我要由衷感谢我的同学刘坤和樊诗煜。在大学期间，我们一起度过了无数充实而难忘的时光。无论是在日常学习、项目合作中的相互协作、共同探讨，还是在课后与生活中的彼此鼓励、真诚陪伴，都给予了我莫大的支持与动力。大学时光因有你们的同行而格外珍贵，在此祝愿你们在未来的道路上前程广阔、万事顺遂、平安喜乐！

接下来，我要感谢我的辅导员王群老师。在大学期间，王老师在日常学习、生活管理以及思想引导上始终给予我们无微不至的关怀与负责耐心的指导，为我们的大学生活保驾护航，陪伴并见证了我们的成长与蜕变。

同时，我要向石玲老师致以诚挚的谢意。在专业学习与实践探索的过程中，石老师严谨治学的态度、扎实的专业功底以及耐心的指导点拨，使我受益匪浅，不仅拓宽了我的专业视野，更培养了我独立思考与解决问题的能力。

最后，我要特别感谢我的论文指导老师王伟老师和陈祥老师。在本次毕业

设计与论文撰写的整个过程中，两位老师倾注了大量的心血与关怀。从课题的选定、方案的论证，到系统实现的细节打磨以及论文的反复修改，老师们都给予了极具针对性、细致且严谨的指导。正是在两位指导老师的严格要求与悉心点拨下，我的毕业设计论文才得以顺利完成。在此，向王伟老师和陈祥老师致以最崇高的敬意与衷心的感谢，并祝愿各位老师工作顺利、桃李芬芳、身体安康！